

Pipeline de Machine Learning com Dataset Real

Predição da Qualidade do Vinho a partir de Atributos Físico-Químicos

Identificação	
Integrantes	Jeann Victor Batista (RA 2024.1.08.014) • Nicolas Rodrigues Teixeira de Oliveira (RA 2023.1.08.047) • Enzo Maranezi (RA 2024.1.08.008)
Curso	Bacharelado em Ciência da Computação – UNIFAL-MG
Disciplina	Inteligência Artificial • Professor: Paulo Alexandre Bressan
Dataset	Wine Quality – vinho tinto (winequality-red.csv), UCI Machine Learning Repository
Tarefa	Regressão – prever a nota sensorial de qualidade (0–10) a partir de 11 atributos físico-químicos

Descrição do problema: o dataset contém 1599 amostras de vinho tinto *Vinho Verde* português, com 11 variáveis físico-químicas de entrada (acidez, açúcares, cloretos, dióxido de enxofre, densidade, pH, sulfatos, teor alcoólico, entre outras) e uma variável-alvo (*quality*) baseada na mediana de avaliações sensoriais de especialistas. O objetivo é construir um pipeline completo de ML – EDA, pré-processamento, treinamento/comparação de modelos e avaliação final – para estimar a qualidade do vinho a partir de suas propriedades objetivas.

Declaração de uso de IA generativa: este trabalho foi estruturado com o auxílio da ferramenta de IA generativa Claude (Anthropic) para apoiar a codificação e a redação deste relatório. O grupo revisou, compreende e é capaz de explicar todo o conteúdo entregue.

1 Análise Exploratória de Dados (EDA)

O dataset possui 1599 instâncias e 12 colunas (11 atributos numéricos contínuos + a variável-alvo *quality*, inteiro de 3 a 8 neste conjunto). Não há variáveis categóricas nem **valores ausentes** (confirmado por `isnull().sum()` em todas as colunas). A variável-alvo é fortemente **desbalanceada**: as notas 5 e 6 concentram 82,5% das amostras, enquanto notas extremas (3, 4, 7, 8) são raras (Figura 1). Também há **outliers** (regra IQR 1,5×) em praticamente todos os atributos, com destaque para *residual sugar* (9,7%) e *chlorides* (7,0%) – Figura 4.




Figura 1: Distribuição da variável-alvo *quality*.




Figura 2: Teor alcoólico e acidez volátil por nota.




Figura 3: Matriz de correlação entre atributos.




Figura 4: Boxplots – identificação de outliers.

Insights: (1) o forte desbalanceamento da variável-alvo indica que o modelo tende a “regredir à média”, errando mais nas notas extremas – por isso avaliamos o erro por faixa de qualidade, e não apenas globalmente; (2) alcohol tem a correlação positiva mais forte com quality e volatile acidity a correlação negativa mais notável (Figura 3 e 2), sugerindo que esses atributos devem ter maior peso na modelagem.

2 Pré-processamento

- **Valores ausentes:** inexistentes – nenhuma imputação necessária.
- **Variáveis categóricas:** inexistentes – nenhum *encoding* necessário.
- **Padronização:** aplicado `StandardScaler` a todos os atributos numéricos, pois têm escalas muito distintas (ex.: total sulfur dioxide chega a centenas, enquanto chlorides é da ordem de 0,01–0,1), o que é essencial para a Regressão Linear e neutro para a Random Forest.
- **Divisão treino/teste:** 80%/20% (1279/320 amostras) realizada *antes* de qualquer ajuste de pré-processamento. O `StandardScaler` é encapsulado em um Pipeline do scikit-learn (via `ColumnTransformer`), ajustado (`fit`) somente no treino em cada fold – evitando *data leakage*.

3 Modelagem e Comparação de Modelos

Como baseline, usamos um `DummyRegressor` (previsão pela média). Treinamos dois algoritmos estudados na disciplina – **Regressão Linear** e **Random Forest Regressor** – avaliados por validação cruzada **estratificada** (`StratifiedKFold`, $k = 5$), estratificando diretamente pelos valores discretos e desbalanceados de quality para preservar a proporção de cada nota em cada fold.

Tabela 1: Comparação de modelos – validação cruzada estratificada ($k = 5$) no treino.

Modelo	MAE	RMSE	R^2
Baseline (média)	$0,684 \pm 0,004$	$0,807 \pm 0,007$	$0,000 \pm 0,000$
Regressão Linear	$0,504 \pm 0,008$	$0,658 \pm 0,013$	$0,333 \pm 0,025$
Random Forest	$0,425 \pm 0,016$	$0,593 \pm 0,029$	$0,458 \pm 0,051$


A Random Forest superou o baseline e a Regressão Linear em todas as métricas, capturando relações não lineares entre atributos e qualidade; por isso foi escolhida para ajuste de hiperparâmetros via GridSearchCV (mesmo esquema de validação cruzada), buscando $n_estimators \in \{100, 300, 500\}$, $max_depth \in \{\text{sem limite}, 10, 20\}$ e $min_samples_leaf \in \{1, 2, 4\}$. Melhor combinação: $n_estimators=500$, $max_depth=20$, $min_samples_leaf=1$ (RMSE médio em CV = 0,591).

4 Avaliação Final e Análise de Erros

O modelo final foi avaliado no conjunto de teste (*hold-out*), não utilizado em nenhuma etapa de treinamento ou seleção de hiperparâmetros:

Tabela 2: Desempenho do modelo final (Random Forest ajustado) no conjunto de teste.

MAE	RMSE	R^2
0,426	0,556	0,528

**Figura 5:** Predito vs. real e distribuição dos resíduos no conjunto de teste.

Análise de erros: o erro médio absoluto por nota real confirma o padrão previsto na EDA – é claramente maior nas notas extremas (3: 2,32; 4: 1,20; 8: 1,35) do que nas notas centrais (5: 0,32; 6: 0,38; 7: 0,57), já que há poucos exemplos de vinhos muito bons ou muito ruins para o modelo aprender, levando-o a “puxar” as previsões em direção à média.

5 Limitações, Melhorias Futuras e Conclusão

Limitações: o desbalanceamento da variável-alvo limita a generalização do modelo para vinhos excepcionais ou defeituosos; a nota é a mediana de avaliações subjetivas, o que impõe um teto de desempenho mesmo para humanos; e não há atributos como tipo de uva, marca ou preço, que poderiam ser preditivos. **Melhoria futura:** aplicar técnicas de balanceamento para regressão

(ex.: SMOGN), testar Gradient Boosting (XGBoost/LightGBM) com busca de hiperparâmetros mais ampla, e combinar os datasets de vinho tinto e branco para aumentar o volume de dados.

Conclusão: o pipeline cobriu EDA, pré-processamento sem *data leakage* (via Pipeline do scikit-learn), comparação de modelos com validação cruzada estratificada, ajuste de hiperparâmetros e avaliação em *hold-out*. A Random Forest superou o baseline e a Regressão Linear em todas as métricas, confirmando relações não lineares relevantes entre os atributos físico-químicos e a qualidade sensorial do vinho – com o desbalanceamento da nota como principal limitação e ponto de partida para trabalhos futuros.