

Universidade Federal de Alfenas
Instituto de Ciências Exatas
Curso de Bacharelado em Ciência da Computação

Plano de Investigação Computacional

Diferenciação e Integração Numéricas: Análise, Comparação e
Aplicações em Python

Aluno: Jeann Victor Batista
RA: 2024.1.08.014

Aluno: Pedro Augusto de Souza Finnochio
RA: 2024.1.08.020

Aluno: Thiago Martins da Silva
RA: 2024.1.08.023

Disciplina: Cálculo Numérico

Professora: Angela Leite Moreno

Alfenas, 2026

Sumário

1. Fórmulas de Diferenças Finitas
 - 1.1 Verificação e primeiros experimentos
 - 1.2 Conflito entre truncamento e arredondamento
 - 1.3 Diferenciação de tabela experimental
 - 1.4 Segunda derivada e aplicações
2. Newton-Cotes: Trapézios e Simpson
 - 2.1 Verificação das fórmulas
 - 2.2 Análise de erro e determinação de n
 - 2.3 Integração de dados experimentais
3. Quadratura Gaussiana e Comparação de Métodos
 - 3.1 Eficiência da Quadratura Gaussiana
 - 3.2 Limitação dos nós de Chebyshev
4. Análise Comparativa Global
 - 4.1 Tabela de síntese
 - 4.2 Tomada de decisão em cenários reais
5. Projeto Integrador: Cálculo Variacional e Física
 - 5.1 Comprimento de curva
 - 5.2 Trabalho realizado por uma força variável
 - 5.3 Distribuição Normal e Probabilidade
6. Desafio (Opcional — Pontuação Extra)
 - 6.1 Richardson Extrapolation
 - 6.2 Integração de Monte Carlo
 - 6.3 Gradiente Numérico em Machine Learning

1 Fórmulas de Diferenças Finitas

1.1 Verificação e primeiros experimentos

Questão 1.1 — Verificação e primeiros experimentos

Enunciado: Para $f(x) = \sin x$ em $x_0 = \pi/3$, o valor exato é $f'(\pi/3) = \cos(\pi/3) = 0,500000$. Use as três fórmulas de dois pontos com $h = 0,1$. Para cada fórmula, calcule o valor aproximado e o erro absoluto.

(a) Preencha a tabela abaixo:

Fórmula	Valor aproximado	Erro $ e $	Ordem esperada
Progressiva			$O(h)$
Regressiva			$O(h)$
Central			$O(h^2)$

(b) Repita com $h = 0,01$. Os erros diminuíram pelo fator esperado (2 para as de 1ª ordem, 100 para a central)?

(c) Por que a fórmula central tem erro $O(h^2)$ mas usa apenas dois pontos ao redor de x_0 , assim como a progressiva?

Resposta:

(a) Tabela com $h = 0,1$:

Para $f(x) = \sin x$ em $x_0 = \pi/3$, o valor exato é $f'(\pi/3) = \cos(\pi/3) = 0,500000$. Aplicando as três fórmulas de dois pontos com $h = 0,1$, obtivemos:

Tabela 1: Resultados das fórmulas de dois pontos para $h = 0,1$.

Fórmula	Valor aproximado	Erro $ e $	Ordem esperada
Progressiva	0,45590189	$4,41 \times 10^{-2}$	$O(h)$
Regressiva	0,54243228	$4,24 \times 10^{-2}$	$O(h)$
Central	0,49916708	$8,33 \times 10^{-4}$	$O(h^2)$

Como era de se esperar, a fórmula central apresenta erro significativamente menor que as progressiva e regressiva, pois sua ordem de convergência é $O(h^2)$ contra $O(h)$ das outras duas.

(b) Redução do erro ao passar de $h = 0,1$ para $h = 0,01$:

Repetindo os cálculos com $h = 0,01$, obtivemos os seguintes fatores de redução:

Tabela 2: Comparação dos fatores de redução do erro ao reduzir h de 0,1 para 0,01.

Fórmula	Erro ($h = 0,1$)	Erro ($h = 0,01$)	Fator observado	Fator esperado
Progressiva	$4,41 \times 10^{-2}$	$4,34 \times 10^{-3}$	$\approx 10,2\times$	$10\times$
Regressiva	$4,24 \times 10^{-2}$	$4,32 \times 10^{-3}$	$\approx 9,8\times$	$10\times$
Central	$8,33 \times 10^{-4}$	$8,33 \times 10^{-6}$	$\approx 100\times$	$100\times$

Os resultados experimentais confirmam perfeitamente as ordens teóricas esperadas. As fórmulas progressiva e regressiva tiveram seus erros reduzidos por um fator de aproximadamente 10 ao diminuir h por um fator de 10, o que é consistente com erro

$O(h)$. Já a fórmula central apresentou redução de cerca de 100 vezes, corroborando seu comportamento $O(h^2)$.

(c) Por que a fórmula central é $O(h^2)$ usando apenas dois pontos?

A explicação está na expansão em série de Taylor e no **cancelamento simétrico** dos termos de ordem ímpar. Expandindo $f(x+h)$ e $f(x-h)$ ao redor de x :

$$\begin{aligned}f(x+h) &= f(x) + hf'(x) + \frac{h^2}{2}f''(x) + \frac{h^3}{6}f'''(x) + \dots \\f(x-h) &= f(x) - hf'(x) + \frac{h^2}{2}f''(x) - \frac{h^3}{6}f'''(x) + \dots\end{aligned}$$

Subtraindo a segunda expressão da primeira:

$$f(x+h) - f(x-h) = 2hf'(x) + \frac{h^3}{3}f'''(x) + \dots$$

Dividindo ambos os lados por $2h$:

$$\frac{f(x+h) - f(x-h)}{2h} = f'(x) + \frac{h^2}{6}f'''(x) + \dots$$

A chave está na **simetria**: ao utilizar um ponto à direita e outro à esquerda de x , os termos de potência par em h — que incluem $f''(x)$ — se cancelam mutuamente na subtração. Como resultado, o termo dominante de erro, que seria $O(h)$, desaparece completamente, deixando o erro restante como $O(h^2)$, associado ao termo com $f'''(x)$. Na fórmula progressiva, por outro lado, expandimos $f(x+h) - f(x)$:

$$f(x+h) - f(x) = hf'(x) + \frac{h^2}{2}f''(x) + \dots$$

O termo $\frac{h^2}{2}f''(x)$ **não cancela**, resultando em um erro $O(h)$. A beleza da fórmula central é que ela "ganha" uma ordem de precisão extra utilizando apenas os mesmos dois pontos laterais, sem custo adicional de avaliações da função — tudo graças à simetria da aproximação.

Questão 1.2 — Fórmulas de três pontos

Enunciado: Para a mesma função, use agora as fórmulas de três pontos com $h = 0,1$ e $h = 0,01$.

- Calcule `df_prog3`, `df_retro3` e `df_central`. Monte uma tabela com os erros.
- Ao reduzir h de 0,1 para 0,01 (fator 10), por quanto o erro de cada fórmula foi reduzido? Isso é consistente com erro $O(h^2)$?
- Por que a fórmula central de 3 pontos produz o mesmo resultado que a central de 2 pontos?

Resposta:

(a) Tabela comparativa dos erros para $h = 0,1$ e $h = 0,01$:

Para $f(x) = \sin x$ em $x_0 = \pi/3$, com valor exato $f'(\pi/3) = 0,500000$, os resultados obtidos foram:

Tabela 3: Resultados das fórmulas de três pontos para $h = 0,1$ e $h = 0,01$.

Fórmula	h	Valor aproximado	Erro $ e $
Progressiva 3 pts	0,1	0,50144469	$1,44 \times 10^{-3}$
Progressiva 3 pts	0,01	0,50001645	$1,64 \times 10^{-5}$
Regressiva 3 pts	0,1	0,50187699	$1,88 \times 10^{-3}$
Regressiva 3 pts	0,01	0,50001688	$1,69 \times 10^{-5}$
Central 2 pts	0,1	0,49916708	$8,33 \times 10^{-4}$
Central 2 pts	0,01	0,49999167	$8,33 \times 10^{-6}$

Observa-se que todas as três fórmulas produzem erros de ordem 10^{-3} para $h = 0,1$ e de ordem 10^{-5} para $h = 0,01$, comportamento consistente com a ordem esperada $O(h^2)$.

(b) Fator de redução do erro ao reduzir h de 0,1 para 0,01:

Tabela 4: Fatores de redução do erro ao passar de $h = 0,1$ para $h = 0,01$.

Fórmula	Erro ($h = 0,1$)	Erro ($h = 0,01$)	Fator observado	Fator esperado
Progressiva 3 pts	$1,44 \times 10^{-3}$	$1,64 \times 10^{-5}$	$\approx 87,8\times$	$100\times$
Regressiva 3 pts	$1,88 \times 10^{-3}$	$1,69 \times 10^{-5}$	$\approx 111,2\times$	$100\times$
Central 2 pts	$8,33 \times 10^{-4}$	$8,33 \times 10^{-6}$	$\approx 100,0\times$	$100\times$

Os três métodos apresentam comportamento consistente com a ordem $O(h^2)$: ao reduzir h por um fator 10, o erro é reduzido por um fator próximo de 100. Os pequenos desvios observados nas fórmulas unilaterais ($87,8\times$ e $111,2\times$) decorrem da contribuição de termos de ordem superior — que ainda têm influência quando $h = 0,1$ não é suficientemente pequeno. À medida que h continua decrescendo, esses fatores convergem para 100, confirmando a ordem teórica.

(c) Por que a fórmula central de 2 pontos e as de 3 pontos (progressiva e regressiva) produzem resultados de ordem $O(h^2)$?

Embora as fórmulas pareçam estruturalmente diferentes, todas compartilham um mesmo princípio fundamental: o cancelamento do termo dominante de erro.

A **fórmula central de 2 pontos** atinge ordem $O(h^2)$ por **cancelamento de simetria**: ao utilizar pontos igualmente espaçados à direita e à esquerda de x , os termos de potência par em h se anulam na subtração $f(x+h) - f(x-h)$, eliminando o erro de primeira ordem — como demonstrado na Questão 1.1(c).

As **fórmulas de 3 pontos** (progressiva e regressiva) foram construídas para atingir essa mesma ordem $O(h^2)$ utilizando apenas pontos de um único lado de x_0 . Essa é uma situação típica das bordas de uma tabela, onde não existe o ponto simétrico necessário para a fórmula central. A combinação linear de três avaliações com coeficientes apropriados $[-3, 4, -1]/(2h)$ anula o termo de primeira ordem, resultando em erro $O(h^2)$.

A conexão algébrica entre as fórmulas fica evidente quando observamos que a fórmula central de 2 pontos é exatamente a **média aritmética** das fórmulas progressiva e regressiva de primeira ordem:

$$\frac{f'_{\text{prog}} + f'_{\text{retro}}}{2} = \frac{1}{2} \left[\frac{f(x+h) - f(x)}{h} + \frac{f(x) - f(x-h)}{h} \right] = \frac{f(x+h) - f(x-h)}{2h}.$$

Expandindo em série de Taylor:

- Progressiva 1ª ordem: $f'(x) + \frac{h}{2}f''(x) + O(h^2)$ — erro com sinal positivo
- Regressiva 1ª ordem: $f'(x) - \frac{h}{2}f''(x) + O(h^2)$ — erro com sinal negativo

A média cancela o termo $\frac{h}{2}f''(x)$, resultando em $O(h^2)$. Analogamente, as fórmulas de 3 pontos realizam esse mesmo cancelamento combinando linearmente três avaliações unilaterais com coeficientes cuidadosamente escolhidos para anular o termo dominante de erro.

É por essa razão que os três métodos convergem com o mesmo fator ≈ 100 ao reduzir h por 10 — todos compartilham a mesma ordem $O(h^2)$, embora com constantes de erro diferentes (os coeficientes que multiplicam o termo h^2 variam entre os métodos).

1.2 Conflito entre truncamento e arredondamento

Questão 1.3 — Passo ótimo

Enunciado: Para $f(x) = e^x$ em $x_0 = 1,0$ (valor exato: $f'(1,0) = e \approx 2,71828$), use a fórmula `df_central` com $h = 10^{-1}, 10^{-2}, \dots, 10^{-16}$ (`np.logspace(0, -16, 200)`).

(a) Plote o erro absoluto em escala log-log. Descreva o que acontece à medida que h decresce: o erro primeiro cai, depois sobe. Por que?

(b) Identifique experimentalmente o h_{opt} (ponto de mínimo do erro). Qual é seu valor aproximado? Compare com a estimativa teórica $h_{\text{opt}} \approx \varepsilon_m^{1/3} \approx 10^{-5}$ para a fórmula central.

(c) Repita para `df_progressiva`. O h_{opt} é diferente? Compare com $h_{\text{opt}} \approx \sqrt{\varepsilon_m} \approx 10^{-8}$.

(d) Qual fórmula atinge menor erro mínimo: progressiva ou central? Por quanto? Isso é consistente com as ordens $O(h)$ e $O(h^2)$?

Resposta:

(a) Comportamento do erro em função de h :




Figura 1: Erro absoluto da fórmula central em função de h (escala log-log) para $f(x) = e^x$ em $x_0 = 1,0$. A curva revela os dois regimes de erro: queda por truncamento para h grandes, e crescimento por arredondamento para h pequenos.

O gráfico do erro absoluto em escala log-log para $f(x) = e^x$ em $x_0 = 1,0$ revela dois regimes distintos à medida que h decresce:

- **Região de truncamento** (h grande, tipicamente $h > 10^{-5}$): o erro cai sistematicamente, pois o termo dominante da expansão de Taylor, que é $O(h^2)$ para a fórmula central, diminui com h . Nesta região, o erro é governado pela aproximação matemática — quanto menor o passo, melhor a aproximação da derivada. No gráfico log-log, a queda do erro segue a inclinação teórica de $+2$ (já que $\log |E| \propto 2 \log h$).
- **Região de arredondamento** (h pequeno, tipicamente $h < 10^{-6}$): ao subtrair valores de f muito próximos entre si, ocorre **cancelamento catastrófico** — a diferença $f(x+h) - f(x-h)$ perde dígitos significativos para a precisão de máquina $\varepsilon_m \approx 2,2 \times 10^{-16}$. O erro de arredondamento cresce proporcionalmente a $1/h$, fazendo o erro total subir novamente. Nesta região, a precisão da computação em ponto flutuante se torna o fator limitante.

O resultado é uma curva em formato de “V” (ou “U”) no plano log-log, com um mínimo bem definido — o **passo ótimo** h_{opt} — que representa o equilíbrio entre os dois tipos de erro. Antes desse ponto, a aproximação melhora com h menor; depois dele, a precisão da máquina degrada o resultado.

(b) Passo ótimo da fórmula central:

Experimentalmente, o ponto de mínimo do erro para a fórmula central foi identificado em:

$$h_{\text{opt}} \approx 1,63 \times 10^{-6}, \quad E_{\text{min}} \approx 1,43 \times 10^{-13}.$$

A estimativa teórica para a fórmula central é $h_{\text{opt}} \approx \varepsilon_m^{1/3} \approx 1,0 \times 10^{-5}$.

Tabela 5: Comparação entre o passo ótimo experimental e a estimativa teórica para a fórmula central.

Grandeza	Valor experimental	Valor teórico
h_{opt}	$1,63 \times 10^{-6}$	$\approx 1,00 \times 10^{-5} (\varepsilon_m^{1/3})$
E_{min}	$1,43 \times 10^{-13}$	$\approx \varepsilon_m^{2/3} \approx 10^{-10}$

O valor experimental de $h_{\text{opt}} \approx 1,63 \times 10^{-6}$ está na mesma ordem de grandeza da estimativa teórica $\varepsilon_m^{1/3}$. A discrepância numérica é esperada: a fórmula teórica é uma estimativa de ordem de grandeza que depende de $|f'''(x)|$, que não é exatamente 1 para $f(x) = e^x$ em $x_0 = 1,0$ (na verdade, $|f'''(1)| = e \approx 2,718$). O erro mínimo atingido foi $1,43 \times 10^{-13}$, ligeiramente melhor do que a estimativa teórica $\varepsilon_m^{2/3} \approx 10^{-10}$, o que indica que a constante multiplicativa favorece a fórmula neste ponto.

(c) Passo ótimo da fórmula progressiva:

Repetindo o experimento para a fórmula progressiva, obtivemos:

$$h_{\text{opt}} \approx 9,12 \times 10^{-9}, \quad E_{\text{min}} \approx 5,19 \times 10^{-10}.$$

A estimativa teórica para a fórmula progressiva é $h_{\text{opt}} \approx \sqrt{\varepsilon_m} \approx 1,48 \times 10^{-8}$.

Tabela 6: Comparação entre o passo ótimo experimental e a estimativa teórica para a fórmula progressiva.

Grandeza	Valor experimental	Valor teórico
h_{opt}	$9,12 \times 10^{-9}$	$\approx 1,48 \times 10^{-8} (\sqrt{\varepsilon_m})$
E_{min}	$5,19 \times 10^{-10}$	$\approx \varepsilon_m^{1/2} \approx 1,5 \times 10^{-8}$

O h_{opt} experimental ($9,12 \times 10^{-9}$) está em excelente acordo com a previsão teórica $\sqrt{\varepsilon_m} \approx 1,48 \times 10^{-8}$, considerando a natureza de estimativa de ordem de grandeza da fórmula teórica.

A fórmula progressiva exige um passo **muito menor** (cerca de 180 vezes menor que a central) para equilibrar os erros. Isso ocorre porque seu erro de truncamento cai mais lentamente ($\propto h$, contra $\propto h^2$ da central), obrigando h a diminuir mais antes que o ganho de precisão se esgote e o arredondamento passe a dominar.

(d) Comparação entre as duas fórmulas:

Tabela 7: Comparação entre as fórmulas central e progressiva no passo ótimo.

Fórmula	Ordem	h_{opt}	Erro mínimo
Central	$O(h^2)$	$1,63 \times 10^{-6}$	$1,43 \times 10^{-13}$
Progressiva	$O(h)$	$9,12 \times 10^{-9}$	$5,19 \times 10^{-10}$
Razão (prog/central)		$\approx 179\times$ menor	$\approx 3600\times$ maior

A fórmula central é aproximadamente **3600 vezes mais precisa** no seu ponto ótimo do que a progressiva. Esse resultado é plenamente consistente com a teoria: por ter erro de truncamento $O(h^2)$, a central consegue usar passos maiores (cerca de 180 vezes maiores) antes que o arredondamento domine, e ainda assim atinge um erro residual muito menor (três ordens de grandeza inferior).

O mecanismo por trás dessa superioridade é o **cancelamento simétrico** dos termos de primeira ordem em h na fórmula central, que eleva a ordem de convergência e desloca o equilíbrio entre truncamento e arredondamento para um ponto muito mais favorável. Em aplicações práticas, isso torna a fórmula central amplamente preferível à progressiva sempre que os dois pontos laterais estão disponíveis.




Figura 2: Comparação do erro absoluto entre as fórmulas central e progressiva em função de h (escala log-log). A fórmula central atinge erro mínimo cerca de 3600 vezes menor que a progressiva, e seu h_{opt} é aproximadamente 180 vezes maior.

1.3 Diferenciação de tabela experimental

Questão 1.4 — Diferenciação de tabela experimental

Enunciado: A tabela abaixo registra a posição (em metros) de um veículo em função do tempo (em segundos), coletada por GPS com resolução de 0,1 m:

t (s)	0,0	0,5	1,0	1,5	2,0	2,5	3,0	3,5
x (m)	0,0	1,2	4,8	10,6	18,5	27,1	35,8	43,6

- Use `derivada_tabela` para estimar a velocidade $v(t) = \dot{x}(t)$ em cada instante.
- Use `d2f_central` (adaptada para tabela) para estimar a aceleração $a(t) = \ddot{x}(t)$ nos pontos interiores.
- O veículo freia em algum instante? Em qual ponto a aceleração muda de sinal?
- Sabendo que os dados têm erro de $\pm 0,1$ m, qual é a incerteza na velocidade estimada? (Dica: para a fórmula central, $\delta v \approx 2 \times 0,1 / (2h) = 0,2/h$. Calcule para $h = 0,5$ s.)
- Discuta: com dados experimentais ruidosos, faz sentido usar h muito pequeno? Por quê?

Resposta:**(a) Velocidade estimada $v(t) = \dot{x}(t)$:**

Aplicando a função `derivada_tabela` aos dados de posição do veículo, que utiliza fórmula progressiva de 2ª ordem na borda esquerda, fórmula central nos pontos interiores e regressiva de 2ª ordem na borda direita, obtivemos:

Tabela 8: Velocidade estimada em cada instante de tempo.

t (s)	x (m)	v (m/s)	Fórmula utilizada
0,0	0,0	0,0000	Progressiva 3 pts (borda esquerda)
0,5	1,2	4,8000	Central
1,0	4,8	9,4000	Central
1,5	10,6	13,7000	Central
2,0	18,5	16,5000	Central
2,5	27,1	17,3000	Central
3,0	35,8	16,5000	Central
3,5	43,6	14,7000	Regressiva 3 pts (borda direita)

A velocidade aumenta de forma consistente desde o repouso até atingir o valor máximo de 17,3 m/s em $t = 2,5$ s, e então começa a diminuir, indicando que o veículo desacelera na segunda metade do percurso.

(b) Aceleração estimada $a(t) = \ddot{x}(t)$ nos pontos interiores:

Aplicando a fórmula central para a segunda derivada, adaptada para a tabela com espaçamento uniforme $h = 0,5$ s, obtivemos:

Tabela 9: Aceleração estimada nos pontos interiores da tabela.

t (s)	a (m/s ²)	Interpretação
0,5	9,6000	Acelerando
1,0	8,8000	Acelerando
1,5	8,4000	Acelerando
2,0	2,8000	Acelerando (pouco)
2,5	0,4000	Aceleração quase nula
3,0	-3,6000	Freando

Os valores foram calculados pela fórmula:

$$a(t_i) = \frac{x_{i+1} - 2x_i + x_{i-1}}{h^2}, \quad i = 1, \dots, 6.$$

(c) Análise do sinal da aceleração — o veículo freia em algum instante?

A aceleração muda de sinal entre $t = 2,5$ s e $t = 3,0$ s:

- Para $t < 2,5$ s, a aceleração é positiva: o veículo está acelerando.

- Em $t = 2,5$ s, a aceleração é praticamente nula ($0,4 \text{ m/s}^2$), indicando que o veículo atinge sua velocidade máxima nesse instante.
- Para $t > 2,5$ s, a aceleração torna-se negativa: o veículo está **freando**.

O sinal da aceleração muda exatamente entre 2,5 s e 3,0 s, o que é coerente com o fato de que a velocidade atinge seu valor máximo em $t = 2,5$ s ($v = 17,3 \text{ m/s}$) e a partir daí passa a diminuir. A mudança de sinal ocorre, portanto, no intervalo (2,5; 3,0) segundos.

(d) Incerteza na velocidade estimada devido ao erro do GPS:

Com resolução do GPS de $\delta x = \pm 0,1 \text{ m}$ e passo $h = 0,5 \text{ s}$, a propagação de incerteza na fórmula central é:

$$\delta v \approx \frac{2 \delta x}{2h} = \frac{2 \times 0,1}{2 \times 0,5} = 0,20 \text{ m/s}.$$

Aplicando essa incerteza a cada estimativa de velocidade:

Tabela 10: Velocidades estimadas com seus respectivos intervalos de incerteza.

t (s)	v (m/s)	Intervalo de incerteza (m/s)
0,0	0,0000	$[-0,20; +0,20]$
0,5	4,8000	$[4,60; 5,00]$
1,0	9,4000	$[9,20; 9,60]$
1,5	13,7000	$[13,50; 13,90]$
2,0	16,5000	$[16,30; 16,70]$
2,5	17,3000	$[17,10; 17,50]$
3,0	16,5000	$[16,30; 16,70]$
3,5	14,7000	$[14,50; 14,90]$

A incerteza de $\pm 0,20 \text{ m/s}$ representa aproximadamente 1,2% da velocidade máxima ($17,3 \text{ m/s}$), o que é um nível aceitável para a resolução do instrumento utilizado.

(e) Por que não faz sentido usar h muito pequeno com dados ruidosos?

Para dados tabelados com ruído de medição δx , o erro total na derivada central é composto por duas parcelas com comportamentos opostos em relação a h :

$$\text{Erro total} \approx \underbrace{\frac{h^2}{6} |f'''(x)|}_{\text{truncamento: cai com } h} + \underbrace{\frac{2 \delta x}{2h}}_{\text{ruído: cresce com } 1/h}.$$

Ao contrário do caso analítico, onde $\varepsilon_m \approx 2,2 \times 10^{-16}$ é uma precisão minúscula, aqui $\delta x = 0,1 \text{ m}$ é uma incerteza *macroscópica* (da ordem de grandeza dos dados reais). Reduzir h amplifica o ruído de forma drástica:

Tabela 11: Propagação da incerteza para diferentes valores de h .

h (s)	δv (m/s)	Impacto relativo
0,50	0,20	$\approx 1,2\%$ de $v_{\text{máx}}$
0,10	1,00	$\approx 10\%$ de $v_{\text{máx}}$
0,01	10,00	Inutilizável (erro $\approx 58\%$)

Com dados experimentais, o **passo ótimo** é determinado pelo equilíbrio entre o erro de truncamento e a propagação do ruído de medição — *não* pela precisão de máquina. Para o GPS com resolução de 0,1 m, o passo $h = 0,5$ s já está próximo desse ponto ótimo. Diminuir h além desse valor não melhora a estimativa: apenas amplifica o ruído, tornando os resultados progressivamente menos confiáveis.

Em resumo: com dados experimentais ruidosos, **não faz sentido** usar h muito pequeno. A presença de ruído macroscópico torna a propagação de incertezas o fator dominante para h pequenos, de modo que o passo deve ser escolhido para equilibrar esse efeito com a precisão desejada. Este é um princípio fundamental da análise numérica aplicada a dados reais: a precisão final é limitada *primeiro* pela qualidade dos dados de entrada, e *depois* pelo método numérico utilizado.

1.4 Segunda derivada e aplicações

Questão 1.5 — Segunda derivada e aplicações

Enunciado: Para $f(x) = \ln x$ em $x_0 = 2,0$:

(a) O valor exato é $f''(2,0) = -1/4 = -0,2500$. Estime com `d2f_central` usando $h = 0,1$ (use $f(1,9) = \ln(1,9)$, $f(2,0) = \ln(2,0)$, $f(2,1) = \ln(2,1)$).

(b) Calcule o erro. A cota teórica é $|E| \leq \frac{h^2}{12}|f^{(4)}(\xi)|$. Para $f(x) = \ln x$, tem-se $f^{(4)}(x) = 6/x^4$. Com $\xi \in [1,9, 2,1]$: calcule a cota e compare com o erro real.

(c) Repita com $h = 0,05$ e $h = 0,01$. Verifique que o erro reduz por fator 4 a cada vez que h é reduzido à metade.

Resposta:

(a) Estimativa com $h = 0,1$:

Aplicando a fórmula de segunda derivada central em $x_0 = 2,0$ com $f(x) = \ln x$:

$$f''(2,0) \approx \frac{f(1,9) - 2f(2,0) + f(2,1)}{h^2}.$$

Os valores necessários são:

Tabela 12: Valores da função $\ln x$ nos pontos ao redor de $x_0 = 2,0$.

Ponto	Valor	Notação
1,9	0,64185389	$f(1,9)$
2,0	0,69314718	$f(2,0)$
2,1	0,74193734	$f(2,1)$

Substituindo na fórmula com $h = 0,1$:

$$f''(2,0) \approx \frac{0,64185389 - 2 \times 0,69314718 + 0,74193734}{0,01} = \frac{-0,00313022}{0,01} = -0,25031302.$$

Tabela 13: Resultado da estimativa da segunda derivada para $h = 0,1$.

Grandeza	Valor
Valor exato $f''(2,0) = -1/4$	-0,25000000
Valor aproximado	-0,25031302
Erro absoluto	$3,13 \times 10^{-4}$

A estimativa aproxima muito bem o valor exato, com erro da ordem de 10^{-4} , o que já é bastante satisfatório para um passo $h = 0,1$.

(b) Cota teórica do erro e comparação:

O erro da fórmula de segunda derivada central é limitado pela expressão:

$$|E| \leq \frac{h^2}{12} \max_{\xi \in [1,9; 2,1]} |f^{(4)}(\xi)|.$$

Para $f(x) = \ln x$, as derivadas sucessivas são:

$$f'(x) = \frac{1}{x}, \quad f''(x) = -\frac{1}{x^2}, \quad f'''(x) = \frac{2}{x^3}, \quad f^{(4)}(x) = -\frac{6}{x^4}.$$

Tomando o valor absoluto: $|f^{(4)}(x)| = 6/x^4$. Esta função é *decrecente* no intervalo $[1,9; 2,1]$, pois sua derivada é $-24/x^5 < 0$. Portanto, o máximo ocorre no extremo esquerdo $\xi = 1,9$:

$$\max_{\xi \in [1,9; 2,1]} |f^{(4)}(\xi)| = \frac{6}{(1,9)^4} = \frac{6}{13,0321} \approx 0,4604.$$

Substituindo $h = 0,1$ na cota:

$$|E| \leq \frac{(0,1)^2}{12} \times 0,4604 = \frac{0,01}{12} \times 0,4604 \approx 3,84 \times 10^{-4}.$$

Tabela 14: Comparação entre a cota teórica e o erro real para $h = 0,1$.

Grandeza	Valor
Cota teórica do erro	$3,84 \times 10^{-4}$
Erro real observado	$3,13 \times 10^{-4}$
Cota $\geq$ erro real?	Sim ($3,84 \times 10^{-4} > 3,13 \times 10^{-4}$)

A cota é válida e segura: o erro real observado é inferior ao limite superior teórico, confirmando que a fórmula da cota é, de fato, um limitante superior confiável para o erro. A diferença entre a cota e o erro real (cerca de $0,71 \times 10^{-4}$) decorre do fato de que a cota utiliza o máximo absoluto da quarta derivada no intervalo, enquanto o erro real depende do valor específico de ξ , que pode ser menor que o máximo.

(c) Convergência quadrática: verificação do fator 4:

Repetindo os cálculos para $h = 0,05$ e $h = 0,01$:

Tabela 15: Convergência da segunda derivada para diferentes valores de h .

h	$f(2-h)$	$f(2)$	$f(2+h)$	f''_{aprox}
Erro				
0,10	0,64185389	0,69314718	0,74193734	-0,25031302
$3,13 \times 10^{-4}$				
0,05	0,66782937	0,69314718	0,71783979	-0,25007816
$7,82 \times 10^{-5}$				
0,01	0,68813464	0,69314718	0,69813472	-0,25000313
$3,13 \times 10^{-6}$				

Tabela 16: Fatores de redução do erro ao reduzir h .

Redução de h	Fator r	Fator observado	Fator esperado
0,10 $\rightarrow$ 0,05	2	$\frac{3,13 \times 10^{-4}}{7,82 \times 10^{-5}} \approx 4,01$	4
0,05 $\rightarrow$ 0,01	5	$\frac{7,82 \times 10^{-5}}{3,13 \times 10^{-6}} \approx 24,98$	25

Os resultados confirmam com precisão o comportamento esperado para uma fórmula de ordem $O(h^2)$:

- Ao reduzir h por um fator r , o erro é reduzido por um fator r^2 (convergência quadrática).
- Para $r = 2$: $2^2 = 4$ — o erro foi reduzido por $\approx 4,01$ vezes.

- Para $r = 5$: $5^2 = 25$ — o erro foi reduzido por $\approx 24,98$ vezes.

Este experimento ilustra perfeitamente a **convergência quadrática** da fórmula central de segunda derivada: cada vez que h é reduzido pela metade, o erro cai por um fator de aproximadamente 4. Este comportamento é característico de métodos de diferenças finitas de ordem $O(h^2)$ e confirma que a estimativa melhora rapidamente com o refinamento da malha.

2 Newton-Cotes: Trapézios e Simpson

2.1 Verificação das fórmulas

Questão 2.1 — Verificação das fórmulas

Enunciado: Calcule $\int_0^1 x^2 dx = \frac{1}{3}$ com as três regras (Ponto Médio, Trapézios e Simpson) usando $n = 4$.

(a) Antes de calcular: qual método você espera que seja exato? Por quê? (Dica: pense no grau do polinômio e na precisão de cada regra.)

(b) Após calcular: seus resultados confirmam a expectativa? Mostre os valores numéricos.

(c) Repita para $\int_0^1 x^3 dx = \frac{1}{4}$. Agora Simpson ainda é exato? Por quê?

Resposta:

(a) Expectativa antes de calcular:

Cada regra de Newton-Cotes integra exatamente polinômios até um certo grau, determinado pelo grau do polinômio interpolador subjacente. A precisão de cada método está diretamente relacionada à ordem do erro de truncamento:

Tabela 17: Grau máximo de polinômios integrados exatamente por cada método.

Método	Integra exatamente até grau	Motivo
Ponto Médio	≤ 1	Erro proporcional a f''
Trapézios	≤ 1	Erro proporcional a f''
Simpson 1/3	≤ 3	Erro proporcional a $f^{(4)}$

Para a integral $\int_0^1 x^2 dx$, o integrando é um polinômio de grau 2. Portanto, espera-se que:

- **Simpson 1/3** seja *exato*, pois polinômios de grau ≤ 3 são integrados exatamente por esta regra ($f^{(4)} \equiv 0$).
- **Ponto Médio** e **Trapézios** apresentem *erros não nulos*, pois ambos têm precisão apenas até polinômios de grau 1.

(b) Resultados para $\int_0^1 x^2 dx = \frac{1}{3} \approx 0,333333$ (grau 2, $n = 4$):

Aplicando as três regras com $n = 4$ subintervalos ($h = 0,25$), obtivemos:

Tabela 18: Resultados da integração de $f(x) = x^2$ em $[0, 1]$ com $n = 4$.

Método	Resultado	Erro absoluto	Exato?
Ponto Médio	0,32812500	$5,21 \times 10^{-3}$	Não
Trapézios	0,34375000	$1,04 \times 10^{-2}$	Não
Simpson 1/3	0,33333333	$0,00 \times 10^0$	Sim

Os resultados confirmam plenamente a expectativa: a regra de Simpson 1/3 produz o valor exato, enquanto o Ponto Médio e os Trapézios apresentam erros não nulos. Observe ainda um padrão característico para funções convexas ($f'' > 0$): o **Ponto Médio subestima** o valor exato ($0,328125 < 0,333333$), enquanto os **Trapézios superestimam** ($0,343750 > 0,333333$). O valor exato fica sempre entre as duas aproximações: $PM < \text{exato} < TR$.

(c) **Resultados para** $\int_0^1 x^3 dx = \frac{1}{4} = 0,250000$ (**grau 3, $n = 4$**):

Repetindo o experimento para o polinômio de grau 3, obtivemos:

Tabela 19: Resultados da integração de $f(x) = x^3$ em $[0, 1]$ com $n = 4$.

Método	Resultado	Erro absoluto	Exato?
Ponto Médio	0,24218750	$7,81 \times 10^{-3}$	Não
Trapézios	0,26562500	$1,56 \times 10^{-2}$	Não
Simpson 1/3	0,25000000	$0,00 \times 10^0$	Sim

Simpson 1/3 continua sendo exato para $f(x) = x^3$, pois a regra de Simpson integra exatamente polinômios de grau até 3. A fórmula de erro de Simpson composto é:

$$E_{\text{Simpson}} = -\frac{b-a}{180} h^4 f^{(4)}(\xi),$$

para algum $\xi \in (a, b)$. Para $f(x) = x^3$, temos $f^{(4)}(x) = 0$ identicamente, de modo que o erro é exatamente nulo para qualquer n par.

Já o Ponto Médio e os Trapézios, cujos erros são proporcionais a $f''(x)$ (não nula para x^3), apresentam erros não nulos. Novamente observa-se o padrão de subestimativa do Ponto Médio e superestimativa dos Trapézios — comportamento consistente com a convexidade da função ($f''(x) = 6x > 0$ em $(0, 1)$).

Este experimento ilustra um princípio fundamental da quadratura numérica: a **ordem do método** determina sua capacidade de integrar exatamente polinômios de grau baixo, o que tem implicações diretas na precisão obtida para funções mais gerais. Quanto maior a ordem, mais suave pode ser a função para que o erro seja pequeno.

Questão 2.2 — Comparação de desempenho

Enunciado: Calcule $\int_1^2 \frac{1}{x} dx = \ln 2 \approx 0,693147$ com Trapézios e Simpson usando $n = 4, 8, 16$.

(a) Preencha a tabela comparativa:

n	Trapézios		Simpson 1/3	
	Resultado	Erro	Resultado	Erro
4				
8				
16				

(b) Ao dobrar n : por qual fator o erro dos Trapézios foi dividido? E o de Simpson? Isso é consistente com as ordens $O(n^{-2})$ e $O(n^{-4})$?

(c) Com $n = 4$, quantas vezes Simpson é mais preciso que Trapézios? Ambos usam 5 pontos de avaliação — o que torna Simpson melhor?

Resposta:

(a) Tabela comparativa:

Para $f(x) = 1/x$ em $[1, 2]$, com valor exato $\ln 2 \approx 0,69314718056$, os resultados obtidos foram:

Tabela 20: Resultados da integração de $f(x) = 1/x$ em $[1, 2]$ para diferentes valores de n .

n	Trapézios		Simpson 1/3	
	Resultado	Erro	Resultado	Erro
4	0,69702381	$3,88 \times 10^{-3}$	0,69325397	$1,07 \times 10^{-4}$
8	0,69412185	$9,75 \times 10^{-4}$	0,69315453	$7,35 \times 10^{-6}$
16	0,69339120	$2,44 \times 10^{-4}$	0,69314765	$4,72 \times 10^{-7}$

Observa-se que ambos os métodos convergem para o valor exato à medida que n aumenta, mas a regra de Simpson o faz de forma muito mais rápida: com $n = 16$, seu erro já é da ordem de 10^{-7} , enquanto os Trapézios ainda apresentam erro de 10^{-4} .

(b) Fatores de redução do erro ao dobrar n :

Para verificar as ordens de convergência, calculamos o fator pelo qual o erro é reduzido a cada duplicação de n :

Tabela 21: Fatores de redução do erro ao dobrar n .

Transição	Trapézios		Simpson 1/3	
	Fator observado	Esperado	Fator observado	Esperado
$n : 4 \rightarrow 8$	$\frac{3,88 \times 10^{-3}}{9,75 \times 10^{-4}} \approx 3,98$	4	$\frac{1,07 \times 10^{-4}}{7,35 \times 10^{-6}} \approx 14,53$	16
$n : 8 \rightarrow 16$	$\frac{9,75 \times 10^{-4}}{2,44 \times 10^{-4}} \approx 3,99$	4	$\frac{7,35 \times 10^{-6}}{4,72 \times 10^{-7}} \approx 15,56$	16

Os resultados são plenamente consistentes com as ordens teóricas:

- **Trapézios** ($O(n^{-2})$): ao dobrar n , o erro é reduzido por um fator de aproximadamente $2^2 = 4$. Os valores observados (3,98 e 3,99) confirmam essa expectativa com excelente precisão.
- **Simpson 1/3** ($O(n^{-4})$): ao dobrar n , o erro é reduzido por um fator de aproximadamente $2^4 = 16$. Os valores observados (14,53 e 15,56) são ligeiramente inferiores ao valor teórico para a primeira transição, pois com $n = 4$ os termos de ordem superior ainda contribuem significativamente para o erro. À medida que n cresce, o fator se aproxima de 16, como observado na transição $8 \rightarrow 16$.

Este comportamento é uma manifestação direta da fórmula de erro de cada método:

$$E_{\text{Trapézios}} = -\frac{b-a}{12} h^2 f''(\xi), \quad E_{\text{Simpson}} = -\frac{b-a}{180} h^4 f^{(4)}(\xi).$$




Figura 3: Convergência do erro em função de n (escala log-log). As inclinações -2 e -4 confirmam as ordens $O(n^{-2})$ e $O(n^{-4})$ para Trapézios e Simpson, respectivamente.

(c) Comparação com $n = 4$ (ambos usando 5 pontos de avaliação):

Com $n = 4$, ambos os métodos utilizam exatamente os mesmos 5 pontos de avaliação da função $f(x)$: $x = 1,00, 1,25, 1,50, 1,75, 2,00$. No entanto, a precisão obtida é drasticamente diferente:

Tabela 22: Comparação entre Trapézios e Simpson com $n = 4$ (5 pontos de avaliação).

Método	Erro ($n = 4$)	Precisão relativa
Trapézios	$3,88 \times 10^{-3}$	$1 \times$
Simpson 1/3	$1,07 \times 10^{-4}$	$\approx 36 \times$ mais preciso

Simpson 1/3 é aproximadamente **36 vezes mais preciso** que os Trapézios com o mesmo número de avaliações de função. O que torna isso possível?

A resposta está na **ordem do polinômio interpolador** utilizado por cada método:

- **Trapézios:** interpola $f(x)$ por uma **reta** (polinômio de grau 1) em cada subintervalo. O erro local é proporcional a $h^3 f''(\xi)$.
- **Simpson 1/3:** interpola $f(x)$ por uma **parábola** (polinômio de grau 2) em cada par de subintervalos. O erro local é proporcional a $h^5 f^{(4)}(\xi)$.

Embora ambos utilizem os mesmos 5 pontos, a forma como esses pontos são combinados é fundamentalmente diferente. Para $n = 4$, os pesos de cada método são:

Tabela 23: Comparação dos pesos utilizados por cada método para $n = 4$.

Método	$x = 1,00$	$x = 1,25$	$x = 1,50$	$x = 1,75$	$x = 2,00$
Trapézios	$h/2$	h	h	h	$h/2$
Simpson 1/3	$h/3$	$4h/3$	$2h/3$	$4h/3$	$h/3$

O **peso 4** atribuído aos pontos intermediários em Simpson (em vez do peso 2 dos Trapézios) permite que a parábola capture a curvatura da função com muito maior fidelidade, sem custo adicional de avaliações. É exatamente essa capacidade de aproveitar melhor a informação contida nos mesmos pontos que confere a Simpson sua superioridade — um exemplo clássico de como a **escolha do método** pode ser mais importante do que o **refinamento da malha** para a precisão final.

2.2 Análise de erro e determinação de n

Questão 2.3 — Determinação de n

Enunciado: Use as cotas de erro para determinar o número mínimo de subintervalos n que garante precisão de 10^{-5} nas integrais abaixo. Para cada uma, calcule n teoricamente e depois verifique computacionalmente qual é o menor n que realmente atinge o erro pedido.

- (a) $\int_0^\pi \sin x \, dx = 2$, pela Regra dos Trapézios. (Dica: $f''(x) = -\sin x$, $\max_{[0,\pi]} |f''| = 1$.)
- (b) $\int_0^1 e^x \, dx = e - 1$, pela Regra de Simpson 1/3. (Dica: $f^{(4)}(x) = e^x$, $\max_{[0,1]} |f^{(4)}| = e$.)

Houve discrepância entre n teórico e experimental? O que isso indica sobre a qualidade das cotas?

Resposta:

(a) $\int_0^\pi \sin x \, dx = 2$ **pela Regra dos Trapézios:**

A cota de erro dos Trapézios compostos é dada por:

$$|E| \leq \frac{(b-a)^3}{12n^2} \max_{[a,b]} |f''(x)|.$$

Para $f(x) = \sin x$, temos $f''(x) = -\sin x$ e, portanto, $\max_{[0,\pi]} |f''(x)| = 1$. A tolerância desejada é $\text{tol} = 10^{-5}$. Isolando n :

$$n \geq \sqrt{\frac{(b-a)^3 \cdot \max |f''|}{12 \cdot \text{tol}}} = \sqrt{\frac{\pi^3 \cdot 1}{12 \times 10^{-5}}} = \sqrt{\frac{31,006}{0,00012}} = \sqrt{258385,64} \approx 508,3.$$

Portanto, o menor inteiro que garante a precisão pela cota teórica é:

$$n_{\text{teórico}} = 509.$$

Para verificar experimentalmente, calculamos o erro real para diferentes valores de n :

Tabela 24: Erro real da Regra dos Trapézios para $\int_0^\pi \sin x \, dx$ em função de n .

n	Erro real	Atende tol?
400	$1,03 \times 10^{-5}$	Não
406	$9,98 \times 10^{-6}$	Sim
500	$6,58 \times 10^{-6}$	Sim
509	$6,35 \times 10^{-6}$	Sim

O menor n que realmente atinge a tolerância é:

$$n_{\text{experimental}} = 406.$$

Tabela 25: Comparação entre o n teórico e o experimental para os Trapézios.

Grandeza	Valor	Observação
n teórico (pela cota)	509	Cota conservadora
Cota garantida para $n = 509$	$9,97 \times 10^{-6}$	Abaixo da tolerância
Erro real com $n = 509$	$6,35 \times 10^{-6}$	Muito menor que a cota
n experimental (mínimo real)	406	Menor que o teórico
Erro real com $n = 406$	$9,98 \times 10^{-6}$	Atinge exatamente a tolerância

(b) $\int_0^1 e^x \, dx = e - 1$ **pela Regra de Simpson 1/3:**

A cota de erro de Simpson 1/3 composto é:

$$|E| \leq \frac{(b-a)^5}{180n^4} \max_{[a,b]} |f^{(4)}(x)|.$$

Para $f(x) = e^x$, temos $f^{(4)}(x) = e^x$ e, portanto, $\max_{[0,1]} |f^{(4)}(x)| = e \approx 2,71828$. A tolerância desejada é $\text{tol} = 10^{-5}$. Isolando n :

$$n \geq \left(\frac{(b-a)^5 \cdot \max |f^{(4)}|}{180 \cdot \text{tol}} \right)^{1/4} = \left(\frac{1 \cdot e}{180 \times 10^{-5}} \right)^{1/4} = \left(\frac{2,71828}{0,0018} \right)^{1/4} = (1510,16)^{1/4} \approx 6,23.$$

Como Simpson requer n par, arredondamos para o próximo inteiro par:

$$n_{\text{teórico}} = 8.$$

Verificando experimentalmente:

Tabela 26: Erro real da Regra de Simpson 1/3 para $\int_0^1 e^x dx$ em função de n .

n	Erro real	Atende tol?
4	$8,39 \times 10^{-5}$	Não
6	$7,34 \times 10^{-6}$	Sim
8	$2,33 \times 10^{-6}$	Sim

O menor n par que realmente atinge a tolerância é:

$$n_{\text{experimental}} = 6.$$

Tabela 27: Comparação entre o n teórico e o experimental para Simpson.

Grandeza	Valor	Observação
n teórico (pela cota)	8	Cota conservadora
Cota garantida para $n = 8$	$3,69 \times 10^{-6}$	Abaixo da tolerância
Erro real com $n = 8$	$2,33 \times 10^{-6}$	Muito menor que a cota
n experimental (mínimo real)	6	Menor que o teórico
Erro real com $n = 6$	$7,34 \times 10^{-6}$	Abaixo da tolerância

(c) Análise da discrepância entre n teórico e experimental:

Tabela 28: Resumo comparativo entre os n teóricos e experimentais.

Método	n teórico	n experimental	Fator de superestimativa
Trapézios	509	406	$\approx 1,3\times$
Simpson 1/3	8	6	$\approx 1,3\times$

Em ambos os casos, o n teórico é **superestimado** em relação ao n mínimo realmente necessário. Isso ocorre por duas razões fundamentais:

1. **Uso do máximo global das derivadas:** A cota emprega $\max |f''|$ ou $\max |f^{(4)}|$ sobre todo o intervalo, mas na prática a derivada pode ser significativamente menor na maior parte do domínio. Para $\sin x$, por exemplo, $|f'''(x)| = 1$ apenas em $x = \pi/2$ e cai a zero nas bordas — o valor médio efetivo é muito menor que o máximo usado na cota.
2. **A cota é uma desigualdade estrita:** Por construção, ela garante que o erro *nunca* supere o valor calculado. Isso a torna um limite superior seguro, mas frequentemente *folgado*. O erro real costuma ser consideravelmente menor que o limite superior, especialmente para funções suaves como $\sin x$ e e^x .

Implicação prática para o uso das cotas de erro:

As cotas de erro são **ferramentas de garantia** — elas fornecem um n que *com certeza* atenderá à tolerância exigida, mas à custa de um possível excesso de subintervalos. Em aplicações críticas (engenharia de segurança, simulações de sistemas físicos com tolerâncias rígidas), usa-se o n teórico para garantir a precisão. Em aplicações onde a eficiência computacional é prioritária (análise de grandes volumes de dados, simulações em tempo real), emprega-se **refinamento adaptativo**: começa-se com n pequeno e aumenta-se progressivamente até que o erro estimado (via comparação entre duas malhas sucessivas) caia abaixo da tolerância — obtendo-se, assim, o menor n realmente necessário para cada problema específico.

Questão 2.4 — Convergência de Trapézios e Simpson

Enunciado: Para $\int_0^\pi x^2 \sin x \, dx = \pi^2 - 4 \approx 5,870$, use Trapézios e Simpson com $n = 4, 8, 16, 32$.

(a) Plote o erro em escala log-log (eixo x : $\log n$, eixo y : $\log |E|$). As retas têm inclinações próximas de -2 e -4 ?

(b) Ao dobrar n : o erro de Trapézios divide por ≈ 4 ? O de Simpson divide por ≈ 16 ? Verifique numericamente.

(c) Com qual n Simpson supera Trapézios com $n = 100$ em termos de precisão? Quantas avaliações de f cada um usa nesse ponto?


Resposta:**(a) Gráfico log-log do erro:**

Figura 4: Erro absoluto em função de n (escala log-log) para a integral $\int_0^\pi x^2 \sin x \, dx$. As retas de referência com inclinações -2 e -4 confirmam as ordens de convergência dos Trapézios ($O(n^{-2})$) e de Simpson ($O(n^{-4})$).

O gráfico do erro absoluto em escala log-log apresenta duas retas bem definidas, com inclinações medidas numericamente:

Tabela 29: Inclinações observadas no gráfico log-log versus valores teóricos.

Método	Inclinação observada	Inclinação esperada	Ordem
Trapézios	-1,999	-2	$O(n^{-2})$
Simpson 1/3	-4,365 (para n pequenos)	-4	$O(n^{-4})$

As retas confirmam visualmente as ordens teóricas de convergência. O leve desvio da inclinação de Simpson para n pequenos (que tende a -4 à medida que n cresce) reflete a contribuição de termos de ordem superior que ainda são relevantes quando h não é suficientemente pequeno. À medida que n aumenta, a inclinação converge para -4 .

(b) Fatores de redução do erro ao dobrar n :

Os erros obtidos para cada valor de n foram:

Tabela 30: Erros absolutos para Trapézios e Simpson em função de n .

n	Erro Trapézios	Erro Simpson 1/3
4	$5,06 \times 10^{-1}$	$1,00 \times 10^{-2}$
8	$1,27 \times 10^{-1}$	$3,58 \times 10^{-4}$
16	$3,17 \times 10^{-2}$	$1,87 \times 10^{-5}$
32	$7,93 \times 10^{-3}$	$1,12 \times 10^{-6}$

A partir desses valores, calculamos os fatores de redução ao dobrar n :

Tabela 31: Fatores de redução do erro ao dobrar n .

Transição	Trapézios		Simpson 1/3	
	Fator observado	Esperado	Fator observado	Esperado
4 $\rightarrow$ 8	$\frac{5,06 \times 10^{-1}}{1,27 \times 10^{-1}} \approx 3,99$	4	$\frac{1,00 \times 10^{-2}}{3,58 \times 10^{-4}} \approx 28,03$	16
8 $\rightarrow$ 16	$\frac{1,27 \times 10^{-1}}{3,17 \times 10^{-2}} \approx 4,00$	4	$\frac{3,58 \times 10^{-4}}{1,87 \times 10^{-5}} \approx 19,07$	16
16 $\rightarrow$ 32	$\frac{3,17 \times 10^{-2}}{7,93 \times 10^{-3}} \approx 4,00$	4	$\frac{1,87 \times 10^{-5}}{1,12 \times 10^{-6}} \approx 16,78$	16

Os Trapézios apresentam fator de redução ≈ 4 de forma consistente desde $n = 4$, confirmando $O(n^{-2})$ com excelente precisão.

Para Simpson, o fator converge progressivamente para 16 à medida que n cresce. O valor elevado ($\approx 28\times$) para a transição $4 \rightarrow 8$ indica que, com n pequeno, termos de ordem superior ainda dominam o erro; a partir de $n = 16 \rightarrow 32$, o fator já está próximo do valor teórico ($16,78\times$), confirmando a ordem $O(n^{-4})$. Este comportamento

é característico de métodos de alta ordem: a convergência assintótica só se manifesta plenamente quando n é suficientemente grande.

(c) Comparação de eficiência: Simpson vs. Trapézios com $n = 100$:

Para determinar com qual n Simpson supera a precisão dos Trapézios com $n = 100$, calculamos:

Tabela 32: Comparação entre Trapézios e Simpson em termos de precisão e custo.

Método	n	Avaliações de f	Erro absoluto
Trapézios	100	101	$8,12 \times 10^{-4}$
Simpson 1/3	8	9	$3,58 \times 10^{-4}$
Simpson 1/3	6	7	$7,94 \times 10^{-4}$

O menor n par para o qual Simpson supera Trapézios com $n = 100$ é:

$$n_{\text{Simpson}} = 8.$$

Neste ponto:

- **Trapézios com $n = 100$:** utiliza $n + 1 = 101$ avaliações de f e atinge erro de $8,12 \times 10^{-4}$.
- **Simpson com $n = 8$:** utiliza $n + 1 = 9$ avaliações de f e atinge erro de $3,58 \times 10^{-4}$.

Simpson com apenas **9 avaliações** de f supera a precisão dos Trapézios com **101 avaliações** — uma redução de mais de $11\times$ no custo computacional para a mesma qualidade de resultado.

Esse resultado ilustra de forma concreta a superioridade assintótica de Simpson: como seu erro decai com n^{-4} enquanto o dos Trapézios decai com n^{-2} , a relação entre os n necessários para atingir um dado erro ε é:

$$\frac{n_{\text{SI}}}{n_{\text{TR}}} \approx \left(\frac{C_{\text{TR}}}{C_{\text{SI}}} \right)^{1/4} \ll 1.$$

Para aplicações que exigem alta precisão, essa diferença de ordem torna Simpson exponencialmente mais eficiente por avaliação de função. A única vantagem dos Trapézios permanece em cenários com dados tabelados de espaçamento irregular ou quando n é imposto externamente — situações em que Simpson pode não ser aplicável diretamente.

2.3 Integração de dados experimentais

Questão 2.5 — Integração de dados experimentais

Enunciado: A potência elétrica $P(t)$ (em watts) de um circuito experimental foi medida a cada 0,5 s:

t (s)	0,0	0,5	1,0	1,5	2,0	2,5	3,0	3,5	4,0	4,5
P (W)	0,0	12,4	22,8	30,1	34,2	35,0	32,8	27,5	20,3	12,1

A energia total dissipada é $E = \int_0^{4,5} P(t) dt$ (em joules).

(a) Use `trapezios_tabela` para estimar E .

(b) Use `simpson13_tabela` (verifique: $n = 9$ é ímpar! Como proceder?). (Sugestão: use Simpson nos primeiros 8 subintervalos e Trapézio no último, ou explique por que isso é válido.)

(c) A diferença entre os dois resultados dá uma ideia do erro. Qual estimativa você consideraria mais confiável? Por quê?

(d) Se a precisão exigida for $\pm 0,1$ J e os dados têm erro de $\pm 0,5$ W, a precisão é limitada pelo método numérico ou pela incerteza dos dados?

Resposta:

(a) Estimativa pela Regra dos Trapézios:

Aplicando a regra dos Trapézios para dados tabelados com espaçamento uniforme $h = 0,5$ s:

$$E_{\text{TR}} = h \left(\frac{P_0 + P_n}{2} + \sum_{i=1}^{n-1} P_i \right) = 0,5 \left(\frac{0,0 + 12,1}{2} + \sum_{i=1}^8 P_i \right).$$

Calculando a soma dos pontos interiores:

$$\sum_{i=1}^8 P_i = 12,4 + 22,8 + 30,1 + 34,2 + 35,0 + 32,8 + 27,5 + 20,3 = 215,1.$$

Substituindo:

$$E_{\text{TR}} = 0,5 \left(\frac{12,1}{2} + 215,1 \right) = 0,5(6,05 + 215,1) = 0,5 \times 221,15 = 110,5750 \text{ J}.$$

Portanto, a regra dos Trapézios fornece:

$$E_{\text{TR}} \approx 110,5750 \text{ J}.$$

(b) Estratégia para $n = 9$ (ímpar) — Simpson + Trapézio:

A regra de Simpson 1/3 composta exige que o número de subintervalos n seja *par*, pois a parábola é ajustada em cada par de subintervalos. Como os dados têm $n = 9$ subintervalos (10 pontos), a aplicação direta não é possível.

A estratégia adotada foi aplicar Simpson 1/3 nos primeiros 8 subintervalos ($t = 0$ a $t = 4,0$ s) e completar com a regra dos Trapézios no último subintervalo ($t = 4,0$ a $t = 4,5$ s). Esta abordagem é válida por dois motivos:

1. A regra dos Trapézios é consistente e fornece uma aproximação razoável para o último subintervalo, especialmente se a função não apresentar variações bruscas nessa região.
2. Esta é uma prática comum em integração numérica de dados tabelados: quando n é ímpar, utiliza-se o método de maior ordem na maior parte do intervalo e um método de ordem inferior no subintervalo restante.

Calculando:

- **Simpson 1/3 no intervalo** $[0, 4]$ (8 subintervalos, $h = 0,5$):

$$E_{\text{SI},[0,4]} = \frac{h}{3} \left(P_0 + P_8 + 4 \sum_{i \text{ ímpar}} P_i + 2 \sum_{i \text{ par}} P_i \right).$$

Com $P_0 = 0,0$, $P_8 = 20,3$:

$$\sum_{\text{ímpar}} P_i = P_1 + P_3 + P_5 + P_7 = 12,4 + 30,1 + 35,0 + 27,5 = 105,0,$$

$$\sum_{\text{par}} P_i = P_2 + P_4 + P_6 = 22,8 + 34,2 + 32,8 = 89,8.$$

$$E_{\text{SI},[0,4]} = \frac{0,5}{3} (0,0 + 20,3 + 4 \times 105,0 + 2 \times 89,8) = \frac{0,5}{3} \times 619,9 = 103,3167 \text{ J}.$$

- **Trapézios no subintervalo** $[4, 4,5]$:

$$E_{\text{TR},[4,4,5]} = \frac{h}{2} (P_8 + P_9) = \frac{0,5}{2} (20,3 + 12,1) = 0,25 \times 32,4 = 8,1000 \text{ J}.$$

Somando as duas contribuições:

$$E_{\text{misto}} = E_{\text{SI},[0,4]} + E_{\text{TR},[4,4,5]} = 103,3167 + 8,1000 = 111,4167 \text{ J}.$$

Portanto:

$$E_{\text{misto}} \approx 111,4167 \text{ J}.$$

(c) Comparação entre os métodos e confiabilidade:

Tabela 33: Comparação entre as estimativas de energia pelos diferentes métodos.

Método	Energia (J)
Trapézios puro	110,5750
Simpson + Trapézio	111,4167
Diferença $ \Delta E $	0,8417 J

A estimativa **mista (Simpson + Trapézio)** é a mais confiável pelos seguintes motivos:

1. **Maior ordem de precisão:** Simpson 1/3 tem erro local $O(h^4)$ nos 8 subintervalos onde é aplicado, enquanto os Trapézios têm erro $O(h^2)$ em todo o intervalo. A maior parte da integral é computada com a fórmula mais precisa.

2. **Consistência com a suavidade dos dados:** A curva de potência varia suavemente no intervalo, sem descontinuidades ou oscilações bruscas. Nesse cenário, Simpson é particularmente adequado.
3. **Estimativa prática do erro:** A diferença de 0,8417 J entre os dois métodos serve como uma estimativa prática do erro do Trapézio puro. Quando dois métodos de ordens diferentes concordam bem, o resultado de maior ordem é o mais confiável.

(d) Análise da limitação da precisão:

A precisão final é limitada pela **incerteza dos dados de medição** e não pelo método numérico. Para verificar isso, calculamos a propagação da incerteza:

- **Erro de medição:** $\delta P = \pm 0,5 \text{ W}$.
- **Propagação na regra dos Trapézios:**

$$\delta E_{\text{TR}} = \frac{h}{2} \cdot \left(\sum_{i=0}^n |c_i| \right) \cdot \delta P,$$

onde c_i são os coeficientes da regra dos Trapézios ($c_0 = c_n = 1$, $c_i = 2$ para $i = 1, \dots, n-1$). Para $n = 9$:

$$\sum |c_i| = 1 + 2 \times 8 + 1 = 18.$$

$$\delta E_{\text{TR}} = \frac{0,5}{2} \times 18 \times 0,5 = 2,25 \text{ J}.$$

- **Erro numérico:** estimado pela diferença entre os métodos:

$$|E_{\text{TR}} - E_{\text{misto}}| \approx 0,8417 \text{ J}.$$

Tabela 34: Comparação entre as fontes de erro.

Fonte de erro	Magnitude (J)
Incerteza dos dados (propagada)	$\pm 2,25$
Erro numérico (estimado)	$\approx 0,84$
Precisão exigida	$\pm 0,10$

A incerteza propagada dos dados ($\pm 2,25 \text{ J}$) é aproximadamente 2,7 vezes maior que o erro numérico (0,84 J) e *mais de 20 vezes maior* que a tolerância exigida ($\pm 0,10 \text{ J}$).

Conclusão sobre a limitação da precisão:

A precisão é **limitada pela incerteza dos dados experimentais** ($\pm 0,5$ W), não pelo método numérico. O erro numérico (0,84 J) é significativamente menor que a incerteza propagada (2,25 J).

Para atingir a precisão exigida de $\pm 0,1$ J, seria necessário um instrumento de medição com resolução $\delta P \leq 0,022$ W — cerca de 23 vezes melhor que o instrumento utilizado. Nenhum refinamento do método de integração (aumentar n , usar Simpson puro, etc.) poderia superar essa limitação, pois o erro de medição é inerente aos dados de entrada.

Este resultado ilustra um princípio fundamental da análise numérica aplicada a dados experimentais: **a precisão final é limitada pela qualidade dos dados de entrada, não pelo método computacional utilizado para processá-los.**

3 Quadratura Gaussiana e Comparação de Métodos

3.1 Eficiência da Quadratura Gaussiana

Questão 3.1 — Eficiência da Quadratura Gaussiana

Enunciado: Para $\int_1^2 \frac{1}{x} dx = \ln 2 \approx 0,693147$, use `tabela_comparativa` com:

- Newton-Cotes: $n = 2, 4, 8, 16, 32$;
- Gauss-Legendre: $n = 2, 3, 4, 5, 6$.

(a) Gauss-Legendre com $n = 2$ (2 avaliações de f) é mais preciso que Simpson com $n = 4$ (5 avaliações)? Explique.

(b) Com quantos pontos de Gauss-Legendre você consegue superar Simpson com $n = 32$ (33 avaliações)?

(c) Por que Gauss-Legendre converge mais rápido? (Dica: pense no grau máximo do polinômio que cada método integra exatamente.)

Resposta:

Tabela comparativa completa:

Tabela 35: Comparação Newton-Cotes vs. Gauss-Legendre para $\int_1^2 1/x dx = \ln 2$.

Método	n	Resultado	Erro
Trapézios	2	0,70833333	$1,52 \times 10^{-2}$
Trapézios	4	0,69702381	$3,88 \times 10^{-3}$
Trapézios	8	0,69412185	$9,75 \times 10^{-4}$
Trapézios	16	0,69339120	$2,44 \times 10^{-4}$
Trapézios	32	0,69320821	$6,10 \times 10^{-5}$
Simpson 1/3	2	0,69444444	$1,30 \times 10^{-3}$
Simpson 1/3	4	0,69325397	$1,07 \times 10^{-4}$
Simpson 1/3	8	0,69315453	$7,35 \times 10^{-6}$
Simpson 1/3	16	0,69314765	$4,72 \times 10^{-7}$
Simpson 1/3	32	0,69314721	$2,97 \times 10^{-8}$
Gauss-Legendre	2	0,69230769	$8,39 \times 10^{-4}$
Gauss-Legendre	3	0,69312169	$2,55 \times 10^{-5}$
Gauss-Legendre	4	0,69314642	$7,63 \times 10^{-7}$
Gauss-Legendre	5	0,69314716	$2,27 \times 10^{-8}$
Gauss-Legendre	6	0,69314718	$6,73 \times 10^{-10}$

(a) Gauss-Legendre $n = 2$ (2 avaliações) vs. Simpson $n = 4$ (5 avaliações):

Tabela 36: Comparação direta entre GL $n = 2$ e Simpson $n = 4$.

Método	Avaliações	Resultado	Erro
Gauss-Legendre $n = 2$	2	0,69230769	$8,39 \times 10^{-4}$
Simpson $n = 4$	5	0,69325397	$1,07 \times 10^{-4}$

Gauss-Legendre com apenas 2 avaliações de f é, na verdade, **menos** preciso que Simpson com 5 avaliações ($8,39 \times 10^{-4}$ contra $1,07 \times 10^{-4}$). À primeira vista isso parece contradizer a superioridade de GL, mas a explicação está em *qual* Simpson está sendo comparado:

GL com $n = 2$ é exato até grau $2n - 1 = 3$ — o mesmo grau de exatidão de um **Simpson simples de 3 pontos** (um único painel). Porém, o Simpson usado aqui não é simples: é o **Simpson composto** com $n = 4$, ou seja, 2 painéis com $h = 0,25$ cada. Cada painel do Simpson composto já é exato até grau 3 *localmente*, de modo que refinar h reduz o erro adicionalmente — algo que GL $n = 2$ não faz, pois aplica um único ajuste polinomial de grau 3 sobre *todo* o intervalo $[1, 2]$, sem qualquer refinamento local. Por isso, mesmo usando menos avaliações "no papel", GL $n = 2$ perde para o Simpson composto com h menor.

(b) Menor n de Gauss-Legendre que supera Simpson $n = 32$ (33 avaliações):

Tabela 37: Menor Gauss-Legendre que supera Simpson $n = 32$.

Método	n	Avaliações	Erro
Simpson 1/3	32	33	$2,97 \times 10^{-8}$
Gauss-Legendre	5	5	$2,27 \times 10^{-8}$

Com apenas $n = 5$ pontos (5 avaliações de f), Gauss-Legendre já supera a precisão do Simpson com $n = 32$ (33 avaliações) — uma redução de custo de mais de $6\times$ para atingir precisão igual ou melhor.

(c) Por que Gauss-Legendre converge mais rápido?

Newton-Cotes com n subintervalos usa $n + 1$ nós fixos e igualmente espaçados; Simpson (grau 2 por par de subintervalos) é exato até grau polinomial 3 independentemente de n , e Trapézios até grau 1.

Gauss-Legendre com n pontos tem $2n$ graus de liberdade (n posições de nós + n pesos), otimizados para maximizar o grau de exatidão: é exato para todo polinômio de grau $\leq 2n - 1$. Ou seja, GL "compra" exatidão polinomial adicional ao permitir que os nós não sejam igualmente espaçados — eles se concentram como as raízes dos polinômios de Legendre, dando mais peso às regiões relevantes para a integração. Por isso, para funções suaves, GL converge muito mais rápido por avaliação de função do que qualquer regra de Newton-Cotes de ordem fixa.

Questão 3.2 — Função sem primitiva elementar

Enunciado: A função $f(x) = e^{-x^2}$ não tem primitiva elementar. Para estimar $\int_0^1 e^{-x^2} dx \approx 0,746824$ (referência: `scipy.special.erf(1) * np.sqrt(np.pi)/2`):

(a) Aplique Trapézios, Simpson e Gauss-Legendre com $n = 2, 4, 8, 16, 32$ (apenas os valores de n aplicáveis).

(b) Plote o erro de cada método vs. número de avaliações de f em escala log-log. Qual método tem a melhor curva “precisão por custo”?

(c) Para obter erro $< 10^{-8}$: qual método precisa de menos avaliações de f ? Estime quantas.

(d) Por que o gráfico de Gauss-Legendre não é uma reta no plano log-log (diferente de Trapézios e Simpson)?

Resposta:

(a) Trapézios, Simpson e Gauss-Legendre para cada n :

Tabela 38: Comparação dos três métodos para $\int_0^1 e^{-x^2} dx \approx 0,746824$.

n	Trapézios	Erro TR	Simpson	Erro SI	Gauss-Leg. (Erro GL)
2	0,73137025	$1,55 \times 10^{-2}$	0,74718043	$3,56 \times 10^{-4}$	0,74659469 ($2,29 \times 10^{-4}$)
4	0,74298410	$3,84 \times 10^{-3}$	0,74685538	$3,12 \times 10^{-5}$	0,74682447 ($3,35 \times 10^{-7}$)
8	0,74586561	$9,59 \times 10^{-4}$	0,74682612	$1,99 \times 10^{-6}$	0,74682413 ($6,77 \times 10^{-15}$)
16	0,74658460	$2,40 \times 10^{-4}$	0,74682426	$1,25 \times 10^{-7}$	0,74682413 ($1,11 \times 10^{-16}$)
32	0,74676425	$5,99 \times 10^{-5}$	0,74682414	$7,79 \times 10^{-9}$	0,74682413 ($0,00 \times 10^0$)

A partir de $n = 8$, o erro de Gauss-Legendre já está no nível da precisão de máquina ($\varepsilon_m \approx 2,2 \times 10^{-16}$), de modo que os valores " $0,00 \times 10^0$ " para $n \geq 32$ refletem esse limite, não um erro matematicamente nulo.

(b) Precisão por custo (erro vs. avaliações de f):




Figura 5: Erro absoluto vs. número de avaliações de f , em escala log-log, para os três métodos aplicados a $\int_0^1 e^{-x^2} dx$.

Gauss-Legendre apresenta a melhor curva precisão-por-custo: para o mesmo número de avaliações de f , seu erro é ordens de grandeza menor que o de Trapezios e Simpson.

(c) Menor número de avaliações para erro $< 10^{-8}$:

Tabela 39: Menor número de avaliações de f para atingir erro $< 10^{-8}$.

Método	n	Avaliações	Erro
Trapezios	2477	2478	$9,99 \times 10^{-9}$
Simpson 1/3	32	33	$7,79 \times 10^{-9}$
Gauss-Legendre	5	5	$6,05 \times 10^{-9}$

Gauss-Legendre atinge erro $< 10^{-8}$ com apenas 5 avaliações de f — muito menos que Simpson (33) e Trapezios (2478).

(d) Por que o gráfico de Gauss-Legendre não é uma reta em log-log?

Trapezios e Simpson têm erro que decai como potência de n ($O(n^{-2})$ e $O(n^{-4})$, respectivamente), o que produz uma reta em escala log-log: $\log |E| = \log(C) - p \log(n)$, com inclinação constante $-p$.

Gauss-Legendre, para funções analíticas (como e^{-x^2} , que é inteira), converge geometricamente/exponencialmente: o erro decai como $O(\rho^{-n})$ para algum $\rho > 1$. Nesse caso $\log |E|$ é linear em n (não em $\log n$), e portanto a curva em escala log-log é côncava — cai muito mais rápido que qualquer lei de potência, até que o erro atinja o nível de arredondamento de máquina.

3.2 Limitação dos nós de Chebyshev

Questão 3.3 — Limitação dos nós de Chebyshev

Enunciado: A Quadratura Gaussiana é ótima para funções analíticas suaves. Mas o que acontece com funções que apresentam comportamento irregular?

Para $f(x) = |x - 0,5|$ em $[0, 1]$ (valor exato = 0,25):

- Calcule o erro de Trapézios, Simpson e Gauss-Legendre com $n = 2, 4, 8, 16$.
- Qual método converge mais rápido para esta função? Isso contradiz os resultados da questão anterior?
- Explique o comportamento de Gauss-Legendre: por que a taxa de convergência cai para funções não-suaves?
- O que esse experimento nos ensina sobre a escolha do método em situações práticas?

Resposta:

(a) Erro de cada método:

Tabela 40: Erro de Trapézios, Simpson e Gauss-Legendre para $\int_0^1 |x - 0,5| dx = 0,25$.

n	Erro Trapézios	Erro Simpson	Erro Gauss-Leg.
2	$0,00 \times 10^0$	$8,33 \times 10^{-2}$	$3,87 \times 10^{-2}$
4	$0,00 \times 10^0$	$0,00 \times 10^0$	$1,06 \times 10^{-2}$
8	$0,00 \times 10^0$	$0,00 \times 10^0$	$2,88 \times 10^{-3}$
16	$0,00 \times 10^0$	$0,00 \times 10^0$	$7,58 \times 10^{-4}$

(b) Qual método converge mais rápido? Isso contradiz Q3.1/Q3.2?

Com $n = 16$, o menor erro é o de Trapézios ($0,00 \times 10^0$) — na verdade, Trapézios é **exato** para *qualquer* n par testado, não apenas o mais rápido a convergir. Simpson também é exato a partir de $n = 4$. Gauss-Legendre, ao contrário, nunca atinge erro nulo neste experimento e converge de forma muito mais lenta.

Tabela 41: Erro de cada método em $n = 16$.

Método	Erro ($n = 16$)
Trapézios	$0,00 \times 10^0$
Simpson 1/3	$0,00 \times 10^0$
Gauss-Legendre	$7,58 \times 10^{-4}$

Isso **contradiz** a tendência observada em Q3.1 e Q3.2, onde Gauss-Legendre era claramente superior. Aqui, para uma função com derivada descontínua em $x = 0,5$, a vantagem de GL desaparece (e se inverte) porque sua convergência espectral depende de suavidade (analiticidade) da função — o que não se verifica em $|x - 0,5|$, que é contínua, mas não diferenciável nesse ponto.

(c) Por que a taxa de convergência de Gauss-Legendre cai?

A convergência exponencial de Gauss-Legendre depende de $f(x)$ ser analítica (ou suave o suficiente) em uma região do plano complexo ao redor do intervalo de integração. A

função $|x - 0,5|$ tem uma **quina** (derivada descontínua) em $x = 0,5$: é contínua, mas não diferenciável ali, e portanto não é analítica.

Os nós de Gauss-Legendre não coincidem, em geral, com o ponto de quina — diferente de **Trapézios**, que é exato para *qualquer* n par neste problema simétrico, pois cada nó de Trapézios cai exatamente sobre $x = 0,5$, ponto onde a própria função (linear por partes) não tem erro de interpolação linear. Já o **Simpson** só zera o erro quando n é *múltiplo de 4*, não simplesmente par: com $n = 2$, $x = 0,5$ é o nó central de um único painel, mas o ajuste quadrático desse painel ainda "sente" a quina e erra ($8,33 \times 10^{-2}$); já com $n = 4, 8, 16$, $x = 0,5$ cai exatamente sobre uma *fronteira entre painéis*, isolando a quina fora de qualquer ajuste quadrático — daí o erro nulo. Gauss-Legendre, por sua vez, "vê" a função não-suave em qualquer n (seus nós nunca coincidem com $x = 0,5$), e sua convergência degrada para uma taxa algébrica (tipicamente $O(n^{-2})$ a $O(n^{-3})$), perdendo a vantagem espectral que tinha para e^{-x^2} .

(d) O que este experimento ensina sobre a escolha do método?

A superioridade de Gauss-Legendre não é universal — ela depende da regularidade (suavidade/analiticidade) do integrando. Para funções suaves e analíticas (Q3.1, Q3.2), GL é imbatível em eficiência (erro por avaliação de f). Para funções com quinas, descontinuidades ou singularidades, seu desempenho se aproxima — ou pode até ficar atrás — do de Newton-Cotes.

Implicação prática:

Antes de escolher Gauss-Legendre por sua alta ordem teórica, é preciso verificar a suavidade do integrando. Se houver pontos não-suaves conhecidos, uma estratégia melhor é dividir o intervalo nesses pontos e aplicar GL (ou Simpson) separadamente em cada subintervalo suave — restaurando a convergência rápida em cada trecho.

4 Análise Comparativa Global

4.1 Tabela de síntese

Questão 4.1 — Tabela de síntese

Enunciado: Com base nos experimentos das seções anteriores, preencha a tabela de síntese abaixo.

Tabela 42: Tabela de síntese: métodos numéricos de diferenciação e integração.

Aspecto	Trapézios	Simpson 1/3	Gauss-Legendre	Dif. Central
Erro global	$O(h^2) \approx O(n^{-2})$	$O(h^4) \approx O(n^{-4})$	$O(\rho^{-n})$ (exponencial p/ f analítica)	$O(h^2)$
Avals. de f (geral)	$n + 1$	$n + 1$	n (nós ótimos)	2 por ponto (borda: 3)
Exato para grau	1 (retas)	3 (cúbicas)	$2n - 1$	2 (parábolas)
Requer n especial?	Não	Sim — n par	Não (qualquer $n \geq 1$)	Não
Funciona com tabela?	Sim — <code>trapezios_tabela</code>	Sim — <code>simpson13_tabela</code>	Não (exige $f(x)$ em nós não-equiespaçados)	Sim — <code>derivada_tabela</code>
Melhor cenário	Dados tabelados/ruidosos, integrando qualquer forma	Funções suaves, dados tabelados com n par	Funções analíticas suaves, poucas avaliações de f	Funções suaves, derivada de dados experimentais
Pior cenário	Funções muito suaves (convergência lenta)	Integrando não-suave (perde $O(h^4)$, Q2.4/Q3.3)	Integrando com quinas/descontinuidades (Q3.3)	Dados muito ruidosos com h pequeno (Q1.4e)

Resposta:

Leitura da síntese:

Não existe um método "melhor" em absoluto — cada um domina em um regime diferente:

- **Trapézios** é o mais robusto: funciona com qualquer n , qualquer dado tabelado, e degrada suavemente com ruído. Em troca, é o mais lento a convergir ($O(n^{-2})$).
- **Simpson 1/3** troca simplicidade por uma ordem a mais ($O(n^{-4})$) ao custo de exigir n par e de assumir suavidade local (ajuste parabólico por painel).
- **Gauss-Legendre** é imbatível em avaliações de f para integrandos analíticos suaves (Q3.1, Q3.2), mas não pode ser aplicado diretamente a dados tabelados e

perde sua vantagem em funções não-suaves (Q3.3).

- **Diferenças finitas centrais** seguem a mesma lógica de Trapézios/Simpson ($O(h^2)$) por cancelamento de termos ímpares na expansão de Taylor — a mesma simetria discutida em Q1.1c), com exatidão até grau 2 (parábolas), análoga ao grau 1 de Trapézios e ao grau 3 de Simpson. A diferenciação, porém, tem um problema adicional exclusivo dela: o conflito truncamento $\times$ arredondamento (Q1.3), que não existe da mesma forma na integração, pois a soma de vários $f(x_i)$ não amplifica o erro de arredondamento como a subtração de valores próximos amplifica na derivação.

Nota sobre as inclinações medidas em Q2.4: a tabela indica $O(n^{-2})$ para Trapézios e $O(n^{-4})$ para Simpson como ordens teóricas. Experimentalmente (Q2.4a), a inclinação log-log ajustada por regressão linear foi $-1,999$ para Trapézios (praticamente exata) e $-4,365$ para Simpson — mais negativa que o -4 teórico. Isso não é uma inconsistência: com $n = 4, 8, 16, 32$ (poucos pontos, ainda no regime pré-assintótico), os fatores de redução do erro de Simpson ao dobrar n foram $28,0\times$, $19,1\times$ e $16,8\times$ (Q2.4b) — convergindo progressivamente para o valor teórico $16\times = 2^4$. A inclinação ajustada fica, portanto, "puxada" pelos primeiros pontos, onde a convergência ainda é mais rápida que $O(n^{-4})$ por efeito de termos de ordem superior; para n maiores, a inclinação se aproximaria de -4 .

4.2 Tomada de decisão em cenários reais

Questão 4.2 — Tomada de decisão em cenários reais

Enunciado: Três estudantes propõem abordagens para calcular $\int_0^{100} f(t) dt$, onde $f(t)$ é a tensão de um sinal elétrico amostrado a cada 0,5 s (total de 201 pontos).

- **Estudante A:** Trapézios com todos os 201 pontos.
 - **Estudante B:** Simpson 1/3 com todos os 200 subintervalos (par).
 - **Estudante C:** Gauss-Legendre com $n = 5$ no intervalo todo.
- (a) Qual proposta é viável? Qual tem um problema conceitual? Explique.
 (b) Qual você recomenda para dados experimentais? Justifique quantitativamente.
 (c) Se o sinal tivesse descontinuidades (chaveamento elétrico), sua recomendação mudaria?

Resposta:

Cenário: sinal elétrico com 201 pontos amostrados a cada 0,5 s, em $[0, 100]$ s $\rightarrow n = 200$ subintervalos, $h = 0,5$ s.

(a) Viabilidade de cada proposta:

- **Estudante A — Trapézios com os 201 pontos: Viável.** trapezios_tabela (ou trapezios com $n = 200$) usa exatamente os pontos disponíveis, sem exigir avaliações de f fora da amostragem. Não há restrição sobre n .
- **Estudante B — Simpson 1/3 com os 200 subintervalos: Viável.** $n = 200$

é par, condição exigida por `simpson13/simpson13_tabela`. Também usa todos os pontos disponíveis, sem nenhuma avaliação extra de f .

- **Estudante C — Gauss-Legendre com $n = 5$ no intervalo todo: Tem problema conceitual.** `gauss_legendre(f, a, b, n)` precisa avaliar $f(x)$ nos nós de Gauss-Legendre — raízes de um polinômio de Legendre transformadas para $[a, b]$ — que, em geral, *não* coincidem com os instantes $t = 0, 0,5, 1, 0, \dots$ amostrados. Como o sinal só é conhecido nesses 201 pontos tabelados (não existe expressão fechada $f(t)$ para avaliar em qualquer t), o Estudante C não tem como calcular f nos nós de Gauss sem antes interpolar os dados — o que introduziria uma fonte de erro adicional não contemplada na proposta.

(b) Recomendação quantitativa para dados experimentais:

Com $h = 0,5$ s fixo pela taxa de amostragem (não pode ser refinado):

$$h^2 = 0,2500, \quad h^4 = 0,0625.$$

Usando as cotas de erro como referência estrutural (com $f''_{\max} = f_{\max}^{(4)} = 1$, já que as derivadas reais do sinal são desconhecidas):

$$\text{Cota Trapézios} = \frac{(b-a)^3}{12n^2} = 2,0833 \times 10^0, \quad \text{Cota Simpson} = \frac{(b-a)^5}{180n^4} = 3,4722 \times 10^{-2}.$$

$$\frac{\text{Cota Trapézios}}{\text{Cota Simpson}} = 60,0 \times .$$

Recomendo Simpson 1/3 (Estudante B):

- Usa todos os 201 pontos disponíveis, exatamente como Trapézios (nenhum dado é descartado e nenhuma avaliação extra é feita).
- Para o mesmo $h = 0,5$ s, sua cota de erro escala com h^4 em vez de h^2 , de modo que — mesmo sem conhecer $f''/f^{(4)}$ do sinal real — a razão estrutural entre as cotas já favorece Simpson por um fator de ordem $60 \times$ (Q2.2 e Q2.4 confirmam esse comportamento empiricamente para outras funções suaves).
- Gauss-Legendre, apesar de mais eficiente por avaliação de f para integrandos analíticos (Q3.1), não é aplicável aqui sem interpolação — o que o exclui de consideração para dados puramente tabelados como este.

(c) Se o sinal tivesse descontinuidades (chaveamento elétrico)?

Sim, a recomendação mudaria. Simpson 1/3 ajusta uma parábola a cada par de subintervalos (Q2.4, Q3.3); perto de uma descontinuidade esse ajuste é inválido — a parábola tenta suavizar um salto, gerando oscilações locais de *overshoot/undershoot* típicas de interpolação polinomial próxima a uma descontinuidade, que podem até superar o erro de Trapézios, cancelando a vantagem teórica de $O(h^4)$.

Nessa situação, a estratégia mais robusta é:

1. Localizar os instantes de chaveamento (onde $f(t)$ salta);
2. Dividir o intervalo de integração exatamente nesses pontos, tratando cada trecho suave separadamente;

3. Aplicar Simpson (ou Trapézios) dentro de cada trecho suave, e Trapézios especificamente nos subintervalos que contêm a descontinuidade (mesma lógica usada em Q2.5b para n ímpar).

Esse comportamento é consistente com o observado em Q3.3 para Gauss-Legendre: métodos de alta ordem (Simpson, GL) dependem de suavidade local para entregar sua taxa de convergência teórica; na presença de quinas ou saltos, a robustez de Trapézios (ou de uma versão segmentada dos métodos de ordem maior) volta a ser a escolha mais segura.

5 Projeto Integrador: Cálculo Variacional e Física

5.1 Comprimento de curva

Questão 5.1 — Comprimento de curva

Enunciado: O comprimento de arco de $y = f(x)$ em $[a, b]$ é:

$$L = \int_a^b \sqrt{1 + [f'(x)]^2} dx.$$

Para a parábola $f(x) = x^2$ em $[0, 2]$, o comprimento exato é $L = \sqrt{5} + \frac{1}{2} \ln(2 + \sqrt{5}) \approx 4,6468$.

(a) Usando derivação analítica ($f'(x) = 2x$), calcule L por Simpson 1/3 com $n = 10$. Qual é o erro?

(b) Agora, usando apenas os valores de f nos pontos da malha (sem a fórmula de f'), estime $f'(x_k)$ pela fórmula central e use esses valores para calcular L . Compare com o resultado anterior.

(c) O erro do passo (b) é maior que o do (a)? A diferenciação numérica introduz erro adicional?

(d) Repita com $n = 20$ e $n = 40$. Plote o erro vs. n . Qual é a ordem de convergência observada?

Resposta:

Valor exato de referência:

Integrando $L = \int_0^2 \sqrt{1 + 4x^2} dx$ analiticamente (substituição $u = 2x$ na antiderivada de $\sqrt{1 + u^2}$):

$$L = \sqrt{17} + \frac{1}{4} \ln(4 + \sqrt{17}) \approx 4,646784.$$

Esse valor confirma a aproximação $\approx 4,6468$ citada no enunciado e será usado como referência (L_{exato}) em todas as comparações a seguir.

(a) Comprimento com Simpson 1/3 ($n = 10$), derivada analítica $f'(x) = 2x$:

Usando o integrando $\sqrt{1 + [2x]^2}$ diretamente em `simpson13` com $n = 10$ subintervalos ($h = 0,2$):

Tabela 43: Comprimento de arco por Simpson 1/3 usando $f'(x) = 2x$ analítico.

Grandeza	Valor
L_{exato}	4,646784
$L_{\text{analítico}}$ (Simpson, $n = 10$)	4,64679076
Erro absoluto	$7,00 \times 10^{-6}$

(b) Comprimento usando $f'(x_k)$ estimado por `derivada_tabela`:

Construindo a malha $x_k = 0,0, 0,2, \dots, 2,0$ ($n = 10$), calculamos $f(x_k) = x_k^2$ e aplicamos `derivada_tabela` para estimar $f'(x_k)$ sem usar a fórmula analítica $2x$:

Tabela 44: Comparação entre a derivada analítica ($2x$) e a estimada por `derivada_tabela`.

x_k	$f(x_k)$	$f'(x_k)$ analítico	$f'(x_k)$ numérico	Fórmula
0,0	0,0000	0,0000	0,0000	Prog. 3 pts (borda)
0,2	0,0400	0,4000	0,4000	Central
0,4	0,1600	0,8000	0,8000	Central
0,6	0,3600	1,2000	1,2000	Central
0,8	0,6400	1,6000	1,6000	Central
1,0	1,0000	2,0000	2,0000	Central
1,2	1,4400	2,4000	2,4000	Central
1,4	1,9600	2,8000	2,8000	Central
1,6	2,5600	3,2000	3,2000	Central
1,8	3,2400	3,6000	3,6000	Central
2,0	4,0000	4,0000	4,0000	Retro. 3 pts (borda)

Usando $\sqrt{1 + f'(x_k)^2}$ (com f' numérico) em `simpson13_tabela`:

$$L_{\text{numérico}} = 4,64679076, \quad \text{Erro} = 7,00 \times 10^{-6}.$$

(c) O erro de (b) é maior que o de (a)?

Tabela 45: Comparação entre (a) derivada analítica e (b) derivada numérica.

Grandeza	Valor
Erro com f' analítica	$7,00 \times 10^{-6}$
Erro com f' numérica	$7,00 \times 10^{-6}$
Diferença $ L_{\text{num}} - L_{\text{an}} $	≈ 0 (nível de arredondamento, $< 10^{-13}$)

Não, o erro do passo (b) *não* é maior que o de (a) — os dois são praticamente idênticos. Isso ocorre porque $f(x) = x^2$ é um polinômio de grau 2: tanto a fórmula central quanto as fórmulas de 3 pontos usadas nas bordas por `derivada_tabela` são **exatas** para $f' = 2x$ (o termo de erro dessas fórmulas depende de f''' ou derivadas superiores, que são identicamente nulas para uma parábola). Assim, a diferenciação numérica **não introduz erro adicional** neste caso além do arredondamento de máquina — o gargalo de precisão observado é inteiramente devido à integração por Simpson 1/3, não à derivação.

(d) **Convergência com $n = 10, 20, 40, 80$:**

Para robustecer a análise de convergência, estendemos o experimento até $n = 80$:

Tabela 46: Erros de L (derivada analítica vs. numérica) para diferentes n .

n	Erro (f' analítica)	Erro (f' numérica)
10	$7,00 \times 10^{-6}$	$7,00 \times 10^{-6}$
20	$4,35 \times 10^{-8}$	$4,35 \times 10^{-8}$
40	$2,79 \times 10^{-9}$	$2,79 \times 10^{-9}$
80	$1,75 \times 10^{-10}$	$1,75 \times 10^{-10}$

Tabela 47: Fatores de redução de erro ao dobrar n .

Transição	Fator observado	Esperado $O(h^4)$
10 $\rightarrow$ 20	160,96 $\times$	16 $\times$
20 $\rightarrow$ 40	15,57 $\times$	16 $\times$
40 $\rightarrow$ 80	15,98 $\times$	16 $\times$




Figura 6: Convergência do erro do comprimento de arco em função de n (escala log-log), comparando f' analítica e f' estimada por `derivada_tabela`. As curvas praticamente se sobrepõem.

O fator de redução $n = 10 \rightarrow 20$ (160,96 $\times$) é bem maior que os 16 $\times$ esperados para $O(h^4)$: com $h = 0,2$ ($n = 10$) o erro ainda carrega contribuição de termos de ordem superior ($h^6, h^8, \dots$) da expansão do erro de Simpson, que ainda não desapareceram — a malha não é fina o bastante para a assíntota $O(h^4)$ dominar sozinha. Já os fatores $n = 20 \rightarrow 40$ (15,57 $\times$) e $n = 40 \rightarrow 80$ (15,98 $\times$) ficam bem próximos de 16 $\times$, confirmando que a partir de $h \approx 0,1$ ($n = 20$) a convergência já segue fielmente a ordem teórica.

Por isso, a inclinação de regressão log-log usando os 4 pontos (−4,98) fica distorcida pelo ponto pré-assintótico $n = 10$; calculada apenas na região assintótica ($n = 20, 40, 80$),

a inclinação $(-3,98)$ confirma com precisão a ordem $O(h^4)$ de Simpson — o mesmo gargalo já identificado em (c): o erro observado é inteiramente devido à integração, não à derivação.

5.2 Trabalho realizado por uma força variável

Questão 5.2 — Trabalho realizado por uma força variável

Enunciado: O trabalho realizado por uma força $F(x)$ ao mover um objeto de $x = a$ até $x = b$ é $W = \int_a^b F(x) dx$.

Os dados experimentais abaixo representam a força (em N) aplicada a um objeto ao longo de um trilho de 6 m:

x (m)	0,0	0,5	1,0	1,5	2,0	2,5	3,0	3,5	4,0	4,5	5,0	5,5	6,0
F (N)	0	8	15	20	24	26	27	26	22	17	11	5	0

- Calcule W por Trapézios e Simpson 1/3.
- Determine em qual ponto a força é máxima usando `derivada_tabela` para encontrar onde $F'(x) \approx 0$.
- A força cresce ou decresce mais rapidamente? Em qual região a aceleração (variação da força) é maior em magnitude?
- Se a massa do objeto é 2 kg e ele parte do repouso, estime sua velocidade ao final do percurso usando $W = \Delta K = \frac{1}{2}mv^2$.

Resposta:

(a) Trabalho $W = \int_0^6 F(x) dx$:

Os dados têm $n = 12$ subintervalos ($h = 0,5$ m), par — `simpson13_tabela` pode ser aplicado diretamente:

Tabela 48: Trabalho estimado por Trapézios e Simpson 1/3.

Método	W (J)
Trapézios	100,5000
Simpson 1/3	101,0000
Diferença $ \Delta W $	0,5000

(b) Localização da força máxima via $F'(x) \approx 0$:

Aplicando `derivada_tabela` aos dados de força:

Tabela 49: Derivada $F'(x)$ estimada em cada ponto da malha.

x (m)	$F'(x)$ (N/m)
0,0	17,000
0,5	15,000
1,0	12,000
1,5	9,000
2,0	6,000
2,5	3,000
3,0	0,000
3,5	-5,000
4,0	-9,000
4,5	-11,000
5,0	-12,000
5,5	-11,000
6,0	-9,000

$F'(x)$ passa de positivo para negativo exatamente em $x = 3,0$ m, onde $F'(3,0) = 0,0000 \approx 0$ — este é o ponto de **força máxima** ($F = 27,0$ N).

(c) Onde a força varia mais rapidamente:

Tabela 50: Taxas de variação extremas da força.

	x (m)	$F'(x)$ (N/m)
Crescimento mais rápido	0,0	17,000
Decrescimento mais rápido	5,0	-12,000

A força cresce mais rapidamente logo no início do percurso ($|F'| \approx 17,0$ N/m em $x = 0,0$ m) do que decresce perto do final ($|F'| \approx 12,0$ N/m em $x = 5,0$ m). Isso indica uma variação inicial mais brusca que a desaceleração no fim do trilho — a "aceleração" (no sentido de variação espacial de F) tem maior magnitude na região inicial do trajeto.

(d) Velocidade final ($m = 2$ kg, parte do repouso):

Como $W = \Delta K = \frac{1}{2}mv^2$ e o objeto parte do repouso:

$$v = \sqrt{\frac{2W}{m}}.$$

Tabela 51: Velocidade final estimada a partir de cada valor de W .

Fonte de W	W (J)	v (m/s)
Trapézios	100,5000	10,0250
Simpson 1/3	101,0000	10,0499
Diferença $ \Delta v $		0,0249

A pequena diferença de 0,0249 m/s entre as duas estimativas de velocidade reflete a diferença de 0,5 J no trabalho calculado — consistente com a maior precisão esperada de Simpson 1/3 para este conjunto de dados suaves.

5.3 Distribuição Normal e Probabilidade

Questão 5.3 — Distribuição Normal e Probabilidade

Enunciado: A função de distribuição acumulada (FDA) normal não tem primitiva elementar:

$$\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-t^2/2} dt \approx \frac{1}{\sqrt{2\pi}} \int_{-6}^x e^{-t^2/2} dt.$$

Calcule $\Phi(1,96)$, $\Phi(2,58)$ e $\Phi(3,00)$ numericamente, comparando com os valores tabelados: 0,9750, 0,9951 e 0,9987.

- (a) Use Simpson 1/3 com $n = 100$ no intervalo $[-6, x]$ para cada valor.
- (b) Use Gauss-Legendre com $n = 5, 10, 20$ no mesmo intervalo. Com qual n Gauss-Legendre supera Simpson com $n = 100$?
- (c) A cauda da distribuição (x grande) torna a integração mais difícil? Por que truncar em -6 (e não em $-\infty$) é adequado?
- (d) Aplicação: Em um teste de hipótese com $\alpha = 5\%$ (bicaudal), o valor crítico é $z_{\alpha/2}$ tal que $\Phi(z_{\alpha/2}) = 0,975$. Use a interpolação inversa sobre os valores de Φ calculados para estimar $z_{0,025}$. Compare com o valor exato $\approx 1,96$.

Resposta:

(a) $\Phi(x)$ por Simpson 1/3 ($n = 100$), truncando em $[-6, x]$:

Tabela 52: $\Phi(x)$ por Simpson 1/3 comparado aos valores tabelados.

x	Φ_{Simpson}	Φ_{tabelado}	Erro
1,96	0,975002	0,9750	$2,08 \times 10^{-6}$
2,58	0,995060	0,9951	$4,01 \times 10^{-5}$
3,00	0,998650	0,9987	$4,99 \times 10^{-5}$

(b) $\Phi(x)$ por Gauss-Legendre ($n = 5, 10, 20$):

Tabela 53: $\Phi(x)$ por Gauss-Legendre para diferentes n .

x	n	Φ_{GL}	Erro
1,96	5	0,978637	$3,64 \times 10^{-3}$
1,96	10	0,974998	$2,12 \times 10^{-6}$
1,96	20	0,975002	$2,10 \times 10^{-6}$
2,58	5	0,947981	$4,71 \times 10^{-2}$
2,58	10	0,994985	$1,15 \times 10^{-4}$
2,58	20	0,995060	$4,00 \times 10^{-5}$
3,00	5	0,908449	$9,03 \times 10^{-2}$
3,00	10	0,998543	$1,57 \times 10^{-4}$
3,00	20	0,998650	$4,99 \times 10^{-5}$

Comparando com Simpson $n = 100$ (101 avaliações), Gauss-Legendre supera essa precisão a partir de $n = 11$ (11 avaliações) nos três casos ($x = 1,96$, $2,58$ e $3,00$) — uma redução de quase $10\times$ no número de avaliações de f para atingir erro comparável ou menor.

(c) A cauda torna a integração mais difícil? Por que truncar em -6 ?

$$f(-6) = \frac{1}{\sqrt{2\pi}}e^{-18} \approx 6,076 \times 10^{-9}.$$

A cauda para $t < -6$ contribui com densidade da ordem de $6,1 \times 10^{-9}$, bem abaixo de qualquer tolerância numérica razoável (várias ordens de grandeza menor que os erros de truncamento de Simpson ou Gauss-Legendre já observados acima). Por isso, truncar em -6 (em vez de $-\infty$) introduz um erro desprezível. A integração em si não é "mais difícil" pela cauda em termos de magnitude — o integrando é suave e decai rapidamente — mas domínios muito maiores que o necessário (ver também discussão da Q6.2d) fariam com que Gauss-Legendre desperdiçasse nós em regiões de densidade nula, reduzindo sua eficiência; por isso a escolha de -6 como limite inferior é criteriosa.

(d) Interpolação inversa para $z_{0,025}$ ($\Phi(z) = 0,975$):

Tabela 54: Malha de $\Phi(x)$ usada para a interpolação inversa (Simpson, $n = 100$).

x	$\Phi(x)$
1,800	0,964070
1,850	0,967843
1,900	0,971283
1,950	0,974412
2,000	0,977250
2,050	0,979818
2,100	0,982136

Interpolando linearmente (inversamente) entre $x = 1,95$ ($\Phi = 0,974412$) e $x = 2,00$ ($\Phi = 0,977250$), que são os pontos que envolvem $\Phi = 0,975$:

Tabela 55: Estimativa de $z_{0,025}$ por interpolação inversa.

Grandeza	Valor
$z_{0,025}$ estimado	1,9604
Valor exato de referência	1,9600
Erro	$3,61 \times 10^{-4}$

A estimativa $z_{0,025} \approx 1,9604$ está em excelente acordo com o valor de referência $1,96$, com erro da ordem de 10^{-4} — perfeitamente adequado para fins de teste de hipótese, onde o valor crítico costuma ser reportado com 2 a 4 casas decimais.

6 Desafio (Opcional — Pontuação Extra)

6.1 Richardson Extrapolation

Questão 6.1 — Richardson Extrapolation

Enunciado: Dado que o erro dos Trapézios é $E_T(h) = c_2h^2 + c_4h^4 + \dots$, é possível combinar duas aproximações $T(h)$ e $T(h/2)$ para cancelar o termo h^2 e obter um método de ordem 4:

$$R(h) = \frac{4T(h/2) - T(h)}{3}.$$

Esta é a Regra de Romberg (primeiro passo).

- (a) Implemente $R(h)$ e verifique que ele é equivalente a Simpson 1/3.
 (b) Aplique o processo iterativamente (eliminando sucessivamente h^4 , h^6 , etc.) para $\int_1^2 \frac{1}{x} dx$ com $h = 0,5, 0,25, 0,125$. Construa a tabela de Romberg. Com quantas avaliações de f você atinge erro $< 10^{-10}$?
 (c) Compare a eficiência (erro por avaliação de f) com Gauss-Legendre.

Resposta:

(a) Verificação: $R(h) \equiv \text{Simpson}(2n)$:

Usando $n = 4$ (i.e., $h = (2 - 1)/4$) para $\int_1^2 1/x dx$:

Tabela 56: Verificação de que $R(h)$ coincide com Simpson(2n).

Grandeza	Valor
$T(n = 4)$	0,6970238095
$T(n = 8)$	0,6941218504
$R(h) = [4T(8) - T(4)]/3$	0,6931545307
$\text{Simpson}(n = 8)$	0,6931545307
$ R(h) - \text{Simpson}(8) $	$1,11 \times 10^{-16}$

A diferença de $1,11 \times 10^{-16}$ está exatamente no nível de arredondamento de máquina, confirmando a **equivalência algébrica** entre uma etapa de extrapolação de Richardson e Simpson 1/3 com o dobro dos subintervalos.

(b) Tabela de Romberg para $\int_1^2 1/x dx$ ($h = 0,5, 0,25, 0,125$):

Tabela 57: Tabela de Romberg (valores) para $\int_1^2 1/x dx = \ln 2$.

Nível	Ordem	Valores
R_0 ($n = 2, 4, 8$)	$O(h^2)$	0,70833333 0,69702381 0,69412185
R_1	$O(h^4)$	0,69325397 0,69315453
R_2	$O(h^6)$	0,69314790

Tabela 58: Erros absolutos da tabela de Romberg.

Nível	Ordem	Erros absolutos		
R_0	$O(h^2)$	$1,52 \times 10^{-2}$	$3,88 \times 10^{-3}$	$9,75 \times 10^{-4}$
R_1	$O(h^4)$	$1,07 \times 10^{-4}$	$7,35 \times 10^{-6}$	
R_2	$O(h^6)$	$7,21 \times 10^{-7}$		

Estendendo a tabela até $n = 32$ (adicionando $h = 0,0625$ e $h = 0,03125$) para localizar o menor número de avaliações que atinge erro $< 10^{-10}$:

Tabela 59: Menor malha necessária para erro de Romberg $< 10^{-10}$.

Grandeza	Valor
Menor malha final necessária (n)	32 ($h = 0,03125$)
Erro atingido	$1,35 \times 10^{-11}$
Avaliações de f (pontos únicos, malhas aninhadas)	33

Como as malhas de Romberg são obtidas por bisseção sucessiva (cada n é o dobro do anterior), os pontos são **aninhados**: a malha mais fina ($n = 32, 33$ pontos) já contém todos os pontos das malhas anteriores. Portanto, 33 avaliações de f bastam para construir toda a tabela e atingir erro $< 10^{-10}$.

(c) Comparação de eficiência: Romberg $\times$ Gauss-Legendre:

Tabela 60: Comparação de custo (avaliações de f) entre Romberg e Gauss-Legendre.

Método	Avaliações	Erro
Romberg (Richardson)	33	$1,35 \times 10^{-11}$
Gauss-Legendre $n = 2$	2	$8,39 \times 10^{-4}$
Gauss-Legendre $n = 3$	3	$2,55 \times 10^{-5}$
Gauss-Legendre $n = 4$	4	$7,63 \times 10^{-7}$
Gauss-Legendre $n = 5$	5	$2,27 \times 10^{-8}$
Gauss-Legendre $n = 6$	6	$6,73 \times 10^{-10}$
Gauss-Legendre $n = 7$	7	$1,99 \times 10^{-11}$

Romberg precisa de 33 avaliações de f para atingir erro $< 10^{-10}$, enquanto Gauss-Legendre atinge erro *comparável ou melhor* (Gauss-Legendre $n = 7$: $1,99 \times 10^{-11}$) com apenas 7 pontos — cerca de 4,7 vezes menos avaliações.

Por que Gauss-Legendre é mais eficiente aqui:

Gauss-Legendre escolhe os nós de forma ótima (maximizando o grau de exatidão por ponto: exato até grau $2n - 1$), enquanto Romberg parte de malhas uniformes e usa extrapolação para cancelar sucessivamente os termos $h^2, h^4, h^6, \dots$ do erro — uma estratégia eficaz, mas ainda limitada pelo número de avaliações da malha mais fina utilizada. Para funções suaves como $1/x$, Gauss-Legendre é ordens de magnitude mais eficiente por avaliação de função; a vantagem de Romberg é não exigir a escolha prévia de nós especiais, funcionando bem também sobre dados tabelados em malha uniforme.

6.2 Integração de Monte Carlo

Questão 6.2 — Integração de Monte Carlo

Enunciado: Para integrais em alta dimensão, Monte Carlo é o método padrão:

$$\int_{\Omega} f(x) d\Omega \approx V(\Omega) \cdot \frac{1}{N} \sum_{i=1}^N f(x_i), \quad x_i \sim \text{Uniform}(\Omega).$$

(a) Implemente Monte Carlo para $\int_0^1 e^{-x^2} dx$ com $N = 10^2, 10^3, 10^4, 10^5$. Calcule o erro médio (média de 20 execuções).

(b) O erro decai como $O(N^{-1/2})$. Verifique no gráfico log-log.

(c) Para obter erro $< 10^{-4}$: Monte Carlo precisa de quantos pontos? Compare com Gauss-Legendre. Para qual dimensão d o Monte Carlo começa a superar Gauss-Legendre em eficiência?

(d) Implemente para $\int_0^1 \int_0^1 e^{-(x^2+y^2)} dx dy$ (2D). Gauss-Legendre ainda funciona bem? Monte Carlo escala melhor?

Resposta:**Valor de referência (1D):**

$$\int_0^1 e^{-x^2} dx = \frac{\sqrt{\pi}}{2} \text{erf}(1) \approx 0,74682413.$$

(a) Monte Carlo — erro médio de 20 execuções:

Tabela 61: Erro médio de Monte Carlo para diferentes N (1D).

N	Erro médio
100	$1,74 \times 10^{-2}$
1000	$5,11 \times 10^{-3}$
10000	$1,32 \times 10^{-3}$
100000	$5,46 \times 10^{-4}$

(b) Verificação de $O(N^{-1/2})$:




Figura 7: Erro absoluto médio de Monte Carlo em função de N (escala log-log), com reta de referência de inclinação $-1/2$.

A inclinação da regressão log-log foi de $-0,510$, em excelente acordo com o $-0,5$ teórico de $O(N^{-1/2})$ — comportamento característico de qualquer estimador de Monte Carlo, independentemente da dimensão do problema.

(c) N necessário para erro $< 10^{-4}$ e comparação com Gauss-Legendre:

Ajustando erro $\approx C/\sqrt{N}$ com $C \approx 0,1726$ (obtido do ponto $N = 10^5$):

Tabela 62: Estimativa de N necessário e comparação com Gauss-Legendre.

Grandeza	Valor
N necessário para erro $< 10^{-4}$	$\approx 2,98 \times 10^6$

Tabela 63: Erro de Gauss-Legendre para a mesma integral 1D.

n (GL)	Erro
2	$2,29 \times 10^{-4}$
3	$9,55 \times 10^{-6}$
4	$3,35 \times 10^{-7}$
5	$6,05 \times 10^{-9}$

Monte Carlo precisaria de aproximadamente 3×10^6 amostras para atingir erro $< 10^{-4}$, enquanto Gauss-Legendre atinge erro muito menor com apenas 3–4 pontos. Para uma função suave em 1D, Monte Carlo é extremamente ineficiente comparado a quadraturas determinísticas.

Quanto à dimensão de equilíbrio: o custo de Gauss-Legendre por produto tensorial cresce como n^d (exponencial em d), enquanto o custo de Monte Carlo permanece $O(N)$, com erro sempre $O(N^{-1/2})$, independente de d . Igualando os custos para uma dada precisão, a dimensão de equilíbrio é tipicamente $d \gtrsim 5-8$ (dependendo da suavidade do

integrando e da precisão exigida) — abaixo disso, Gauss-Legendre (ou outra quadratura determinística) é mais eficiente; acima disso, a maldição da dimensionalidade torna Monte Carlo competitivo ou superior.

(d) **Extensão 2D:** $\int_0^1 \int_0^1 e^{-(x^2+y^2)} dx dy$:

$$\int_0^1 \int_0^1 e^{-(x^2+y^2)} dx dy = \left(\frac{\sqrt{\pi}}{2} \operatorname{erf}(1) \right)^2 \approx 0,55774629.$$

Tabela 64: Erro médio de Monte Carlo 2D em $[0, 1] \times [0, 1]$.

N	Erro médio (2D)
100	$2,06 \times 10^{-2}$
1000	$7,18 \times 10^{-3}$
10000	$1,26 \times 10^{-3}$
100000	$6,14 \times 10^{-4}$

Tabela 65: Gauss-Legendre 2D (produto tensorial $n \times n$) em $[0, 1] \times [0, 1]$.

n	Avaliações	Erro
2	4	$3,43 \times 10^{-4}$
4	16	$5,01 \times 10^{-7}$
6	36	$1,16 \times 10^{-10}$

Sim, Gauss-Legendre ainda funciona muito bem em 2D — com $n = 4$ (16 avaliações) atinge erro da ordem de 10^{-7} , e com $n = 6$ (36 avaliações) chega a 10^{-10} : muito melhor que Monte Carlo com $N = 10^5$ (100.000 amostras, erro $\approx 6,1 \times 10^{-4}$). Mesmo em 2D, Gauss-Legendre ainda domina claramente. Isso ocorre porque o custo de Gauss-Legendre cresce como n^d (exponencial na dimensão d), enquanto o de Monte Carlo permanece $O(N)$ independente de d , com erro sempre $O(N^{-1/2})$. A vantagem de Monte Carlo só se manifesta quando a dimensão é alta o suficiente (tipicamente $d \gtrsim 5-8$, dependendo da suavidade do integrando) para que n^d supere o custo fixo de Monte Carlo — daí seu uso dominante em problemas de alta dimensão (finanças, física estatística, aprendizado de máquina), onde quadraturas por produto tensorial se tornam inviáveis.

6.3 Gradiente Numérico em Machine Learning

Questão 6.3 — Gradiente Numérico em Machine Learning

Enunciado: Em treinamento de redes neurais, o *gradient check* verifica a implementação do backpropagation comparando com diferenças finitas:

$$\frac{\partial L}{\partial \theta_i} \approx \frac{L(\theta + \varepsilon e_i) - L(\theta - \varepsilon e_i)}{2\varepsilon}.$$

(a) Para a função de perda $L(\theta) = \sum_{k=1}^n (\theta^T x_k - y_k)^2$ com dados sintéticos ($x_k \in \mathbb{R}^3$,

$\theta \in \mathbb{R}^3$), calcule o gradiente analítico $\nabla_{\theta} L = 2X^T(X\theta - y)$.

(b) Calcule o gradiente numérico por diferenças centrais com $\varepsilon = 10^{-5}$.

(c) Calcule a diferença relativa $\frac{\|\nabla L_{\text{analítico}} - \nabla L_{\text{numérico}}\|_2}{\|\nabla L_{\text{analítico}}\|_2}$. Se for $< 10^{-5}$, o gradiente está correto.

(d) Por que não se usa ε muito pequeno no gradient check? Conecte com a análise do passo ótimo da Seção 1.

Resposta:

Dados sintéticos: $K = 20$ amostras, $x_k \in \mathbb{R}^3$ gerados de uma normal padrão, com $\theta_{\text{verdadeiro}} = (2, 0, -1, 0, 5)$ e ruído gaussiano de desvio 0,1 sobre $y_k = \theta_{\text{verdadeiro}}^T x_k$. O gradiente é avaliado em $\theta_0 = (0, 5, 0, 5, 0, 5)$.

(a) **Gradiente analítico** $\nabla_{\theta} L = 2X^T(X\theta - y)$:

Tabela 66: Gradiente analítico em θ_0 .

Componente	Valor
$\partial L / \partial \theta_1$	-58,74709524
$\partial L / \partial \theta_2$	62,88812228
$\partial L / \partial \theta_3$	16,38888362

(b) **Gradiente numérico por diferenças centrais** ($\varepsilon = 10^{-5}$):

Tabela 67: Gradiente numérico em θ_0 (diferença central).

Componente	Valor
$\partial L / \partial \theta_1$	-58,74709524
$\partial L / \partial \theta_2$	62,88812228
$\partial L / \partial \theta_3$	16,38888362

Os gradientes analítico e numérico coincidem até a 8ª casa decimal exibida.

(c) **Diferença relativa:**

$$\frac{\|\nabla L_{\text{analítico}} - \nabla L_{\text{numérico}}\|_2}{\|\nabla L_{\text{analítico}}\|_2} = 1,50 \times 10^{-11}.$$

Como $1,50 \times 10^{-11} < 10^{-5}$, o critério é satisfeito: **o gradiente analítico está correto.**

(d) **Por que não usar ε muito pequeno?**

Tabela 68: Sensibilidade da diferença relativa ao passo ε .

ε	Diferença relativa
10^{-2}	$3,07 \times 10^{-14}$
10^{-4}	$1,10 \times 10^{-12}$
10^{-5}	$1,50 \times 10^{-11}$
10^{-7}	$2,29 \times 10^{-9}$
10^{-9}	$8,14 \times 10^{-8}$
10^{-11}	$2,36 \times 10^{-5}$

O padrão é exatamente o mesmo identificado na análise do passo ótimo da Seção 1.3: como $L(\theta)$ é quase-quadrática, o erro de truncamento da diferença central já é desprezível mesmo para ε relativamente grandes (10^{-2}), e a diferença relativa fica dominada pelo **arredondamento de máquina**. Ao diminuir ε além de um certo ponto, a subtração $L(\theta + \varepsilon e_i) - L(\theta - \varepsilon e_i)$ passa a envolver valores de perda quase idênticos, e o **cancelamento catastrófico** faz a diferença relativa **crescer** (de $3,07 \times 10^{-14}$ em $\varepsilon = 10^{-2}$ até $2,36 \times 10^{-5}$ em $\varepsilon = 10^{-11}$).

Conexão com a Seção 1.3:

Este é exatamente o mesmo fenômeno do h_{opt} identificado para `df_central` na Questão 1.3: existe um equilíbrio entre erro de truncamento (que cai com ε^2) e erro de arredondamento (que cresce com $1/\varepsilon$). Por isso, o gradient check **não deve usar ε extremamente pequeno** (ex.: 10^{-11}) — em vez de melhorar a precisão, isso amplifica o erro de cancelamento catastrófico. Um valor intermediário, como $\varepsilon = 10^{-5}$ a 10^{-4} (a escolha convencional em implementações de gradient check), equilibra bem os dois efeitos para a precisão de máquina em ponto flutuante duplo ($\varepsilon_m \approx 2,2 \times 10^{-16}$).