

Universidade Federal de Alfenas
Instituto de Ciências Exatas
Curso de Bacharelado em Ciência da Computação

Plano de Investigação Computacional

Interpolação e Ajuste de Curvas: Uma Abordagem Integrada em Python

Aluno: Jeann Victor Batista
RA: 2024.1.08.014

Aluno: Pedro Augusto de Souza Finnochio
RA: 2024.1.08.020

Aluno: Thiago Martins da Silva
RA: 2024.1.08.023

Disciplina: Cálculo Numérico

Professora: Angela Leite Moreno

Alfenas, 2026

Sumário

1. Interpolação: Implementação e Verificação
 - 1.1 Primeiros passos com os métodos
 - 1.2 Adição de um ponto e atualização de Newton
 - 1.3 Fenômeno de Runge e nós de Chebyshev
 - 1.4 Spline cúbica vs. polinômio global
2. Ajuste de Curvas: Mínimos Quadrados e Modelos
 - 2.1 Geometria dos mínimos quadrados
 - 2.2 Sobreajuste polinomial
 - 2.3 Critérios para escolha do grau
3. Dados com Ruído: Interpolação ou Ajuste?
 - 3.1 Comparação direta
 - 3.2 Diagnóstico pelo gráfico de resíduos
4. Modelos Não Lineares e Linearização
 - 4.1 Crescimento populacional e lei de potência
 - 4.2 Quando a linearização distorce
5. Comparação Integrada: Interpolação vs. Ajuste
 - 5.1 Tabela de síntese
 - 5.2 Tomada de decisão em cenários reais
6. Projeto Integrador: Calibração de Sensor
 - 6.1 Calibração precisa (laboratório)
 - 6.2 Robustez ao ruído de campo
 - 6.3 Decisão final e documentação
7. Desafio (Opcional — Pontuação Extra)
 - 7.1 Spline de suavização (smoothing spline)
 - 7.2 Interpolação de Hermite e derivadas conhecidas
 - 7.3 Regressão com múltiplas variáveis

1 Interpolação: Implementação e Verificação

1.1 Primeiros passos com os métodos

Questão 1.1 — Primeiros passos com os métodos

Enunciado: Utilizando os pontos $x = [1, 2, 3, 4]$ e $y = [1, 4, 9, 16]$ (que pertencem à função $f(x) = x^2$), responda:

(a) Execute `lagrange` e `newton` para $x = 1,5$ e $x = 2,5$. Os dois métodos produzem o mesmo resultado? Qual é a diferença numérica $|p_L(x) - p_N(x)|$? Explique por que, teoricamente, os dois devem coincidir.

(b) Imprima a tabela de diferenças divididas. Identifique os coeficientes do polinômio de Newton na forma $p_3(x) = c_0 + c_1(x - x_0) + c_2(x - x_0)(x - x_1) + c_3(x - x_0)(x - x_1)(x - x_2)$.

(c) Os dados acima provêm de $f(x) = x^2$. O polinômio interpolador coincide exatamente com f ? Por quê? (Discuta o teorema de unicidade.)

Resposta:

(a) Comparação entre Lagrange e Newton:

Para os pontos fornecidos, os valores interpolados obtidos foram:

Tabela 1: Comparação entre Lagrange e Newton

Método	$x = 1,5$	$x = 2,5$
Lagrange	2,25	6,25
Newton	2,25	6,25
Diferença	0,00	0,00

Os dois métodos produzem resultados numericamente idênticos (diferença = 0), pois pelo **teorema da unicidade do interpolador polinomial**: dado $n + 1$ pontos distintos, existe exatamente um polinômio de grau $\leq n$ que passa por todos eles. Lagrange e Newton são apenas representações algébricas diferentes do mesmo e único polinômio interpolador.

(b) Coeficientes do polinômio de Newton (diferenças divididas):

A tabela de diferenças divididas resulta nos coeficientes:

$$c_0 = 1,0000, \quad c_1 = 3,0000, \quad c_2 = 1,0000, \quad c_3 = 0,0000.$$

O polinômio na forma de Newton é, portanto:

$$p_3(x) = 1 + 3(x - 1) + 1 \cdot (x - 1)(x - 2) + 0 \cdot (x - 1)(x - 2)(x - 3).$$

Expandindo: $p_3(x) = 1 + 3x - 3 + x^2 - 3x + 2 = x^2$, confirmando a recuperação exata de f .

(c) Recuperação exata de $f(x) = x^2$:

Sim, o polinômio interpolador coincide *exatamente* com $f(x) = x^2$. Como f é um polinômio de grau 2 e os 4 pontos fornecidos pertencem a f , o único polinômio de grau ≤ 3 que interpola esses pontos é o próprio f . Isso se reflete nos coeficientes: a diferença dividida de terceira ordem $c_3 = 0$, sinalizando que o interpolador tem grau efetivo 2.

1.2 Adição de um ponto e atualização de Newton

Questão 1.2 — Adição de um ponto e atualização de Newton

Enunciado: Adicione o ponto $x_4 = 5,0$, $f(x_4) = 25,0$ à tabela anterior.

(a) Para a forma de Lagrange, quantas operações a mais são necessárias? Refaça o cálculo completo para o novo conjunto.

(b) Para a forma de Newton, mostre como apenas uma nova diferença dividida precisa ser calculada. Verifique que o novo polinômio coincide com o de Lagrange em $x = 3,5$.

(c) Esta propriedade é a principal vantagem prática de Newton sobre Lagrange. Em que cenário ela seria crítica em uma aplicação real?

Resposta:

(a) Custo computacional de Lagrange:

Na forma de Lagrange, cada base $L_i(x)$ depende de *todos* os nós: $L_i(x) = \prod_{j \neq i} \frac{x - x_j}{x_i - x_j}$.

Ao adicionar um quinto ponto, todos os 5 polinômios de base precisam ser recalculados do zero. O custo cresce como $O(n^2)$ — a estrutura anterior é inteiramente descartada. Os valores interpolados para $x = 1,5$ e $x = 2,5$ permanecem 2,25 e 6,25, respectivamente.

(b) Atualização incremental de Newton:

Na forma de Newton, os quatro coeficientes anteriores (c_0, c_1, c_2, c_3) permanecem *inalterados*. Apenas uma nova diferença dividida de quarta ordem precisa ser computada:

$$f[x_0, x_1, x_2, x_3, x_4] = 0,0000.$$

Verificação em $x = 3,5$:

$$\text{Lagrange} = 12,25, \quad \text{Newton} = 12,25, \quad \text{Diferença} = 0,00.$$

Os dois polinômios coincidem, como garantido pelo teorema da unicidade (ambos representam o mesmo interpolador de grau ≤ 4 sobre 5 pontos de x^2).

(c) Cenários de aplicação crítica:

A atualização incremental de Newton é fundamental em qualquer aplicação com **chegada contínua de novos dados**, como sensores IoT e sistemas de monitoramento industrial que registram novas medições a cada instante, simulações numéricas onde pontos são adicionados adaptativamente à malha, e sistemas de aquisição em tempo real onde recalcular toda a interpolação a cada novo ponto seria computacionalmente inviável.

1.3 Fenômeno de Runge e nós de Chebyshev

Questão 1.3 — Runge e remédios

Enunciado: Considere a função de Runge $f(x) = \frac{1}{1 + 25x^2}$, $x \in [-1, 1]$.

(a) Para $n \in \{5, 9, 13, 17\}$, interpole f com nós igualmente espaçados usando Lagrange. Plote o erro $|f(x) - p_n(x)|$. O erro aumenta ou diminui com n ?

(b) Repita com nós de Chebyshev. Plote as duas curvas de erro ($n = 13$) no mesmo gráfico. Qual redução máxima de erro você observa?

(c) Preencha a tabela com as normas do erro infinito.

(d) Por que os nós de Chebyshev mitigam o fenômeno de Runge?

Resposta:

(a) Comportamento do erro com nós igualmente espaçados:




Figura 1: Erro de interpolação para a função de Runge com nós igualmente espaçados para $n \in \{5, 9, 13, 17\}$.

Com nós igualmente espaçados, o erro **cresce rapidamente nas extremidades** do intervalo à medida que n aumenta — este é o **fenômeno de Runge**. Embora o polinômio passe exatamente pelos nós, a oscilação entre eles se torna cada vez mais violenta próxima às bordas do intervalo.

(b) Comparação com nós de Chebyshev ($n = 13$):




Figura 2: Comparação do erro de interpolação entre nós igualmente espaçados e nós de Chebyshev para $n = 13$.

Com $n = 13$, a redução máxima do erro ao usar nós de Chebyshev foi de aproximadamente **52,9 vezes** ($\|f - p_{13}\|_{\infty} \approx 3,66$ com nós igualmente espaçados vs. $\approx 0,069$ com Chebyshev).

(c) Tabela de erros:

Tabela 2: Norma do erro infinito $\|f - p_n\|_\infty$ para diferentes n e tipos de nós.

n	$\ f - p_n\ _\infty$ (igualmente espaçados)	$\ f - p_n\ _\infty$ (Chebyshev)
5	$4,3835 \times 10^{-1}$	$4,0201 \times 10^{-1}$
9	$1,0452 \times 10^0$	$1,7080 \times 10^{-1}$
13	$3,6629 \times 10^0$	$6,9189 \times 10^{-2}$
17	$1,4387 \times 10^1$	$3,2613 \times 10^{-2}$

Observa-se que, com nós igualmente espaçados, o erro cresce por ordem de grandeza a cada incremento de n , enquanto com Chebyshev o erro *decrece* monotonamente — convergência que é a esperada para funções analíticas.

(d) Por que Chebyshev mitiga o fenômeno de Runge:

A fórmula do erro de interpolação estabelece:

$$|f(x) - p_n(x)| \leq \frac{M_{n+1}}{(n+1)!} |\omega_{n+1}(x)|, \quad \omega_{n+1}(x) = \prod_{i=0}^n (x - x_i).$$

Os nós de Chebyshev são definidos como as raízes do polinômio de Chebyshev $T_{n+1}(x)$ em $[-1, 1]$:

$$x_i = \cos\left(\frac{2i-1}{2(n+1)}\pi\right), \quad i = 1, \dots, n+1.$$

Pode-se demonstrar que T_{n+1} *minimiza* $\|\omega_{n+1}\|_\infty$ dentre todos os polinômios mônicos de grau $n+1$ em $[-1, 1]$, com $\|\omega_{n+1}\|_\infty = 2^{-n}$. Como o erro é proporcional a $|\omega_{n+1}(x)|$, usar as raízes de T_{n+1} como nós reduz o pior caso do erro, concentrando os nós nas extremidades do intervalo e evitando as oscilações características do fenômeno de Runge.

1.4 Spline cúbica vs. polinômio global

Questão 1.4 — Quando a spline supera o polinômio global

Enunciado: Use os dados mensais de temperatura média em Alfenas-MG:

Mês	1	2	3	4	5	6	7	8	9	10	11	12
T (°C)	23	24	23	21	18	16	16	18	20	22	23	24

- Interpole com Lagrange ($n = 11$, nós nos meses $1, \dots, 12$). Há oscilações indesejadas?
- Interpole com spline cúbica (`tipo='not-a-knot'`). Plote na mesma figura.
- Compare os valores interpolados para $x = 1,5$, $x = 6,5$ e $x = 11,5$.
- Investigue o efeito das condições de contorno (`'natural'` vs. `'not-a-knot'`).

Resposta:

(a) Polinômio global de Lagrange:




Figura 3: Interpolação de Lagrange (grau 11) para as temperaturas mensais de Alfenas-MG.

O polinômio global de grau 11 apresenta **oscilações indesejadas**, principalmente nas extremidades do intervalo (meses 1–2 e 11–12), caracterizando o fenômeno de Runge aplicado a dados reais. Fisicamente, temperaturas não oscilam dessa forma no curto prazo.

(b) Spline cúbica (not-a-knot):




Figura 4: Comparação entre spline cúbica (not-a-knot) e polinômio de Lagrange (grau 11).

A spline cúbica reproduz **muito melhor** o comportamento físico esperado de uma série climática, produzindo uma curva suave e sem oscilações artificiais. Isso ocorre porque a spline é composta por polinômios de grau 3 por partes, com continuidade até a segunda derivada em cada nó — evitando as oscilações globais do polinômio de alto grau.

(c) Comparação numérica nos pontos intermediários:

Tabela 3: Valores interpolados por Lagrange e spline cúbica.

x	Lagrange (°C)	Spline not-a-knot (°C)	Diferença (°C)
1,5	26,07	23,84	2,23
6,5	15,70	15,71	0,01
11,5	20,51	23,40	2,89

As maiores discrepâncias ocorrem nas extremidades, exatamente onde as oscilações de Lagrange são mais acentuadas. Para um sistema de monitoramento climático, a **spline cúbica** é mais adequada: as estimativas para $x = 1,5$ (23,84°C) e $x = 11,5$ (23,40°C) são fisicamente plausíveis para Alfenas, enquanto as de Lagrange (26,07°C e 20,51°C, respectivamente) apresentam variações artificiais.

(d) Efeito das condições de contorno:




Figura 5: Comparação entre spline natural e not-a-knot nas extremidades do intervalo.

As duas variantes diferem principalmente nas bordas do intervalo:

A **spline natural** impõe $S''(x_0) = S''(x_n) = 0$, forçando curvatura nula nos extremos — comportamento mais “relaxado”, que pode subestimar a curvatura real da função nesses pontos.

A condição **not-a-knot** exige continuidade da terceira derivada nos nós x_1 e x_{n-1} , efetivamente reduzindo o número de parâmetros livres e produzindo um ajuste mais “firme” e geralmente mais preciso quando o comportamento nas bordas é desconhecido. A escolha entre elas depende de informação adicional disponível: se há razão física para impor $S'' = 0$ nas bordas, usa-se natural; caso contrário, not-a-knot costuma ser a opção padrão mais robusta.

2 Ajuste de Curvas: Mínimos Quadrados e Modelos

2.1 Geometria dos mínimos quadrados

Questão 2.1 — A geometria dos mínimos quadrados

Enunciado: Considere os dados de velocidade e distância de frenagem:

v (km/h)	20	40	60	80	100	120
d (m)	5	14	28	47	72	103

- (a) Ajuste $d = a_0 + a_1 v$ e reporte a_0 , a_1 , R^2 .
- (b) Ajuste $d = a'_0 + a'_1 v^2$ (linearize com $z = v^2$). Compare R^2 .
- (c) Plote os dados, as curvas e os resíduos. O que os resíduos revelam?
- (d) Por que minimizamos $\sum r_i^2$ e não $\sum |r_i|$?

Resposta:

(a) Ajuste linear $d = a_0 + a_1 v$:

$$d = -23,4667 + 0,9757 v, \quad R^2 = 0,9593.$$

Embora $R^2 > 0,95$ pareça razoável, o ajuste linear não é adequado: a distância de frenagem cresce de forma quadrática com a velocidade (energia cinética $\propto v^2$), e o modelo linear não captura essa curvatura.

(b) Ajuste quadrático $d = a'_0 + a'_1 v^2$ (linearização $z = v^2$):


$$d = 2,5763 + 0,006965 v^2, \quad R^2 = 0,99994.$$

Tabela 4: Comparação dos R^2 entre os dois modelos de frenagem.

Modelo	R^2
Linear ($d = a_0 + a_1 v$)	0,9593
Quadrático ($d = a'_0 + a'_1 v^2$)	0,99994

O modelo quadrático é claramente superior: $R^2 \approx 1$, pois é fisicamente correto (decorre diretamente da equação $d = v^2/(2\mu g)$ para frenagem com atrito).

(c) Gráficos e análise dos resíduos:



(a) Ajustes linear e quadrático sobre os dados. (b) Resíduos $r_i = d_i - \hat{d}_i$ para cada modelo.

Figura 6: Comparação entre os modelos de frenagem.

Os resíduos do modelo linear apresentam um **padrão sistemático em arco** (negativos para velocidades baixas e altas, positivos no meio), confirmando *underfitting*: o modelo linear não captura a curvatura quadrática dos dados. Os resíduos do modelo quadrático são pequenos e distribuídos aleatoriamente em torno de zero, indicando ajuste adequado.

(d) Por que minimizar $\sum r_i^2$?

Minimizar $\sum r_i^2$ (critério dos mínimos quadrados) em vez de $\sum |r_i|$ apresenta duas vantagens fundamentais: a função objetivo é **diferenciável em todo o domínio**, o que permite derivar uma solução analítica fechada pelas equações normais $A^T A \mathbf{c} = A^T \mathbf{y}$; e, pelo **Teorema de Gauss-Markov**, o estimador resultante é o melhor estimador linear não viesado (BLUE) sob as hipóteses clássicas de regressão.

A principal desvantagem é a **sensibilidade a outliers**: a penalização quadrática amplifica fortemente o efeito de pontos aberrantes, distorcendo o ajuste. Nesses casos, alternativas como regressão LAD ($\sum |r_i|$) ou regressão robusta são mais apropriadas.

2.2 Sobreajuste polinomial

Questão 2.2 — Sobreajuste polinomial

Enunciado: Gere 15 dados sintéticos com ruído:

```
1 np.random.seed(7)
2 x = np.linspace(0, 2*np.pi, 15)
3 y = np.sin(x) + 0.15 * np.random.randn(15)
```

(a) Ajuste polinômios de grau $k \in \{1, 3, 5, 7, 10, 14\}$, calculando R^2 no treino e $\|f - p_k\|_\infty$ em 500 pontos.

(b) Preencha a tabela.

(c) Plote o erro em escala log vs. grau. A partir de qual grau o modelo deteriora?

(d) Explique a diferença entre erro de treinamento e generalização. Relacione com Runge.


Resposta:

(a) e (b) Resultados dos ajustes:

Tabela 5: Métricas dos ajustes polinomiais para dados com ruído.

Grau k	R^2 (treino)	$\ f - p_k\ _\infty$
1	0,5321	$8,031 \times 10^{-1}$
3	0,9597	$1,757 \times 10^{-1}$
5	0,9793	$2,125 \times 10^{-1}$
7	0,9825	$2,492 \times 10^{-1}$
10	0,9879	$3,635 \times 10^{-1}$
14	1,0000	$1,521 \times 10^1$

(c) Análise do erro vs. grau:

Figura 7: Erro máximo $\|f - p_k\|_\infty$ em função do grau k (escala logarítmica).

O menor erro de generalização ocorre para **grau 3**. A partir do **grau 7–10** o erro máximo começa a crescer de forma consistente fora dos pontos de ajuste. No grau 14, o polinômio interpola exatamente os 15 pontos ($R^2 = 1,0000$), mas o erro máximo em relação à função verdadeira dispara para $\approx 15,2$ — exemplo clássico de sobreajuste: ajuste perfeito nos dados de treino, mas péssima generalização.

(d) Sobreajuste e analogia com Runge:

Erro de treinamento mede o ajuste nos pontos usados para construir o modelo. Este erro decresce monotonamente com o grau — um modelo mais complexo sempre pode se ajustar melhor aos dados vistos.

Erro de generalização mede o desempenho em pontos novos, não vistos durante o treinamento. Quando o modelo memoriza o ruído presente nos dados (sobreajuste), esse erro aumenta mesmo com $R^2 \rightarrow 1$.

A analogia com Runge é direta: em ambos os fenômenos, polinômios de grau elevado oscilam violentamente entre os pontos de referência. A diferença está no contexto — Runge ocorre mesmo com dados *exatos*, enquanto o sobreajuste é *agravado* pela presença de ruído, que o polinômio “aprende” em detrimento do sinal verdadeiro.

2.3 Critérios para escolha do grau

Questão 2.3 — Critérios para escolha do grau

Enunciado: Usando os dados sintéticos da questão anterior:

(a) Separe 10 pontos para treino e 5 para teste (`seed=42`). Calcule MSE nos dois conjuntos para graus 1 a 10. Qual grau minimiza o MSE de teste?

(b) Calcule o Critério de Informação de Akaike (AIC) para graus 1 a 10. Qual grau minimiza o AIC?

(c) Os dois critérios concordam? Qual é mais adequado para dados escassos?

Resposta:

(a) Validação treino-teste:




Figura 8: MSE de treino e de teste em função do grau polinomial.

O grau que minimiza o MSE de teste foi **grau 3**. Observa-se o comportamento clássico de sobreajuste: o MSE de treino decresce monotonamente com o grau, enquanto o MSE de teste atinge um mínimo e depois cresce — o modelo começa a memorizar o ruído dos dados de treino.

(b) Critério de Informação de Akaike (AIC):

O AIC foi calculado como $AIC = n \ln(RSS/n) + 2(k + 1)$, onde RSS é a soma dos resíduos ao quadrado e k é o grau.

Tabela 6: AIC calculado para graus 1 a 10 (conjunto de treino com 10 pontos).

Grau	AIC
1	-11,85
2	-9,87
3	-35,10
4	-36,79
5	-50,59
6	-48,76
7	-51,04
8	-64,08
9	-485,81
10	-483,55

O grau que minimiza o AIC foi **grau 9**. Os valores muito negativos para graus 9 e 10 decorrem de RSS extremamente pequenos: com 10 pontos de treino e polinômio de grau 9 (10 parâmetros), o sistema fica quase interpolante, tornando o RSS próximo de zero e, portanto, $\ln(\text{RSS}/n) \rightarrow -\infty$. Isso evidencia uma limitação da fórmula AIC com amostras muito pequenas: o critério penaliza a complexidade com $+2(k+1)$, mas essa penalização torna-se insuficiente quando $n \approx k$. Nesses casos, recomenda-se o AIC corrigido (AIC_c).

(c) Comparação e recomendação:

Critério	Grau ótimo
Validação treino-teste	3
AIC (fórmula padrão)	9

Os dois critérios **não concordam**. A validação cruzada com apenas 5 pontos de teste pode ter alta variância (o conjunto de teste pode não ser representativo), mas o AIC padrão com amostra pequena sofre do problema descrito acima.

Para **dados escassos**, recomenda-se usar o AIC_c (Akaike corrigido: $\text{AIC} + \frac{2k(k+1)}{n-k-1}$) ou validação cruzada com k -fold ($k = 5$ ou $k = 10$), que usa todos os dados tanto para treino quanto para teste. Considerando os resultados, o **grau 3** parece a escolha mais parcimoniosa e robusta para esses dados.

3 Dados com Ruído: Interpolação ou Ajuste?

3.1 Comparação direta

Questão 3.1 — O custo de interpolar dados ruidosos

Enunciado: Considere medições (com ruído) de uma função exponencial decrescente:

```
1 np.random.seed(3)
2 x_med = np.array([0.0, 0.5, 1.0, 1.5, 2.0, 2.5, 3.0])
3 y_med = 5.0 * np.exp(-0.8 * x_med) + 0.2 * np.random.randn(7)
```

(a) Aplique interpolação de Lagrange (grau 6) aos 7 pontos ruidosos. Plote a curva interpoladora, os dados e a função verdadeira $f(x) = 5e^{-0,8x}$.

(b) Aplique ajuste exponencial. Reporte a e b estimados e compare com os valores verdadeiros ($a = 5$, $b = -0,8$).

(c) Plote as três curvas no mesmo gráfico. Qual é mais fiel no intervalo $[0, 3]$? E na extrapolação $[3, 4]$?

(d) Para prever $f(3,5)$, qual método usaria? Por quê?

Resposta:

(a) Interpolação de Lagrange sobre dados ruidosos:




Figura 9: Interpolação de Lagrange (grau 6) sobre dados ruidosos da exponencial e função verdadeira $f(x) = 5e^{-0,8x}$.

O interpolador de grau 6 passa *exatamente* por todos os 7 pontos ruidosos, mas oscila em torno da função verdadeira. Esta é a principal limitação da interpolação com dados ruidosos: ela **força o polinômio a passar pelos erros de medição**, capturando o ruído como sinal.

(b) Ajuste exponencial (linearização via $\ln y$):

$$\hat{a} = 5,0772, \quad \hat{b} = -0,8469.$$

Tabela 7: Comparação entre parâmetros estimados e valores verdadeiros.

Parâmetro	Valor real	Estimado	Erro relativo
a	5,0	5,0772	1,54%
b	-0,8	-0,8469	5,86%

Apesar do ruído nos dados, o ajuste exponencial recupera os parâmetros verdadeiros com boa precisão, pois o método dos mínimos quadrados distribui o efeito do ruído ao longo de todos os pontos.

(c) Comparação visual das três curvas:




Figura 10: Comparação entre interpolação de Lagrange, ajuste exponencial e função verdadeira.

Intervalo $[0, 3]$: O ajuste exponencial representa melhor a tendência global, ignorando o ruído. O interpolador passa pelos pontos ruidosos, mas não captura o comportamento subjacente.

Extrapolação $[3, 4]$: O interpolador de Lagrange **diverge fortemente** (comportamento típico de polinômios de alto grau fora do intervalo de interpolação), enquanto o ajuste exponencial mantém o decrescimento esperado fisicamente.

(d) Previsão em $x = 3,5$:

Método	Previsão
Lagrange	12,9349
Ajuste exponencial	0,2620
Valor real $f(3,5)$	0,3041

Para prever $f(3,5)$, o **ajuste exponencial** é incomparavelmente mais adequado: sua previsão (0,2620) difere do valor real (0,3041) em apenas 13,8%, enquanto o interpolador de Lagrange produz 12,93 — um erro de mais de 4000%. O ajuste preserva o comportamento físico correto (decrescimento exponencial) e é estável na extrapolação.

3.2 Diagnóstico pelo gráfico de resíduos

Questão 3.2 — Diagnóstico pelo gráfico de resíduos

Enunciado: Usando os dados do experimento anterior:

(a) Calcule os resíduos $r_i = y_i - \hat{y}_i$ para o ajuste exponencial. Plote r_i vs. x_i . Os resíduos têm estrutura ou parecem aleatórios?

(b) Agora ajuste um modelo linear $y = a_0 + a_1x$ aos mesmos dados ruidosos. Plote os resíduos. O que o gráfico revela?

(c) Formule uma regra prática para diagnosticar *underfitting* a partir do gráfico de resíduos.

Resposta:

(a) Resíduos do ajuste exponencial:




Figura 11: Resíduos do ajuste exponencial $r_i = y_i - \hat{y}_i$ em função de x_i .

Os resíduos do ajuste exponencial estão distribuídos de forma **aproximadamente aleatória** em torno de zero, sem tendência sistemática ou padrão identificável. Isso indica que o modelo exponencial é adequado para descrever a relação subjacente nos dados: o sinal foi capturado e o que resta são apenas erros aleatórios de medição.

(b) Resíduos do modelo linear:




Figura 12: Resíduos do ajuste linear $r_i = y_i - \hat{y}_i$ em função de x_i .

Os resíduos do modelo linear apresentam um **padrão sistemático curvado**: resíduos positivos para x pequeno (o modelo subestima a queda inicial), negativos na região intermediária (o modelo superestima) e positivos novamente para x grande. Esse padrão em forma de “U” invertido evidencia que o modelo linear não captura a curvatura exponencial dos dados — é um caso clássico de *underfitting*.

(c) Regra prática de diagnóstico via resíduos:

Regra de diagnóstico de underfitting pelo gráfico de resíduos:

Se os resíduos $r_i = y_i - \hat{y}_i$ exibem **padrão sistemático** (tendência monotônica, curvatura, agrupamentos ou estrutura periódica), o modelo está subdimensionado: existe estrutura nos dados que o modelo não está capturando. Nesse caso, deve-se considerar uma família de modelos mais expressiva (maior grau, modelo não linear, variáveis adicionais).

Se os resíduos estão **espalhados aleatoriamente em torno de zero**, sem estrutura visível, o ajuste é adequado para a família de modelos escolhida.

Se a variância dos resíduos **cresce sistematicamente com x** , há heterocedasticidade — pode ser necessária uma transformação dos dados ou um modelo de regressão ponderada. Vale ressaltar que R^2 elevado não garante um bom modelo: a análise de resíduos é complementar e indispensável.

4 Modelos Não Lineares e Linearização

4.1 Crescimento populacional e lei de potência

Questão 4.1 — Crescimento populacional e lei de potência

Enunciado: A tabela abaixo apresenta dados históricos da população urbana brasileira (em milhões):

Ano	1960	1970	1980	1990	2000	2010
Pop. (M)	32	52	82	111	138	161

Defina $t = \text{Ano} - 1960$ (anos desde 1960).

(a) Teste três modelos: Exponencial $P(t) = ae^{bt}$ (via linearização); Potência $P(t) = at^b$ (via log-log); Polinomial grau 2 (via regressão polinomial). Para cada, reporte os parâmetros estimados e o R^2 .

(b) Plote os três modelos sobre os dados. Qual apresenta melhor ajuste visual?

(c) Preveja a população em $t = 60$ (ano 2020). O valor real foi ≈ 171 M. Calcule o erro percentual de cada modelo.

(d) Limitação da linearização: use ajuste não linear direto para comparar os parâmetros obtidos com a linearização.

(a) Ajuste dos três modelos ao crescimento populacional urbano:

Os três modelos foram ajustados aos dados de população urbana brasileira com $t = \text{Ano} - 1960 \in \{0, 10, 20, 30, 40, 50\}$. Os resultados obtidos são apresentados a seguir.

Modelo exponencial $P(t) = ae^{bt}$ (via linearização $\ln P = \ln a + bt$):

$$\hat{a} = 37,1829, \quad \hat{b} = 0,032312, \quad R^2 = 0,9193.$$

Modelo potência $P(t) = at^b$ (via linearização log-log):

$$\hat{a} = 10,0830, \quad \hat{b} = 0,706848, \quad R^2 = 0,9992.$$

Modelo polinomial de grau 2 (via regressão polinomial):

$$P(t) = 29,6071 + 2,6361t + 5,36 \times 10^{-4}t^2, \quad R^2 = 0,9973.$$

Tabela 8: Parâmetros estimados e R^2 dos três modelos de crescimento populacional.

Modelo	Parâmetros estimados	R^2
Exponencial (ae^{bt})	$\hat{a} = 37,1829, \hat{b} = 0,032312$	0,9193
Potência (at^b)	$\hat{a} = 10,0830, \hat{b} = 0,706848$	0,9992
Polinomial grau 2	$c_0 = 29,6071, c_1 = 2,6361, c_2 = 5,36 \times 10^{-4}$	0,9973

O modelo exponencial apresenta o menor R^2 entre os três (0,9193), o que já indica que a hipótese de crescimento percentual constante não se sustenta para o período

completo: o ritmo de urbanização brasileira foi desacelerando ao longo das décadas. Os modelos de potência e polinomial de grau 2 descrevem bem essa desaceleração, com R^2 superiores a 0,997.

(b) Comparação visual dos modelos sobre os dados:




Figura 13: Três modelos ajustados aos dados históricos de população urbana brasileira ($t = \text{Ano} - 1960$). O modelo exponencial superestima progressivamente os anos finais; os modelos de potência e polinomial de grau 2 acompanham a desaceleração do crescimento com maior fidelidade.

Visualmente, o **modelo de potência** e o **polinomial de grau 2** apresentam a melhor aderência aos dados no intervalo observado, capturando a concavidade decrescente da curva de urbanização. O modelo exponencial, por impor crescimento relativo constante, diverge sistematicamente dos pontos a partir de $t = 30$ (ano 1990), superestimando os valores observados — comportamento característico de *underfitting* no sentido de modelo incorretamente especificado.

(c) Previsão para $t = 60$ (ano 2020) e erros percentuais:

Tabela 9: Previsão da população urbana em 2020 ($t = 60$) e erro percentual em relação ao valor real de 171,0 M.

Modelo	Previsão (M)	Erro percentual
Exponencial	258,41	51,12%
Potência	182,17	6,53%
Polinomial grau 2	189,70	10,94%

A superestimação do modelo exponencial em quase 51% confirma que a hipótese de crescimento ilimitado a taxa constante é inadequada para horizontes de extrapolação além do intervalo calibrado. O modelo de **potência** produziu a melhor previsão (6,53% de erro), sugerindo que a relação $P \propto t^{0,71}$ captura a dinâmica de desaceleração do processo de urbanização de forma mais parcimoniosa. O polinômio de grau 2, apesar do excelente R^2 no intervalo de ajuste, acumula erro de 10,94% na extrapolação —

comportamento esperado, pois polinômios não possuem interpretação física inerente fora da região calibrada.

(d) Limitação da linearização: comparação com o ajuste não linear direto:

Tabela 10: Comparação entre os parâmetros estimados pela linearização e pelo ajuste não linear direto para o modelo exponencial.

Método	$\hat{a}$	$\hat{b}$	R^2 (espaço original)
Linearização ($\ln P$ vs. t)	37,1829	0,032312	0,9193
Ajuste direto (<code>curve_fit</code>)	44,9429	0,026622	0,9593
Diferença $ \Delta $	7,7600	0,005690	+0,0400

Os dois métodos produzem estimativas distintas para os mesmos parâmetros a e b , com $\Delta a = 7,76$ e $\Delta b \approx 5,7 \times 10^{-3}$. A diferença decorre de uma distinção fundamental nos critérios de otimização.

Ao linearizar $P = ae^{bt}$ tomando $\ln P = \ln a + bt$, aplica-se mínimos quadrados ordinários no espaço logarítmico, minimizando:

$$\sum_{i=1}^n (\ln P_i - \ln \hat{P}_i)^2 = \sum_{i=1}^n (\ln P_i - \ln a - bt_i)^2.$$

Isso equivale a **minimizar erros relativos** em P , atribuindo implicitamente pesos menores aos pontos com valores mais elevados de população (anos mais recentes), que são justamente os mais informativos para a extrapolação.

O ajuste direto via `curve_fit` minimiza os resíduos no **espaço original**:

$$\sum_{i=1}^n (P_i - ae^{bt_i})^2,$$

o que é conceitualmente mais coerente quando o objetivo é prever P em unidades absolutas (milhões de habitantes). O R^2 calculado no espaço original melhora de 0,9193 para 0,9593, confirmando que o ajuste direto representa melhor a variância dos dados de interesse. Em síntese, a linearização é uma alternativa computacionalmente simples, mas introduz uma distorção sistemática nos pesos que pode comprometer tanto a qualidade do ajuste quanto a confiabilidade das extrapolações.

4.2 Quando a linearização distorce

Questão 4.2 — Quando a linearização distorce

Enunciado: Gere dados de uma lei de potência com ruído multiplicativo:

```
1 np.random.seed(11)
2 x_p = np.linspace(1, 10, 20)
3 y_p = 3.0 * x_p**2.5 * (1 + 0.1 * np.random.randn(20))
```

(a) Ajuste via linearização log-log. Reporte a e b e compare com os valores verdadeiros ($a = 3$, $b = 2,5$).

(b) Ajuste via `curve_fit` (mínimos quadrados não lineares diretos). Compare os erros relativos nos parâmetros entre os dois métodos.

(c) Plote os resíduos de ambos os métodos no espaço original. Qual abordagem apresenta resíduos menores e mais homogêneos?

(d) Explique intuitivamente por que o ruído multiplicativo favorece o ajuste direto em relação à linearização.

(a) Ajuste via linearização log-log:

Aplicando $\ln y = \ln a + b \ln x$ e ajustando por mínimos quadrados ordinários no espaço log-log, obtiveram-se:

$$\hat{a} = 2,9276, \quad \hat{b} = 2,4999, \quad R_{\ln}^2 = 0,9817.$$

Tabela 11: Comparação entre os parâmetros estimados pela linearização log-log e os valores verdadeiros do processo gerador ($a = 3$, $b = 2,5$).

Parâmetro	Valor real	Linearização	Erro relativo
a	3,0000	2,9276	2,41%
b	2,5000	2,4999	0,00%

A estimativa de b é notavelmente precisa ($< 0,01\%$ de erro), resultado esperado para o expoente na linearização log-log, pois ele corresponde à inclinação da reta ajustada em escala logarítmica — grandeza que a regressão linear estima com eficiência. Já a apresenta erro relativo de 2,41%, reflexo da distorção introduzida pela transformação no intercepto, que é recuperado via $\hat{a} = e^{\hat{c}_0}$, amplificando qualquer desvio em $\hat{c}_0$.

(b) Ajuste via `curve_fit` (mínimos quadrados não lineares diretos):

$$\hat{a} = 2,8805, \quad \hat{b} = 2,5180, \quad R^2 = 0,9828.$$

Tabela 12: Erros relativos nos parâmetros: linearização log-log vs. ajuste direto.

Parâmetro	Valor real	Linearização	Erro rel.	Ajuste direto
			Erro rel.	
a	3,0000	2,9276	2,41%	2,8805
			3,98%	
b	2,5000	2,4999	0,00%	2,5180
			0,72%	

Neste experimento, a linearização apresentou erro ligeiramente menor em ambos os parâmetros em relação ao ajuste direto, embora as diferenças sejam pequenas. O R^2 do

ajuste direto no espaço original (0,9828) é marginalmente superior ao da linearização (0,9817). A comparação entre os dois critérios de otimização — mínimos quadrados no espaço log vs. espaço original — é discutida em detalhe no item (d).

(c) Resíduos no espaço original e RMSE:




Figura 14: Resíduos $r_i = y_i - \hat{y}_i$ no espaço original para a linearização log-log e para o ajuste direto não linear. O ajuste direto apresenta resíduos menores e distribuição mais homogênea ao longo de x .

Tabela 13: RMSE no espaço original para os dois métodos de ajuste.

Método	RMSE
Linearização log-log	40,0312
Ajuste direto (<code>curve_fit</code>)	38,8562

O ajuste direto apresenta RMSE inferior (38,86 vs. 40,03) e, como observado no gráfico, resíduos com variância mais uniforme ao longo do eixo x . Na linearização, os resíduos crescem em magnitude para valores maiores de x — sinal de heterocedasticidade induzida pela transformação logarítmica, discutida no item (d).

(d) Por que o ruído multiplicativo favorece o ajuste direto:

O processo gerador dos dados é:

$$y_i = 3,0 \cdot x_i^{2,5} \cdot (1 + \varepsilon_i), \quad \varepsilon_i \sim \mathcal{N}(0, 0,01),$$

em que o ruído ε_i é **multiplicativo**: sua magnitude é proporcional ao valor de y , e não constante. Ao aplicar a transformação logarítmica, obtém-se:

$$\ln y_i = \ln 3 + 2,5 \ln x_i + \underbrace{\ln(1 + \varepsilon_i)}_{\approx \varepsilon_i - \varepsilon_i^2/2 + \dots}.$$

Para $|\varepsilon_i| \ll 1$, a aproximação $\ln(1 + \varepsilon_i) \approx \varepsilon_i$ é razoável, de modo que o erro transformado tem variância *aproximadamente* constante no espaço log. Entretanto, a regressão linear

no espaço logarítmico minimiza:

$$\sum_{i=1}^n (\ln y_i - \ln \hat{y}_i)^2 = \sum_{i=1}^n \left(\ln \frac{y_i}{\hat{y}_i} \right)^2,$$

o que equivale a penalizar **erros relativos**, atribuindo pesos implicitamente menores aos pontos de maior magnitude. Em consequência, os pontos com y elevado — que na lei de potência correspondem a x grandes — são sistematicamente subponderados no ajuste logarítmico, gerando os resíduos crescentes observados no espaço original.

O ajuste direto via `curve_fit`, por sua vez, minimiza:

$$\sum_{i=1}^n (y_i - \hat{a} x_i^{\hat{b}})^2,$$

critério que pondera todos os pontos de forma uniforme no espaço original da variável de interesse. Quando o ruído é multiplicativo e as magnitudes de y variam em ordens de grandeza ao longo do domínio, essa abordagem produz resíduos mais homogêneos e parâmetros com menor viés em relação ao processo gerador. A linearização permanece uma boa aproximação inicial — especialmente para estimar valores de partida para algoritmos iterativos — mas o ajuste direto deve ser preferido sempre que a adequação estatística no espaço original for o critério primário de avaliação.

5 Comparação Integrada: Interpolação vs. Ajuste

5.1 Tabela de síntese

Questão 5.1 — Tabela de síntese

Enunciado: Com base nos experimentos realizados nas seções anteriores, preencha a tabela abaixo.

Tabela 14: Tabela de síntese: Interpolação vs. Ajuste por Mínimos Quadrados.

Aspecto	Interpolação	Ajuste (MQ)
Passagem pelos dados		
Reação ao ruído		
Número de parâmetros		
Risco de oscilação		
Extrapolação		
Escolha do modelo		
Quando preferir		
Ferramenta típica		

Resposta:

A tabela a seguir sistematiza as principais diferenças entre interpolação e ajuste por mínimos quadrados, com base nos experimentos conduzidos nas Seções 1–4.

Tabela 15: Síntese comparativa entre interpolação e ajuste por mínimos quadrados.

Aspecto	Interpolação	Ajuste (MQ)
Passagem pelos dados	Exata — a curva passa obrigatoriamente por todos os pontos fornecidos	Aproximada — minimiza $\sum r_i^2$; em geral não passa por nenhum ponto
Reação ao ruído	Amplifica o ruído: o polinômio é forçado a passar pelos erros experimentais	Suaviza o ruído: os resíduos são distribuídos entre todos os pontos
Número de parâmetros	Determinado automaticamente pelo número de pontos ($n + 1$ pontos $\Rightarrow$ grau $\leq n$)	Escolhido pelo analista com base em critérios como AIC, validação cruzada ou conhecimento físico do problema
Risco de oscilação	Alto para grau elevado (fenômeno de Runge); mitigável com nós de Chebyshev ou splines cúbicas	Menor para modelos bem especificados; pode ocorrer sobreajuste quando o grau é excessivo em relação a n
Extrapolação	Perigosa fora do intervalo de interpolação: polinômios de alto grau divergem rapidamente	Mais estável quando o modelo tem respaldo físico; modelos empíricos sem fundamento também extrapolam mal
Escolha do modelo	Automática — depende apenas dos nós e da família escolhida (Lagrange, Newton, spline)	Exige conhecimento prévio: família funcional (e^{bt} , t^b , polinômio) deve ser adequada à relação subjacente
Quando preferir	Dados de alta precisão (erro $\ll 1\%$); necessidade de reprodução exata; integração e derivação numéricas	Dados com ruído ou subnotificação relevante; estimação de parâmetros físicos; extrapolação necessária
Ferramenta típica	Lagrange, Newton (diferenças divididas), spline cúbica (not-a-knot , natural)	Regressão linear/polinomial, ajuste exponencial, lei de potência, <code>curve_fit</code> (MQ não linear)

Os experimentos anteriores fornecem suporte quantitativo para cada aspecto da tabela. Em relação à **reação ao ruído**, a Questão 3.1 demonstrou que a interpolação de Lagrange de grau 6 sobre dados ruidosos produziu previsão de 12,93 para $f(3,5)$, enquanto o ajuste exponencial obteve 0,2620 — erro percentual de 13,8% frente ao valor real 0,3041, contra mais de 4000% do interpolador. Esse contraste ilustra de forma inequívoca que interpolar dados ruidosos significa memorizar os erros de medição.

Quanto ao **risco de oscilação**, a Questão 1.3 mostrou que a norma do erro infinito com nós igualmente espaçados cresceu de $4,38 \times 10^{-1}$ para $n = 5$ até $1,44 \times 10^1$ para $n = 17$ na função de Runge — crescimento de mais de 30 vezes — enquanto com nós de Chebyshev o mesmo erro *decreceu* de $4,02 \times 10^{-1}$ para $3,26 \times 10^{-2}$. O fenômeno de sobreajuste em regressão (Q2.2) é análogo: o polinômio de grau 14 atingiu $R^2 = 1,0000$ nos 15 pontos de treino, mas $\|f - p_{14}\|_\infty \approx 15,2$ nos 500 pontos de avaliação — o mesmo mecanismo de oscilação, agravado pelo ruído.

No que tange à **extrapolação**, a Questão 4.1 evidenciou que o modelo exponencial, com $R^2 = 0,9193$ no intervalo calibrado, produziu erro de 51,12% em $t = 60$ (ano 2020), enquanto o modelo de potência — com $R^2 = 0,9992$ e respaldo físico mais adequado para a dinâmica de urbanização — gerou erro de apenas 6,53%. Isso reforça que o R^2 elevado no intervalo de ajuste não garante extrapolação confiável: a família funcional deve ser escolhida com base na compreensão do fenômeno.

Por fim, a **escolha do modelo** mostrou-se crítica nos cenários estudados: o gráfico de resíduos da Questão 3.2 revelou padrão sistemático em arco para o modelo linear ajustado a dados exponenciais, enquanto os resíduos do ajuste exponencial distribuíram-se aleatoriamente em torno de zero — regra de diagnóstico que complementa o R^2 e é indispensável para validar a especificação do modelo. Critérios como o AIC (Q2.3) penalizam adequadamente a complexidade excessiva, apontando para soluções mais parcimoniosas e generalizáveis.

5.2 Tomada de decisão em cenários reais

Questão 5.2 — Tomada de decisão em cenários reais

Enunciado: Para cada cenário abaixo, indique qual abordagem você usaria e justifique com base nos conceitos da investigação:

(a) Um engenheiro de controle tem a curva $v \times t$ de um motor medida com sensores de alta precisão (erro $< 0,01\%$) em 50 instantes de tempo. Ele precisa calcular a posição por integração numérica.

(b) Um epidemiologista tem contagens diárias de casos de uma doença em 30 dias, com ruído de subnotificação de aproximadamente 15%. Ele precisa estimar a taxa de crescimento r no modelo $C = C_0 e^{rt}$.

(c) Um projetista de pontes tem 8 medições de deslocamento vs. carga em uma viga, obtidas em laboratório sem erros instrumentais significativos. Ele precisa interpolar deslocamentos para cargas intermediárias.

(d) Um cientista de dados tem 500 pares (x_i, y_i) de medições físicas com ruído gaussiano. Ele suspeita que $y = ax^b + c$, mas não tem certeza do valor de c .

Resposta:

(a) Curva $v \times t$ de motor com precisão $< 0,01\%$ — integração numérica:

Recomenda-se **interpolação por spline cúbica (not-a-knot)**. Com 50 pontos e erro instrumental inferior a 0,01%, os dados podem ser tratados como exatos para fins práticos — não há ruído relevante a suavizar. A spline cúbica passa exatamente por todos os 50 instantes medidos, garante continuidade até a segunda derivada (C^2) e produz derivadas locais bem comportadas, o que é fundamental para a qualidade da integração numérica subsequente. Um polinômio global de grau 49 seria inviável: como demonstrado na Questão 1.4 com dados de temperatura de Alfenas e na Questão 1.3

com a função de Runge, polinômios de alto grau com nós igualmente espaçados oscilam violentamente — introduzindo erros artificiais exatamente onde a curva $v(t)$ deve ser fiel para que $\int v dt$ seja preciso. A spline evita esse problema dividindo o intervalo em segmentos cúbicos suaves.

(b) Contagens diárias de casos com $\approx 15\%$ de ruído — estimação de taxa de crescimento r :

Recomenda-se **ajuste exponencial por mínimos quadrados não lineares diretos** (`curve_fit` com modelo $C = C_0 e^{rt}$). Com ruído de subnotificação de 15% — nível substancialmente mais elevado do que o $\sigma = 0,2$ estudado na Questão 3.1 — a interpolação amplificaria os erros de registro e produziria estimativas de r completamente espúrias. O ajuste por MQ distribui os resíduos entre os 30 dias, atenuando o efeito de cada ponto ruidoso individualmente. Prefere-se o ajuste direto não linear ao invés da linearização via $\ln C$ pelos motivos demonstrados na Questão 4.1: a linearização minimiza erros no espaço logarítmico, subponderando implicitamente os pontos de maior magnitude — justamente os mais informativos para a estimação de r no final da série. A análise de resíduos (Q3.2) deve ser conduzida após o ajuste para verificar que não há padrão sistemático residual indicativo de modelo inadequado.

(c) Oito medições deslocamento $\times$ carga em laboratório sem erros instrumentais:

Recomenda-se **interpolação por spline cúbica (not-a-knot)**. O contexto é análogo ao do projeto integrador da Seção 6: dados laboratoriais de alta precisão, conjunto pequeno e bem controlado, com necessidade de estimar valores intermediários. Como demonstrado na Questão 6.1, a spline cúbica com os 8 pontos de calibração do sensor de pressão produziu resíduo máximo nulo nos nós e curva suave em todo o intervalo — comportamento fisicamente plausível para a relação deslocamento–carga de uma viga, que tipicamente é contínua e apresenta variação suave. Um polinômio global de grau 7 poderia introduzir oscilações nas extremidades do intervalo, conforme evidenciado pela Questão 1.4 para os dados de temperatura de Alfenas (diferenças de até $2,89^\circ\text{C}$ nas bordas). A spline garante que as estimativas intermediárias sejam fisicamente coerentes com o comportamento elástico da viga.

(d) Quinhentos pares (x_i, y_i) com ruído gaussiano e modelo $y = ax^b + c$:

Recomenda-se **ajuste não linear direto por mínimos quadrados** (`curve_fit` com modelo `lambda x, a, b, c: a*x**b + c`). Três razões fundamentais sustentam essa escolha. Primeiro, a interpolação sobre 500 pontos ruidosos produziria sobreajuste extremo — análogo ao interpolador de Lagrange de grau 29 da Questão 6.2, que gerou RMSE da ordem de 10^6 bar ao memorizar o ruído de entrada. Segundo, o modelo $y = ax^b + c$ não admite linearização direta pela presença do termo aditivo c : a transformação log-log requereria $\ln(y - c)$, mas c é desconhecido, tornando a abordagem circular. O ajuste direto resolve simultaneamente os três parâmetros a , b e c por otimização numérica. Terceiro, como evidenciado na Questão 4.2, o ajuste direto minimiza resíduos no espaço original de y — critério consistente com o objetivo de prever y em unidades físicas — enquanto a linearização distorce os pesos implícitos das observações. Após o ajuste, recomenda-se analisar o gráfico de resíduos (Q3.2) para verificar homocedasticidade e ausência de estrutura sistemática, bem como calcular o AIC para comparar com modelos alternativos mais simples (por exemplo, $y = ax^b$ sem o termo constante), evitando a inclusão de parâmetros desnecessários.

6 Projeto Integrador: Calibração de Sensor

Contexto: Um sensor de pressão industrial gera leituras em milivolts (mV) que precisam ser convertidas em pressão (bar). O fabricante fornece 8 pontos de calibração (obtidos em laboratório, sem erros), mas o técnico suspeita que as leituras em campo contêm ruído de ± 2 mV.

Tabela 16: Dados de calibração (laboratório, sem ruído).

Tensão (mV)	10	20	35	50	65	80	90	100
Pressão (bar)	0,5	1,2	2,3	3,5	4,8	6,0	6,8	7,5

6.1 Calibração precisa (laboratório)

Questão 6.1 — Calibração precisa (laboratório)

Enunciado:

(a) Usando os dados de calibração (sem ruído), ajuste: spline cúbica not-a-knot; regressão polinomial de grau 2 e grau 3; modelo linear simples.

(b) Para cada método, calcule o resíduo máximo $\max_i |y_i - \hat{y}_i|$ nos 8 pontos de calibração.

(c) Plote todas as curvas em $[10, 100]$ mV com 200 pontos de avaliação. Visualmente, qual apresenta o comportamento mais suave?

(d) Se a precisão exigida for $\pm 0,05$ bar, qual(is) método(s) é(são) aceitável(is)? Justifique numericamente.

Resposta:

(a) Ajuste dos modelos aos dados de calibração laboratoriais:

Os quatro modelos foram ajustados aos 8 pontos de calibração sem ruído. Os parâmetros estimados por mínimos quadrados (exceto a spline, que é interpoladora) são apresentados a seguir.

Regressão linear:

$$\hat{p}(x) = -0,3790 + 0,0792x, \quad R^2 = 0,999376.$$

Polinômio grau 2:

$$\hat{p}(x) = -0,3105 + 0,07553x + 3,32 \times 10^{-5}x^2, \\ R^2 = 0,999479.$$

Polinômio grau 3:

$$\hat{p}(x) = -0,0645 + 0,05262x + 5,346 \times 10^{-4}x^2 - 3,038 \times 10^{-6}x^3, \\ R^2 = 0,999960.$$

Spline cúbica (not-a-knot): interpolação exata nos 8 nós; resíduo estruturalmente nulo nos pontos de suporte.

A spline cúbica not-a-knot é um método interpolador: ela passa exatamente por todos os nós de calibração e não possui R^2 no sentido da regressão, uma vez que o resíduo nos pontos de suporte é, por construção, idêntico a zero.

(b) Resíduo máximo nos pontos de calibração:

Tabela 17: Métricas de ajuste de cada modelo nos 8 pontos de calibração laboratoriais.

Método	R^2	RMSE (bar)	$\max_i y_i - \hat{y}_i $ (bar)
Spline cúbica (not-a-knot)	—	0,0000	0,0000
Polinômio grau 3	0,999960	0,0155	0,0234
Polinômio grau 2	0,999479	0,0559	0,0749
Regressão linear	0,999376	0,0611	0,0924

A spline cúbica apresenta resíduo nulo nos nós por construção. Entre os métodos de regressão, o polinômio de grau 3 possui o menor resíduo máximo (0,0234 bar), seguido pelo polinômio de grau 2 (0,0749 bar) e pelo modelo linear (0,0924 bar). Nota-se que, embora os R^2 de todos os modelos de regressão sejam superiores a 0,999, os resíduos máximos diferem substancialmente — reforçando a importância de analisar os resíduos individuais e não apenas o coeficiente de determinação global.

(c) Comportamento visual das curvas em [10, 100] mV:




Figura 15: Comparação das quatro curvas de calibração em [10, 100] mV com 200 pontos de avaliação. A spline cúbica e o polinômio de grau 3 aderem aos dados com comportamento visivelmente mais suave; o polinômio de grau 2 e a regressão linear introduzem desvios crescentes nas extremidades da faixa calibrada.

Visualmente, a **spline cúbica** e o **polinômio de grau 3** apresentam comportamento mais suave e aderente aos dados ao longo de toda a faixa [10, 100] mV. O polinômio de grau 2 introduz desvio crescente nas extremidades, pois a curvatura de segundo grau não é suficiente para representar a leve não linearidade da relação tensão–pressão. A regressão linear, apesar do R^2 elevado, não captura essa curvatura e apresenta os maiores afastamentos nos extremos da faixa calibrada.

(d) Aceitabilidade dos métodos para precisão $\pm 0,05$ bar:

Tabela 18: Verificação da exigência de precisão $\pm 0,05$ bar nos pontos de calibração.

Método	$\max_i y_i - \hat{y}_i $ (bar)	Atende $\pm 0,05$ bar?
Spline cúbica (not-a-knot)	0,0000	Sim (por construção)
Polinômio grau 3	0,0234	Sim
Polinômio grau 2	0,0749	Não
Regressão linear	0,0924	Não

Os métodos que satisfazem a exigência de $\pm 0,05$ bar nos nós de calibração são a **spline cúbica** e o **polinômio de grau 3**. É fundamental ressaltar, contudo, que esta análise avalia exclusivamente os resíduos nos 8 pontos de suporte. A spline cúbica garante interpolação exata nesses nós e continuidade C^2 em todo o intervalo; entretanto, sem conhecer a função verdadeira que relaciona tensão e pressão, não é possível afirmar que a spline apresenta menor erro entre os nós do que os modelos de regressão. Já os métodos de regressão podem apresentar desvios adicionais nas posições não calibradas, dependendo do grau e da curvatura local dos dados. Para aplicações que exijam garantia formal de precisão em todo o intervalo, recomenda-se validar os métodos aprovados com pontos de verificação independentes dos nós de calibração.

6.2 Robustez ao ruído de campo

Questão 6.2 — Robustez ao ruído de campo

Enunciado: Simule 30 leituras de campo com ruído:

```

1 np.random.seed(42)
2 mV_lab = np.array([10, 20, 35, 50, 65, 80, 90, 100],
3 dtype=float)
4 bar_lab = np.array([0.5, 1.2, 2.3, 3.5, 4.8, 6.0, 6.8, 7.5])
5 mV_campo = np.linspace(10, 100, 30)
6 ruído = 2.0 * np.random.randn(30) # +/- 2 mV ruído

```

(a) Aplique a spline cúbica de calibração para converter **mV_ruidoso** em pressão. Plote pressão estimada vs. pressão verdadeira e calcule o RMSE.

(b) Re-ajuste um polinômio de grau 3 diretamente sobre os 30 pontos ruidosos e calcule o RMSE. Compare com o método anterior.

(c) Qual abordagem é mais robusta? Justifique com os valores de RMSE.

(d) O técnico propõe interpolar (Lagrange grau 29) os 30 pontos ruidosos. Sem executar o código, preveja o que aconteceria. Em seguida, execute e confirme.

Resposta:

(a) Spline de calibração aplicada a entradas ruidosas:

A spline cúbica construída sobre os 8 pontos laboratoriais foi utilizada para converter as tensões perturbadas $\tilde{v}_i = v_i + \varepsilon_i$ (com $\varepsilon_i \sim \mathcal{N}(0, 4 \text{ mV}^2)$) em estimativas de pressão. Como a spline é uma função contínua e localmente diferenciável, o erro de saída é aproximadamente proporcional à perturbação de entrada multiplicada pela

sensibilidade local dP/dv :

$$\delta P \approx \left. \frac{dP}{dv} \right|_{v_i} \cdot \varepsilon_i.$$

Para $\sigma = 2$ mV e sensibilidade média de 0,0778 bar/mV, a estimativa analítica do RMSE é $\approx 0,1556$ bar, coerente com o valor obtido numericamente nas simulações conduzidas:

$$\text{RMSE}_{\text{spline}} = 0,1444 \text{ bar.}$$




Figura 16: Pressão estimada pela spline de calibração vs. pressão verdadeira para 30 leituras de campo com ruído $\sigma = 2$ mV ($\text{seed}=42$). O RMSE obtido foi 0,1444 bar.

(b) Polinômio de grau 3 ajustado por mínimos quadrados sobre dados ruidosos:

Um polinômio de grau 3 foi ajustado diretamente sobre os 30 pares $(\tilde{v}_i, P_{\text{verdade},i})$ por mínimos quadrados. Por operar em modo de regressão (e não interpolação), o polinômio não é forçado a passar por nenhum dos pontos perturbados, distribuindo o efeito do ruído entre todas as 30 observações. Os resultados obtidos foram:

$$R^2 = 0,9965, \quad \text{RMSE}_{\text{pol. grau 3}} = 0,0664 \text{ bar.}$$

(c) Comparação de robustez:

Tabela 19: Comparação de RMSE entre os dois métodos para realização única ($\text{seed}=42$) e análise de Monte Carlo ($N = 1000$, $\sigma = 2$ mV).

Método	RMSE			
seed 42	RMSE			
médio	Desv.			
pad.	RMSE			
mediana				
Spline + entrada ruidosa	0,1444	0,1513	0,0198	0,1506
Pol. grau 3 (MQ, ruidoso)	0,0664	0,0525	0,0169	0,0512
Todas as entradas em bar.				

Nos experimentos realizados, a análise de Monte Carlo ($N = 1000$ realizações independentes, $\sigma = 2$ mV) indicou que o **polinômio de grau 3 por mínimos quadrados apresentou RMSE inferior** ao da spline em todas as 1000 realizações simuladas. O RMSE médio do polinômio (0,0525 bar) foi aproximadamente $2,9\times$ inferior ao da spline (0,1513 bar) nesta configuração de simulação. Cabe ressaltar que esses resultados foram obtidos para um nível de ruído específico ($\sigma = 2$ mV) e para a relação tensão–pressão dos dados de calibração fornecidos; a vantagem observada reflete as condições do experimento e não deve ser generalizada como uma superioridade incondicional do método de regressão sobre a spline em qualquer cenário.




Figura 17: Distribuição do RMSE para 1000 realizações de Monte Carlo ($\sigma = 2$ mV). Nos experimentos realizados, o polinômio de grau 3 por mínimos quadrados apresentou RMSE inferior ao da spline de calibração em todas as realizações para esta configuração de simulação.

A vantagem do polinômio de grau 3 nas simulações realizadas decorre de um princípio da teoria da estimação: o ajuste por mínimos quadrados com $n = 30$ observações *dilui* a variância do ruído de entrada entre todos os pontos, ao passo que a spline *propaga* o erro de cada tensão medida diretamente à saída, de forma ponto a ponto, via a sensibilidade local dP/dv . Em cenários com ruído de maior amplitude ou com relações tensão–pressão de maior curvatura local, o comportamento relativo dos dois métodos pode diferir.

(d) Interpolação de Lagrange de grau 29 sobre dados ruidosos — previsão e confirmação:

Previsão teórica: Um polinômio de Lagrange de grau 29 é forçado a interpolar exatamente os 30 pares $(\tilde{v}_i, P_{\text{verdade},i})$, cujas abscissas $\tilde{v}_i = v_i + \varepsilon_i$ estão irregularmente perturbadas pelo ruído. Polinômios de grau elevado com nós irregulares tendem a oscilar violentamente entre os pontos de suporte — comportamento análogo ao fenômeno de Runge estudado na Seção 1. Prevê-se, portanto, que o RMSE resultante será ordens de grandeza superior ao de qualquer método de regressão.

Confirmação numérica:

$$\text{RMSE}_{\text{Lagrange grau 29}} = 2,403 \times 10^6 \text{ bar}, \quad \text{Erro máximo} = 1,030 \times 10^7 \text{ bar}.$$




Figura 18: Comparação entre o polinômio de Lagrange grau 29 e o polinômio de grau 3 por mínimos quadrados sobre os 30 pontos ruidosos. As oscilações explosivas do interpolador de grau 29 confirmam a previsão teórica — o mesmo mecanismo do fenômeno de Runge.

A previsão foi integralmente confirmada: o RMSE do interpolador de Lagrange grau 29 é aproximadamente 4×10^7 vezes superior ao do polinômio de grau 3 por mínimos quadrados. As oscilações explosivas resultam do condicionamento numericamente adverso de polinômios de grau elevado com nós irregularmente distribuídos — exatamente o mesmo mecanismo que fundamenta o fenômeno de Runge. Este resultado reforça, de forma dramática, a inadequação da interpolação de alto grau quando os dados contêm ruído.

6.3 Decisão final e documentação

Questão 6.3 — Decisão final e documentação

Enunciado:

(a) Você é o engenheiro responsável. Escreva um parágrafo técnico (máximo 10 linhas) recomendando o método de conversão $\text{mV} \rightarrow \text{bar}$ para uso em campo. Inclua: o método escolhido e sua justificativa; o erro esperado; as condições em que a recomendação deixa de ser válida.

(b) Proponha uma estratégia de re-calibração periódica. Com que frequência e em que condições você recomendaria refazer os experimentos de laboratório? O que sinalizaria a necessidade de re-calibração antes do prazo previsto?

Resposta:

(a) **Parecer técnico — Método de conversão $\text{mV} \rightarrow \text{bar}$ para operação em campo:**

Recomendação Técnica — Conversão mV $\rightarrow$ bar em Operação de Campo

Recomenda-se a **regressão polinomial de grau 3 por mínimos quadrados** para a conversão mV $\rightarrow$ bar em campo. Em análise de Monte Carlo ($N=1000$, $\sigma=2$ mV), o método apresentou RMSE médio de **$0,0525 \pm 0,0169$ bar**, inferior ao da spline com entrada ruidosa (0,1513 bar) em todas as realizações simuladas. A recomendação perde validade nas seguintes condições: (i) operação fora de [10, 100] mV; (ii) nível de ruído substancialmente superior a $\sigma = 2$ mV, situação que requer reavaliação do método; (iii) deriva temporal do sensor por envelhecimento, impacto mecânico ou exposição a agentes corrosivos, que invalida os coeficientes ajustados.

(b) Estratégia de re-calibração periódica:

Frequência recomendada: Re-calibração laboratorial a cada **12 meses** em condições normais de operação (temperatura 15–35 °C, pressão na faixa 0,5–8,0 bar, ausência de vibrações mecânicas intensas).

Verificação em campo: Ao início de cada turno operacional, verificar ao menos dois pontos de referência rastreáveis — por exemplo, pressão atmosférica local certificada e pressão de linha padrão conhecida — confirmando que o erro de leitura não ultrapassa $\pm 0,10$ bar. Os registros devem ser armazenados em log auditável com data, hora e identificação do operador, permitindo rastreabilidade metrológica em conformidade com normas aplicáveis (p.ex., ABNT NBR ISO/IEC 17025).

Sinais de degradação que indicam re-calibração antecipada:

- Deriva sistemática superior a $\pm 0,08$ bar nos pontos de verificação por três dias consecutivos, indicando deslocamento da curva de calibração;
- Desvio-padrão das leituras superior a 0,15 bar em dez medições consecutivas com pressão de referência estável e conhecida;
- Ocorrência de sobrepressão (acima de 110% da escala nominal) ou operação fora da faixa de temperatura especificada pelo fabricante;
- Impacto mecânico, vibração excessiva ou contato com agente corrosivo sobre o transdutor.

A re-calibração deve ser antecipada sempre que qualquer um dos sinais acima for detectado, independentemente do prazo anual, garantindo rastreabilidade metrológica contínua e conformidade com as normas aplicáveis ao setor.

7 Desafio (Opcional — Pontuação Extra)

7.1 Spline de suavização (smoothing spline)

Questão 7.1 — Spline de suavização

Enunciado: A spline de suavização resolve o compromisso entre ajuste e suavidade via o funcional:

$$J_\lambda(s) = \sum_{i=1}^n (y_i - s(x_i))^2 + \lambda \int (s''(x))^2 dx.$$

(a) Use `scipy.interpolate.UnivariateSpline` com parâmetro s (equivalente a λ) nos dados de Q3.1. Teste $s \in \{0; 0,1; 0,5; 1,0; 5,0\}$.

(b) Plote as cinco curvas. Identifique o valor de s que oferece melhor equilíbrio visual entre ajuste e suavidade.

(c) Calcule o RMSE em relação à função verdadeira $5e^{-0,8x}$ para cada valor de s . O RMSE mínimo coincide com o melhor visual?

(d) Interprete o papel de λ como regularização. Como esse conceito se relaciona com o sobreajuste estudado em Q2.2?

Resposta:

(a) Ajuste de `UnivariateSpline` para $s \in \{0; 0,1; 0,5; 1,0; 5,0\}$:

As cinco splines de suavização foram ajustadas aos dados ruidosos de Q3.1 ($f(x) = 5e^{-0,8x}$, `seed=3`, $\sigma_\varepsilon = 0,2$). O parâmetro s da `UnivariateSpline` do SciPy não corresponde diretamente a λ , mas atua como limite superior para a soma dos resíduos quadráticos: o algoritmo FITPACK seleciona automaticamente λ e o número de nós internos de modo que $\sum_{i=1}^n (y_i - s(x_i))^2 \leq s$. Para $s = 0$, a restrição impõe interpolação exata (RSS = 0), enquanto $s \rightarrow \infty$ leva a curva a convergir para uma reta (penalidade de curvatura dominante).

(b) Comparação visual das cinco curvas:




Figura 19: Smoothing splines com $s \in \{0; 0,1; 0,5; 1,0; 5,0\}$ ajustadas aos dados ruidosos de Q3.1 e função verdadeira $5e^{-0,8x}$. Para $s = 0$ a curva interpola exatamente os pontos ruidosos; para $s = 0,1$ o equilíbrio visual entre fidelidade e suavidade é mais adequado; valores maiores de s produzem suavização excessiva.

Visualmente, o valor $s = 0,1$ oferece o melhor equilíbrio entre fidelidade aos dados observados e suavidade da curva: a spline acompanha a tendência exponencial decrescente sem memorizar as flutuações individuais do ruído, ao contrário de $s = 0$ (interpolação exata, que captura o ruído).

(c) RMSE em relação à função verdadeira $f(x) = 5e^{-0,8x}$:

Tabela 20: RMSE em relação à função verdadeira, número de nós internos e RSS nos dados para cada valor de s .

s	RMSE vs. $f(x)$	Nós internos	RSS nos dados
0,0	0,1704	5	0,0000
0,1	0,1496	2	0,0611
0,5	0,1496	2	0,0611
1,0	0,1496	2	0,0611
5,0	0,1496	2	0,0611

Os valores de RMSE para $s \in \{0,1; 0,5; 1,0; 5,0\}$ são numericamente idênticos (0,1496) e apresentam o mesmo número de nós internos (2) e o mesmo RSS (0,0611). Esse comportamento é consequência do algoritmo FITPACK: para este conjunto de dados com apenas 7 pontos e nível de ruído $\sigma_\varepsilon = 0,2$, o algoritmo converge para a mesma configuração de nós internos e o mesmo λ efetivo para todos esses valores de s . Isso indica que, uma vez satisfeita a condição $\text{RSS} \leq s$ com a spline de 2 nós internos, aumentar s não altera a solução — a mesma spline já satisfaz a restrição com folga. Apenas $s = 0$ (interpolação exata) produz resultado distinto, com 5 nós internos e RMSE superior (0,1704), pois impõe RSS nulo nos dados ruidosos. O menor RMSE em relação à função verdadeira foi portanto obtido para qualquer $s \geq 0,1$ neste experimento, coincidindo com o melhor equilíbrio visual observado em (b).

(d) Interpretação de λ como regularização e analogia com Q2.2:

O funcional variacional da smoothing spline,

$$J_\lambda(f) = \underbrace{\sum_{i=1}^n (y_i - f(x_i))^2}_{\text{fidelidade}} + \lambda \underbrace{\int (f''(x))^2 dx}_{\text{penalidade de curvatura}},$$

é matematicamente equivalente à **regularização de Tikhonov (L2)** em problemas inversos: o segundo termo penaliza funções de alta curvatura, impondo um *prior* de suavidade sobre o estimador.

A analogia com o sobreajuste de Q2.2 é direta e precisa:

- Para $\lambda = 0$ ($s = 0$): a penalidade de curvatura é nula, e a spline interpola exatamente os dados ruidosos, memorizando o ruído — comportamento equivalente ao polinômio de grau 14 em Q2.2 ($R^2 = 1,0000$, $\|f - p_{14}\|_\infty \approx 15,2$).
- Para $\lambda \rightarrow \infty$ ($s \rightarrow \infty$): a penalidade domina e a solução converge para uma reta (função de curvatura mínima — análogo ao modelo de grau 1 em Q2.2, que apresenta *underfitting*).

- Para λ intermediário ótimo: a regularização equilibra fidelidade e suavidade, resultando em menor erro de generalização — análogo ao grau 3 identificado como ótimo em Q2.2.

Em termos mais gerais, λ controla a posição do estimador no *trade-off* viés–variância: valores pequenos produzem alta variância (sobreajuste ao ruído) e baixo viés; valores grandes produzem baixa variância e alto viés (subajuste). O valor ótimo de λ minimiza o erro de generalização, não o erro de treinamento.

7.2 Interpolação de Hermite e derivadas conhecidas

Questão 7.2 — Interpolação de Hermite e derivadas conhecidas

Enunciado: Em algumas aplicações, são conhecidos nos nós tanto os valores $f(x_i)$ quanto as derivadas $f'(x_i)$.

- Implemente a interpolação de Hermite cúbica para dois nós x_0 e x_1 , usando $f(x_0)$, $f(x_1)$, $f'(x_0)$, $f'(x_1)$ e as funções de base H_{00} , H_{10} , H_{01} e H_{11} .
- Para $f(x) = \sin(x)$, use os nós $x_0 = 0$, $x_1 = \pi/2$. Compare o erro máximo em $[0, \pi/2]$ entre: Hermite cúbico (4 informações: 2 valores + 2 derivadas); Lagrange cúbico com 4 nós igualmente espaçados; spline cúbica com 4 nós.
- Qual método é mais preciso neste caso? O resultado faz sentido intuitivamente?

Resposta:

(a) Implementação da interpolação de Hermite cúbica:

Dados dois nós x_0 e x_1 com $h = x_1 - x_0$, define-se a variável local normalizada $t = (x - x_0)/h \in [0, 1]$. As quatro funções de base de Hermite cúbica são:

$$H_{00}(t) = 2t^3 - 3t^2 + 1,$$

$$H_{10}(t) = t^3 - 2t^2 + t,$$

$$H_{01}(t) = -2t^3 + 3t^2,$$

$$H_{11}(t) = t^3 - t^2,$$

e o polinômio interpolador de Hermite é dado por:

$$p(x) = f(x_0) H_{00}(t) + h f'(x_0) H_{10}(t) + f(x_1) H_{01}(t) + h f'(x_1) H_{11}(t).$$

Por construção, satisfaz-se $p(x_0) = f(x_0)$, $p(x_1) = f(x_1)$, $p'(x_0) = f'(x_0)$ e $p'(x_1) = f'(x_1)$ — quatro condições de interpolação, determinando unicamente um polinômio de grau ≤ 3 .


Para $f(x) = \sin(x)$, os valores de entrada são:

$$\begin{aligned} f(x_0) &= \sin(0) = 0,000000, & f'(x_0) &= \cos(0) = 1,000000, \\ f(x_1) &= \sin(\pi/2) = 1,000000, & f'(x_1) &= \cos(\pi/2) = 0,000000. \end{aligned}$$

(b) Comparação do erro máximo em $[0, \pi/2]$:

Tabela 21: Erro máximo $\|f - p\|_\infty$ em $[0, \pi/2]$ para os três métodos de interpolação cúbica.

Método	Informações usadas	Nós	h	$\ f - p\ _\infty$
Hermite cúbico	2 valores + 2 derivadas	2	$\pi/2$	0,010791
Lagrange (4 nós equi.)	4 valores	4	$\pi/6$	0,002393
Spline cúbica (4 nós)	4 valores	4	$\pi/6$	0,002393

Figura 20: Comparação do erro de interpolação $|f(x) - p(x)|$ em $[0, \pi/2]$ para os três métodos. Lagrange e spline cúbica com 4 nós igualmente espaçados apresentam erro máximo $4,5\times$ inferior ao Hermite cúbico com 2 nós.**(c) Análise da precisão relativa:**

O método mais preciso neste caso é o **Lagrange com 4 nós igualmente espaçados** (e igualmente a spline cúbica com 4 nós), com $\|f - p\|_\infty = 0,002393$, aproximadamente $4,5\times$ inferior ao erro do Hermite cúbico (0,010791).

Antes de apresentar a fundamentação teórica, é importante notar que a comparação não é perfeitamente equilibrada do ponto de vista da distribuição espacial das informações: o Hermite cúbico utiliza **apenas dois nós** ($x_0 = 0$ e $x_1 = \pi/2$), com suas respectivas derivadas, cobrindo o intervalo com espaçamento $h = \pi/2$; o Lagrange e a spline cúbica utilizam **quatro nós distribuídos** ao longo do intervalo, com espaçamento $h_L = \pi/6$. Embora todos os métodos utilizem exatamente 4 condições de interpolação (grau efetivo ≤ 3), a distribuição espacial dessas condições é qualitativamente diferente: o Hermite concentra toda a informação nos extremos do intervalo, enquanto Lagrange e spline distribuem os nós de forma uniforme ao longo de $[0, \pi/2]$.

O resultado tem fundamentação teórica precisa. Para a interpolação de Hermite cúbica entre dois nós x_0 e x_1 , com $h = x_1 - x_0$, o erro satisfaz:

$$|f(x) - p(x)| \leq \frac{M_4}{4!} |\psi_4(x)|, \quad \psi_4(x) = (x - x_0)^2(x - x_1)^2,$$

onde $M_4 = \max_{[x_0, x_1]} |f^{(4)}(x)|$. O fator $(x - x_0)^2(x - x_1)^2$ atinge seu máximo em $x^* = (x_0 + x_1)/2$, com valor $h^4/16$, de modo que:

$$\|f - p\|_\infty \leq \frac{M_4}{4!} \cdot \frac{h^4}{16} = \frac{M_4 h^4}{384}.$$

Para $f(x) = \sin(x)$, tem-se $f^{(4)}(x) = \sin(x)$ e, portanto, $M_4 = \max_{[0, \pi/2]} |\sin(x)| = 1$. Com $h = \pi/2$:

$$\|f - p_{\text{Hermite}}\|_{\infty} \leq \frac{(\pi/2)^4}{384} \approx \frac{6,088}{384} \approx 0,01585,$$

cota consistente com o erro máximo observado (0,010791).

Para o Lagrange cúbico com $n = 3$ e 4 nós igualmente espaçados ($h_L = \pi/6$), a cota de erro é:

$$\|f - p\|_{\infty} \leq \frac{M_4}{4!} \|\omega_4\|_{\infty}, \quad \|\omega_4\|_{\infty} \approx \frac{9\sqrt{3}}{256} h_L^4,$$

o que, com $h_L = \pi/6$ e $M_4 = 1$, fornece uma cota de ordem $h_L^4 \approx 0,0752$, muito inferior a $h^4 = (\pi/2)^4 \approx 6,088$. Como a cota de erro escala com h^4 , reduzir o espaçamento por um fator de 3 diminui a cota por um fator de $3^4 = 81$. O erro efetivo observado foi reduzido por um fator de $\approx 4,5$, dentro da ordem de grandeza esperada pela teoria.

Em síntese, a maior precisão do Lagrange e da spline cúbica neste experimento é consequência direta da distribuição mais uniforme dos nós ao longo do intervalo, que reduz o espaçamento efetivo e, portanto, o erro de interpolação. O Hermite cúbico seria preferível em cenários onde *derivadas são conhecidas mas nós intermediários não estão disponíveis*, ou onde a continuidade das derivadas na junção de segmentos é uma exigência intrínseca do problema (animação computacional, dinâmica de veículos). Quando nós adicionais podem ser inseridos livremente, Lagrange ou spline com espaçamento reduzido são geralmente superiores.

7.3 Regressão com múltiplas variáveis

Questão 7.3 — Regressão com múltiplas variáveis

Enunciado: Um engenheiro mede o consumo de combustível C (L/100 km) de 20 veículos em função de massa m (kg) e potência P (cv):

```
1 np.random.seed(99)
2 m = 1000 + 400 * np.random.rand(20)      # massa: 1000-1400 kg
3 P = 80 + 120 * np.random.rand(20)        # potencia: 80-200 cv
4 C = 0.005*m + 0.03*P - 5 + 0.5*np.random.randn(20)
```

(a) Monte a matriz de design X para o modelo $C = \beta_0 + \beta_1 m + \beta_2 P$ e resolva as equações normais $X^T X \beta = X^T C$ usando `numpy.linalg.solve`. Compare $\hat{\beta}$ com os coeficientes verdadeiros.

(b) Calcule R^2 múltiplo e o erro padrão dos resíduos. O modelo é adequado?

(c) Adicione o termo $\beta_3 m P$ (interação). O R^2 melhora significativamente? Use o AIC para decidir se o termo de interação deve ser incluído.

Resposta:

(a) Equações normais e estimativa de $\hat{\beta}$:

A matriz de design $X \in \mathbb{R}^{20 \times 3}$ para o modelo $C = \beta_0 + \beta_1 m + \beta_2 P$ é construída com uma coluna de uns (intercepto), uma coluna de massas e uma de potências:

$$X = \begin{bmatrix} 1 & m_1 & P_1 \\ \vdots & \vdots & \vdots \\ 1 & m_{20} & P_{20} \end{bmatrix}.$$

As equações normais $X^T X \hat{\beta} = X^T C$ foram resolvidas via `numpy.linalg.solve`, produzindo:

Tabela 22: Comparação entre os coeficientes estimados $\hat{\beta}$ e os valores verdadeiros do processo gerador.

Parâmetro	Valor verdadeiro	$\hat{\beta}$ estimado	Erro absoluto
β_0 (intercepto)	-5,0000	-3,3497	1,6503
β_1 (massa)	0,005000	0,003943	0,001057
β_2 (potência)	0,030000	0,027092	0,002908

O estimador de mínimos quadrados ordinários é não viesado sob as hipóteses clássicas do modelo linear (erros com média zero, homocedásticos e não correlacionados); adicionalmente, pelo **Teorema de Gauss-Markov**, ele é o estimador linear não viesado de menor variância (BLUE) nessas condições. Os desvios observados entre $\hat{\beta}$ e os valores verdadeiros são puramente amostrais e esperados para $n = 20$ observações com $\sigma = 0,5$ L/100 km. O intercepto apresenta o maior erro relativo (33,0%), o que é característico quando as covariáveis não estão centradas e a extrapolação até $m = P = 0$ carece de suporte nos dados.

(b) R^2 múltiplo e erro padrão dos resíduos:

$$R^2 = 0,8237, \quad \hat{\sigma} = 0,5889 \text{ L/100 km.}$$




Figura 21: Resíduos $r_i = C_i - \hat{C}_i$ em função dos valores ajustados $\hat{C}_i$ para o modelo de regressão múltipla sem interação. A distribuição aleatória e homogênea dos resíduos confirma que o modelo está bem especificado.

O $R^2 = 0,8237$ indica que o modelo linear em m e P explica aproximadamente 82,4% da variância total de C — resultado substancial para $n = 20$ com dois regressores. O erro padrão estimado $\hat{\sigma} = 0,5889$ L/100 km é próximo do desvio verdadeiro ($\sigma = 0,5$ L/100 km), confirmando que a família linear é a família correta e que os resíduos refletem essencialmente o ruído aleatório adicionado no processo gerador. A análise gráfica dos resíduos (Fig. 21) não evidencia padrão sistemático, corroborando a adequação do modelo.

(c) Inclusão do termo de interação $\beta_3 mP$ e critério AIC:

Tabela 23: Comparação entre o modelo sem e com o termo de interação mP , via R^2 , RSS e AIC.

Modelo	k	R^2	RSS	AIC
Sem interação ($\beta_0 + \beta_1 m + \beta_2 P$)	3	0,8237	5,8965	-18,4275
Com interação ($+\beta_3 mP$)	4	0,8239	5,8907	-16,4473

$$\Delta R^2 = +0,0002, \quad \Delta \text{AIC} = +1,9802.$$

O ganho de R^2 com a inclusão do termo mP é **desprezível** ($\Delta R^2 = 0,02\%$), e o AIC **aumenta** em $\approx 2,0$ unidades ao adicionar o parâmetro extra, indicando que o modelo sem interação é preferido.

A interpretação é direta: a redução de RSS proporcionada por $\beta_3 mP$ é insuficiente para compensar a penalidade de 2 unidades de AIC pelo parâmetro adicional. Pela **regra prática do AIC**: quando $\Delta \text{AIC} > 2$, o modelo mais complexo não apresenta evidência suficiente de melhoria; quando $\Delta \text{AIC} < -2$, o modelo mais complexo é preferido; valores $|\Delta \text{AIC}| \leq 2$ indicam evidência ambígua.

Este resultado é coerente com o processo gerador: o modelo verdadeiro $C = 0,005m + 0,03P - 5 + \varepsilon$ não contém interação mP . A inclusão de β_3 introduz um parâmetro espúrio que o AIC penaliza adequadamente, impedindo o sobreajuste mesmo com n modesto. O critério de informação de Akaike demonstra, portanto, sua eficácia como ferramenta de seleção de modelos parcimoniosos em regressão múltipla.